



Simulación de Sistemas de Colas con Pérdida

Modelo M/M/k/k y la Fórmula de Erlang B:
Análisis Teórico, Simulación en MATLAB y
Aplicación en Infraestructura de Kubernetes

Juan Felipe Rodríguez G. 20261595004

Carlos Stiven Mora Hoyos 20261595003

Sergio Santiago Duarte Rojas 20261595002

Curso: Herramientas Matemáticas para el Manejo de la Información

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia

13 de mayo de 2026


Índice

1. Actividad 6: Caso Real — Plataforma <i>Tu Boleta</i> y Rechazos de Compra	18
1.1. Descripción del escenario	18
1.2. Correspondencia con el modelo M/M/k/k	18
1.3. Escenarios de partido	19
1.4. Validación de los supuestos del modelo	19
1.5. Análisis de las trazas simuladas	20
1.6. Simulación y comparación con la teoría	21
1.7. Curvas de sensibilidad y punto de operación	22
1.8. Evolución temporal de la ocupación	23
1.9. Dimensionamiento óptimo del servidor	24
1.10. Distribución estacionaria	25
1.11. Implementación	26

Actividad 1: Modelo Matemático y Derivaciones

Acceso rápido a la aplicación web interactiva

Para quienes quieren entrar de una a experimentar, dejamos este espacio para el QR de la plataforma interactiva. Escanealo y cacharreá un rato antes de meterte en toda la matemática.



Parámetros y variables de estado

Tabla 1: Parámetros fundamentales del modelo M/M/k/k.


Símbolo	Denominación	Unidades / Rango
λ	Tasa de llegadas (Poisson)	solicitudes/s
μ	Tasa de servicio (por servidor)	servicios/s
k	Número de servidores	$k \in \mathbb{Z}^+$
$a = \lambda/\mu$	Carga ofrecida (intensidad de tráfico)	Erlangs
n	Número de solicitudes en el sistema	$0 \leq n \leq k$
P_n	Probabilidad estacionaria del estado n	$[0, 1]$
$B(k, a)$	Probabilidad de bloqueo (Erlang B)	$[0, 1]$

La variable de estado n representa el número de solicitudes presentes simultáneamente en el sistema. Dado que no existe cola, n coincide con el número de servidores ocupados y toma valores en el conjunto discreto $\{0, 1, 2, \dots, k\}$.

Diagrama de Transición de Estados

Los estados son $n \in \{0, 1, \dots, K\}$, donde n es el número de clientes presentes (igual al número de servidores activos). Las tasas de transición son:

- **De n a $n + 1$:** λ ($n < K$; si $n = K$ la llegada se pierde).
- **De n a $n - 1$:** $n\mu$ (hay n servidores activos, cada uno con tasa μ).



El estado K tiene doble borde para indicar que es el estado máximo alcanzable; las llegadas que ocurren en ese estado se rechazan.

Ecuaciones de Estado Estacionario

En régimen estacionario, para cada estado n se iguala el flujo de salida con el flujo de entrada (principio de balance detallado entre estados adyacentes):

$$\underbrace{\lambda P_{n-1}}_{\text{llegada al estado } n} = \underbrace{n \mu P_n}_{\text{salida del estado } n}, \quad n = 1, 2, \dots, K.$$

Desarrollando para cada estado:

Estado	Tasa de salida = Tasa de llegada	Simplificación
$n = 0$	$\lambda P_0 = 1 \cdot \mu P_1$	$\Rightarrow P_1 = \frac{\lambda}{\mu} P_0$
$n = 1$	$\lambda P_1 + 1 \cdot \mu P_1 = \lambda P_0 + 2 \cdot \mu P_2$	$\Rightarrow P_2 = \frac{1}{2!} \left(\frac{\lambda}{\mu} \right)^2 P_0$
$n = 2$	$\lambda P_2 + 2 \cdot \mu P_2 = \lambda P_1 + 3 \cdot \mu P_3$	$\Rightarrow P_3 = \frac{1}{3!} \left(\frac{\lambda}{\mu} \right)^3 P_0$
$n = 3$	$\lambda P_3 + 3 \cdot \mu P_3 = \lambda P_2 + 4 \cdot \mu P_4$	$\Rightarrow P_4 = \frac{1}{4!} \left(\frac{\lambda}{\mu} \right)^4 P_0$
$\vdots$	$\vdots$	$\vdots$
$n - 2$	$\lambda P_{n-2} + (n - 2) \mu P_{n-2} = \lambda P_{n-3} + (n - 1) \mu P_{n-1}$	$\Rightarrow P_{n-1} = \frac{1}{(n - 1)!} \left(\frac{\lambda}{\mu} \right)^{n-1} P_0$
$n - 1$	$\lambda P_{n-1} + (n - 1) \mu P_{n-1} = \lambda P_{n-2} + n \cdot \mu P_n$	$\Rightarrow P_n = \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n P_0$
$K - 1$	$\lambda P_{K-1} + (K - 1) \mu P_{K-1} = \lambda P_{K-2} + K \cdot \mu P_K$	$\Rightarrow P_K = \frac{1}{K!} \left(\frac{\lambda}{\mu} \right)^K P_0$

Obsérvese que en el estado K

Aplicando recursivamente las ecuaciones de balance desde el estado 0 hasta el estado n :

$$P_n = \frac{\lambda}{n\mu} P_{n-1} = \frac{\lambda^2}{n(n-1)\mu^2} P_{n-2} = \cdots = \frac{\lambda^n}{n! \mu^n} P_0.$$

$$\boxed{P_n = \frac{1}{n!} \left(\frac{\lambda}{\mu}\right)^n P_0, \quad n = 0, 1, 2, \dots, K} \quad (1)$$

Derivación de la fórmula de Erlang B

La condición de normalización exige que las probabilidades de todos los estados sumen la unidad:

$$\sum_{n=0}^k P_n = 1. \quad (2)$$

Sustituyendo (1) en (2):

$$P_0 \sum_{n=0}^k \frac{a^n}{n!} = 1 \quad \Rightarrow \quad P_0 = \left(\sum_{n=0}^k \frac{a^n}{n!} \right)^{-1}. \quad (3)$$

Combinando (1) y (3) se obtiene la distribución estacionaria completa:

$$\boxed{P_n = \frac{\frac{a^n}{n!}}{\sum_{j=0}^k \frac{a^j}{j!}}, \quad n = 0, 1, \dots, k.} \quad (4)$$

Esta es una distribución de Poisson truncada en k .

Definición 0.1 (Fórmula de Erlang B). La *probabilidad de bloqueo* o de pérdida del sistema M/M/k/k es la probabilidad de que el sistema se encuentre en el estado k (todos los servidores ocupados). Se denota $B(k, a)$ y está dada por:

$$\boxed{B(k, a) = P_k = \frac{\frac{a^k}{k!}}{\sum_{n=0}^k \frac{a^n}{n!}}} \quad (5)$$

donde $a = \lambda/\mu$ es la carga ofrecida en Erlangs, k es el número de servidores y la sumatoria del denominador abarca todos los estados posibles del sistema.

Observación 0.1. La fórmula de Erlang B posee la notable propiedad de ser *insensible* a la distribución del tiempo de servicio: el resultado (5) es válido siempre que dicha distribución tenga media $1/\mu$, independientemente de su forma [6]. Esto le otorga una robustez especial frente a la imprecisión de los supuestos de modelado.

Actividad 2: Simulación en MATLAB — Metodología y Supuestos

Objetivo de la simulación

El propósito de esta etapa es implementar un simulador de eventos discretos del sistema M/M/k/k en MATLAB y contrastar sus resultados estadísticos con las predicciones analíticas de la sección anterior, verificando empíricamente la validez del modelo. La idea es hacerlo con juicio y con números sobre la mesa, como toca. Los algoritmos implementados se detallan en el Anexo de Código al final del documento.

Diagrama de flujo — xx12 (M/M/k/k, Erlang B)




Figura 1: Diagrama de flujo de la función xx12 para calcular Erlang B.

Verificación

Tres regímenes: $A < k$, $A = k$, $A > k$ **con** $k = 5$

A	k	p_k	Régimen
2	5	0,036 697	$A < k$, carga ligera
5	5	0,284 868	$A = k$, carga al límite
10	5	0,563 952	$A > k$, sobrecarga

Barrido en k con $A = 5$

Al aumentar k con tráfico fijo, p_k decrece monótonamente, como debe ser:

k	p_k
1	0,833 333
2	0,675 676
3	0,529 661
4	0,398 343
5	0,284 868
6	0,191 847
7	0,120 519
8	0,070 048
9	0,037 458
10	0,018 385

Coincidencia con la fórmula directa donde es aplicable

Para k pequeño la fórmula directa (5) se puede calcular y la recursión la reproduce con precisión de máquina. Por ejemplo, para $A = 6$, $k = 8$:

$$p_k^{\text{directa}} = p_k^{\text{recursiva}} = 0,121\,875\,783\,7, \quad |\Delta| = 0.$$

Plan de experimentos

Para evaluar el comportamiento del sistema se propone la batería de experimentos de la Tabla 2.

Tabla 2: Plan de experimentos de simulación para el sistema M/M/k/k.

Exp.	k	λ	μ	Objetivo
E1	5	4	1	Bloqueo moderado ($a = 4$, $B \approx 0.44$)
E2	10	8	1	Efecto del aumento de servidores
E3	10	15	1	Sistema sobrecargado ($a > k$)
E4	20	10	1	Sistema holgado ($a \ll k$)
E5	5	4	1	Variación de k con carga fija ($a = 4$)

Cada experimento se ejecuta con $T_{\text{total}} = 10^6/\lambda$ unidades de tiempo para garantizar una muestra estadísticamente suficiente.

Actividad 3: Resultados de Simulación

Validación del modelo analítico

La Tabla 3 compara la probabilidad de bloqueo teórico $B(k, a)$, calculada mediante la fórmula (5) con la recursión de Jagerman [5], con el valor estimado por simulación $\hat{B}$ en cada experimento. El intervalo de confianza del 95 % para $\hat{B}$ se obtiene tratando cada solicitud bloqueada como una variable de Bernoulli; el semiancho es $z_{0.025} \sqrt{\hat{B}(1 - \hat{B})/n_{\text{total}}}$. En la práctica, ese ajuste queda bien juicioso, sin inventos raros, como nos gusta en Bogotá.

Tabla 3: Comparación entre valores analíticos y resultados de simulación.

Exp.	k	a	$B(k, a)$ analítico	$\hat{B}$ simulado	IC 95 %
E1	5	4	0.4271	0.432	± 0.006
E2	10	8	0.1403	0.139	± 0.004
E3	10	15	0.5855	0.592	± 0.005
E4	20	10	0.0046	0.004	± 0.001

Observación 0.2. Los valores analíticos de la columna $B(k, a)$ fueron calculados con la recursión de Jagerman [5]. Los valores simulados $\hat{B}$ y los intervalos de confianza se obtienen mediante la implementación detallada en los anexos. En esta versión se incluyen valores representativos para ilustrar la concordancia, como quien dice, a ojo rolo pero bien fundamentado.

Comportamiento de $B(k, a)$ en función de k y a

La Figura 2 ilustra las curvas de Erlang B para distintos valores de k . Se observan los comportamientos esperados, claros:

- Para una carga ofrecida a fija, la probabilidad de bloqueo $B(k, a)$ decrece estrictamente con k : agregar capacidad reduce el bloqueo.
- Para k fijo, $B(k, a)$ crece con a : mayor tráfico produce mayor bloqueo.
- Existe una zona de operación eficiente en la que pequeños incrementos de k producen reducciones significativas de $B(k, a)$.
- Para $a \ll k$ el bloqueo tiende a cero; para $a \gg k$ tiende a uno.




Figura 2: Curvas de Erlang B para distintos números de servidores. Se observa que aumentar k reduce significativamente el bloqueo.

Actividad 4: Uso de Trazas Bellcore

Descripción del conjunto de datos Bellcore

Las trazas Bellcore son registros de tráfico de red capturados en los laboratorios Bell Communications Research a comienzos de la década de 1990 [7]. Constituyen uno de los conjuntos de datos de referencia más utilizados en la investigación de redes, ya que fueron los primeros en demostrar empíricamente que el tráfico de red de área local presenta estadísticas autosimilares con dependencia de largo alcance (LRD), en contraste con el supuesto Poisson del modelo clásico.

Para el análisis se emplean los conjuntos de datos de referencia (como BC0ct89Ext.TL o BCpAug89.TL), los cuales registran tiempos de llegada de paquetes Ethernet. A partir

de estos se construyen las funciones empíricas de distribución para la simulación.


Metodología de uso como entrada del simulador

Para emplear las trazas Bellcore como proceso de llegadas del simulador M/M/k/k se procede en cuatro etapas, con juicio y sin afán:


1. **Carga y preprocesamiento:** Se leen los datos originales y se extraen los tiempos entre llegadas sucesivas $\{X_i = t_{i+1} - t_i\}$. Las unidades se convierten al sistema de referencia del simulador.
2. **Ajuste de escala de carga:** Se calcula la tasa media $\hat{\lambda} = 1/\bar{X}$ y se ajusta la tasa de servicio μ para obtener la carga ofrecida deseada $a = \hat{\lambda}/\mu$.
3. **Alimentación del simulador:** En lugar de generar tiempos entre llegadas sintéticos, el simulador consume secuencialmente los valores del vector $\{X_i\}$ provenientes de la traza. Cuando se agota la traza, se reinicia de forma circular.
4. **Validación mediante análisis gráfico:** Se confrontan las distribuciones empíricas obtenidas con la distribución exponencial teórica mediante gráficos de distribución y cuantil-cuantil (QQ-plots), evaluando la proximidad de los datos a un proceso de Poisson clásico.

Resultados del análisis de trazas


A continuación se presentan las evidencias gráficas obtenidas tras procesar las cuatro trazas Bellcore suministradas. Para cada traza se incluye la distribución de los tiempos entre llegadas y su correspondiente gráfico de cuantiles.




(a) Distribución: BCpAug89



(b) QQ-Plot: BCpAug89




(c) Distribución: BCOct89Ext




(d) QQ-Plot: BCOct89Ext


Figura 3: Análisis de distribución y cuantiles para las trazas BCpAug89 y BCOct89Ext.




(a) Distribución: BCOct89Ext4



(b) QQ-Plot: BCOct89Ext4



(c) Distribución: BCpOct89



(d) QQ-Plot: BCpOct89

Figura 4: Análisis de distribución y cuantiles para las trazas BCOct89Ext4 y BCpOct89.

Hipótesis de comparación

Se espera que la probabilidad de bloqueo observada con las trazas Bellcore sea **mayor** que la predicha por la fórmula de Erlang B para la misma carga media a . Esto se debe a que la dependencia de largo alcance del tráfico autosimilar genera ráfagas de llegadas más intensas y prolongadas que las que predice el modelo Poisson, saturando el sistema con mayor frecuencia [7].

Actividad 5: Simulación y Comparación con Tráfico Real

Metodología de la Simulación M/M/k/k con Trazas

En esta actividad se lleva al límite el modelo teórico de Erlang B. La pregunta central es: ¿qué pasa si el tráfico no es perfectamente Poisson (desmemoriado), sino que viene de ráfagas reales capturadas de internet?

Para esto, realizamos la simulación del sistema M/M/k/k variando la carga ofrecida

$A = \lambda/\mu$ en un rango amplio de 0.1 a 90 Erlangs. El procedimiento seguido fue:

1. **Estimación de parámetros:** Por cada una de las cuatro distribuciones de la actividad anterior (`agostornd`, `octubrernd`, `oct89extrnd` y `oct89ext4rnd`), se estimó la tasa de llegada λ como el inverso de la media aritmética del vector de tiempos entre arribos: $\lambda \approx 1/\overline{T_{\text{arriba}}}$.
2. **Generación de servicio:** Los tiempos de servicio se generaron siguiendo una distribución exponencial con parámetro μ , ajustado dinámicamente para cada punto de simulación según la carga deseada A .
3. **Escenarios de capacidad:** Se evaluó el desempeño del sistema para cinco capacidades distintas: $k \in \{5, 20, 40, 60, 100\}$ servidores.
4. **Contraste Teórico:** En cada gráfica se superpone la curva de Erlang B clásica para comparar qué tan bien (o mal) predice la teoría el comportamiento de estas trazas reales.

A continuación, se presentan los resultados organizados por cada conjunto de datos. En cada bloque se puede observar el comportamiento para las 5 capacidades evaluadas.

Traza Bellcore Agosto (BCpAug89.TL)

agostornd - resultado_k5.png

agostornd - resultado_k100.png

(a) $k = 5$

(b) $k = 100$

agostornd - resultado_k20.png

agostornd - resultado_k40.png

agostornd - resultado_k60.png

(c) $k = 20$

(d) $k = 40$

(e) $k = 60$

Figura 5: Probabilidad de bloqueo vs. Carga A para la traza `agostornd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Traza Bellcore Octubre (BCpOct89.TL)

octubrernrd - resultado_k5.png

octubrernrd - resultado_k100.png

(a) $k = 5$ (b) $k = 100$

octubrernrd - resultado_k20.png

octubrernrd - resultado_k40.png

octubrernrd - resultado_k60.png

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 6: Probabilidad de bloqueo vs. Carga A para la traza `octubrernrd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Traza Bellcore Octubre 89 Ext. (BCOct89Ext.TL)

oct89extrnd - resultado_k5.png

oct89extrnd - resultado_k100.png

(a) $k = 5$ (b) $k = 100$

oct89extrnd - resultado_k20.png

oct89extrnd - resultado_k40.png

oct89extrnd - resultado_k60.png

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 7: Probabilidad de bloqueo vs. Carga A para la traza `oct89extrnd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Traza Bellcore Octubre 89 Ext. 4 (BCOct89Ext4.TL)

oct89ext4rnd - resultado_k5.png

oct89ext4rnd - resultado_k100.png

(a) $k = 5$ (b) $k = 100$

oct89ext4rnd - resultado_k20.png

oct89ext4rnd - resultado_k40.png

oct89ext4rnd - resultado_k60.png

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 8: Probabilidad de bloqueo vs. Carga A para la traza oct89ext4rnd. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Discusión y Comparación

La Tabla 4 resume las métricas esperadas bajo los dos tipos de tráfico para un mismo escenario (k, a) .

Tabla 4: Comparación de métricas: Erlang B analítico, Poisson y Bellcore.

Métrica	Erlang B	Poisson	Bellcore
$B(k, a)$	B_t	$\approx B_t$	$> B_t$
$\bar{N}$	$a(1 - B)$	$\approx a(1 - B)$	Variable
ρ	$a(1 - B)/k$	$\approx a(1 - B)/k$	Variable
$\mathbb{E}[T_w]$	0	0	0
Ráfagas	Cortas	Cortas	Largas




Figura 9: Comparación de probabilidad de bloqueo: Erlang B analítico vs. simulación con tráfico Poisson y tráfico Bellcore. Se nota, sin carreta, que Bellcore mete más bloqueo por sus ráfagas.

Discusión

Concordancia con el modelo analítico. Bajo tráfico Poisson sintético, los valores de $\hat{B}$ obtenidos por simulación deben converger al valor teórico $B(k, a)$ a medida que aumenta el tiempo de simulación. La concordancia valida tanto la implementación del simulador como las derivaciones matemáticas de la Sección . En buen colombiano: si la simulación cuadra con la teoría, vamos bien.

Efecto de la autosimilaridad. El tráfico Bellcore, al presentar dependencia de largo alcance, genera períodos de alta actividad correlacionada que superan con frecuencia la capacidad del sistema. En consecuencia, la probabilidad de bloqueo observada supera sistemáticamente la predicción de Erlang B, lo que indica que para sistemas reales con tráfico autosimilar es necesario aumentar la capacidad k por encima del valor que dicta la fórmula clásica a fin de garantizar la misma calidad de servicio. Ese exceso es el precio de la ráfaga, y se siente clarito.

Implicación para el diseño. El índice de Hurst H de las trazas Bellcore es aproximadamente $H \approx 0.8$ [7], lo que indica una dependencia de largo alcance significativa. En la práctica, los ingenieros de dimensionamiento deben aplicar modelos de tráfico autosimilar (como el modelo de Pareto compuesto o los procesos brownianos fraccionarios) para obtener estimaciones de bloqueo más conservadoras y realistas.

1. Actividad 6: Caso Real — Plataforma *Tu Boleta* y Rechazos de Compra

1.1. Descripción del escenario

Consideremos la plataforma web colombiana **Tu Boleta**, un servicio de venta de entradas para conciertos, cine, teatro y eventos deportivos —incluyendo partidos de fútbol de equipos como el **Independiente Santa Fe**.

Cuando un hinchas quiere comprar una entrada para un partido, su petición HTTP llega a un balanceador de carga (*Load Balancer*) que la distribuye entre varias instancias del servicio (*back-end*) encargadas de procesar la compra.

En este sistema, cada instancia (servidor) puede atender **exactamente una** petición de compra a la vez. Si un hinchas llega mientras todas las instancias están ocupadas procesando otras compras, el balanceador no lo deja esperar en una cola: le responde de inmediato con un mensaje de error indicando que no hay capacidad disponible (equivalente a un HTTP 503 *Service Unavailable*). Esto modela de forma directa el sistema M/M/k/k.




Figura 10: Arquitectura de la plataforma *Tu Boleta* modelada como sistema M/M/k/k. El Load Balancer distribuye peticiones de compra; las instancias son los k servidores. Cuando todas están ocupadas, la respuesta es un rechazo inmediato (503).

1.2. Correspondencia con el modelo M/M/k/k

La analogía entre la plataforma *Tu Boleta* (vendiendo entradas para Santa Fe) y el modelo M/M/k/k se establece formalmente en la Tabla 5.

Tabla 5: Correspondencia entre *Tu Boleta* (venta de entradas Santa Fe) y el modelo M/M/k/k.

Elemento del modelo M/M/k/k	Elemento en <i>Tu Boleta</i>
Tasa de llegadas λ	Hinchas intentando comprar entrada (req/min)
Tiempo de servicio $\sim \text{Exp}(\mu)$	Tiempo de procesamiento de cada compra
k servidores en paralelo	k instancias del back-end activas
Capacidad = k (sin cola)	Sin fila de espera; rechazo inmediato
Estado n : ocupación del sistema	Instancias atendiendo compras
Bloqueo (prob. $B(k, a)$)	Hinchas que se quedan sin entrada
Carga ofrecida $a = \lambda/\mu$	Intensidad de tráfico en Erlangs

1.3. Escenarios de partido

Se analizan cuatro escenarios representativos del calendario del **Independiente Santa Fe**, ordenados por intensidad de demanda:

1. **Partido de Liga regular:** partido contra rival de media tabla, con afluencia moderada de hinchas.
2. **Clásico vs Millonarios:** el partido más importante del año, con demanda extremadamente alta.
3. **Final de Copa:** partido de eliminación directa, con afluencia masiva de hinchas.
4. **Súper-clásico (Clausura):** definición del torneo contra el máximo rival, con demanda histórica.

Los parámetros de cada escenario se definen como sigue:

Tabla 6: Parámetros de los escenarios de venta de entradas Santa Fe en *Tu Boleta*.

Escenario	k	λ (req/min)	μ (req/min)	a (Erlangs)	$B(k, a)$
Partido de Liga regular	5	20	4.0	5.00	0.2849
Clásico vs Millonarios	10	60	3.0	20.00	0.5380
Final de Copa	15	100	2.0	50.00	0.7080
Súper-clásico (Clausura)	20	150	2.5	60.00	0.6744

1.4. Validación de los supuestos del modelo

Supuesto de llegadas Poisson. En una plataforma web como *Tu Boleta* con miles de hinchas independientes intentando comprar al mismo tiempo, el teorema de super-

posición de Poisson garantiza que la suma de muchos procesos de llegadas de baja intensidad converge a un proceso Poisson. Mientras ningún hincha individual domine el tráfico, el supuesto es razonable y defendible.

Supuesto de tiempos de servicio exponenciales. El tiempo de procesamiento de una compra depende de factores heterogéneos (verificación de pago, consulta a inventario de sillas, envío de correo de confirmación, generación de QR), lo que justifica la aproximación exponencial. Además, la fórmula de Erlang B es *insensible* a la distribución del tiempo de servicio: solo necesita que la media sea $1/\mu$.

1.5. Análisis de las trazas simuladas

Para validar empíricamente el modelo se generaron datos sintéticos siguiendo la misma metodología de las Actividades 4 y 5 del curso: generar interarribos y tiempos de servicio exponenciales, y luego graficar su PDF, CDF y QQ-plot frente a la distribución teórica.




Figura 11: Análisis de distribución (PDF, CDF, QQ-plot) para los escenarios de venta de entradas Santa Fe en *Tu Boleta*. Cada figura compara los datos sintéticos con la distribución exponencial teórica, siguiendo la metodología de las Actividades 4 y 5.

1.6. Simulación y comparación con la teoría

Se ejecutó un simulador de eventos discretos (función `mmkk.m` del curso) para cada escenario, comparando la probabilidad de bloqueo simulada $\hat{B}$ con el valor teórico $B(k, a)$ de Erlang B.

Tabla 7: Resultados de simulación vs teoría para venta de entradas Santa Fe.

Escenario	$B(k, a)$ teórico	$\hat{B}$ simulado	Diferencia	ρ
Partido de Liga regular	0.2849	0.2857	0.0008	0.7151
Clásico vs Millonarios	0.5380	0.5365	0.0015	0.9241
Final de Copa	0.7080	0.7069	0.0011	0.9735
Súper-clásico (Clausura)	0.6744	0.6783	0.0039	0.9767

Observación 1.1. La diferencia entre teoría y simulación es menor al 0.01 en todos los casos, validando tanto la implementación del simulador como la aplicabilidad del modelo M/M/k/k al caso real de una plataforma de venta de entradas para fútbol.




Figura 12: Comparación entre Erlang B analítico y simulación por eventos discretos para los escenarios de venta de entradas Santa Fe en *Tu Boleta*.

1.7. Curvas de sensibilidad y punto de operación

La Figura 13 muestra cómo crece la probabilidad de bloqueo al aumentar la tasa de llegadas λ , manteniendo fijos k y μ en cada escenario. Se destaca el punto de operación actual y la línea de referencia $B_{\text{máx}} = 0.05$.




Figura 13: Curvas de Erlang B para cada escenario de venta de entradas Santa Fe. El punto negro indica la operación actual; la línea punteada roja marca el umbral del 5 %.

1.8. Evolución temporal de la ocupación

La Figura 14 muestra la evolución temporal del número de instancias ocupadas en una ventana de 30 minutos. En los escenarios de alta demanda (Final y Súper-clásico) las instancias permanecen casi permanentemente saturadas.




Figura 14: Evolución temporal de la ocupación de instancias en los primeros 30 minutos de venta para cada escenario. La línea roja punteada indica la capacidad máxima k .

1.9. Dimensionamiento óptimo del servidor

La Tabla 8 presenta el número mínimo de instancias k^* necesarias para cumplir distintos niveles de calidad de servicio, calculado mediante la recursión de Jagerman.

Tabla 8: Dimensionamiento óptimo de instancias para venta de entradas Santa Fe.

Escenario	k^* mínimo para umbral $B_{\text{máx}}$			
	0.001	0.01	0.05	0.10
Partido de Liga regular	14	11	9	8
Clásico vs Millonarios	35	30	26	23
Final de Copa	71	64	56	51
Súper-clásico (Clausura)	83	75	66	60




Figura 15: Dimensionamiento óptimo de instancias por nivel de servicio. El rombo rojo indica la configuración actual de cada escenario.

Observación 1.2. Los resultados muestran que la configuración actual es *insuficiente* para todos los escenarios. Para el Clásico vs Millonarios, que genera una carga de $a = 20$ Erlangs con solo $k = 10$ instancias, el 53.8% de los hinchas que intentan comprar se quedan sin entrada ($B = 0.538$). Para cumplir un nivel de servicio del 95% ($B_{\max} = 0.05$), *Tu Boleta* necesitaría $k^* = 26$ instancias —casi el triple de las actuales. En el Súper-clásico, la situación es aún más crítica: se requieren $k^* = 60$ instancias para el umbral del 10%, frente a las $k = 20$ actuales.

1.10. Distribución estacionaria

La Figura 16 muestra la distribución estacionaria P_n de probabilidades para cada escenario. La barra roja destaca P_k , la probabilidad de que todas las instancias estén ocupadas (bloqueo).




Figura 16: Distribución estacionaria P_n para cada escenario de venta de entradas Santa Fe. La barra roja indica P_k (probabilidad de bloqueo).

1.11. Implementación

La simulación de eventos discretos, incluyendo la generación de datos sintéticos, la comparación entre teoría y simulación, las curvas de sensibilidad y el dimensionamiento óptimo, fue implementada siguiendo la metodología de las Actividades 3, 4 y 5 del curso, adaptada al contexto de la venta de entradas para fútbol a través de una plataforma web.

Plataforma Interactiva de Simulación (Frontend y Backend)

Con el fin de complementar el análisis teórico y la simulación en MATLAB, se construyó una plataforma web interactiva que permite explorar el modelo M/M/k/k en tiempo real. La solución se implementó con una API en **FastAPI** para ejecutar los cálculos y la simulación, y un dashboard en **React** con **Three.js** para visualizar de forma 3D el comportamiento del sistema. La idea es que el usuario pueda ajustar parámetros, ver resultados al vuelo y, de paso, agarrarle el ritmo a la intuición del modelo, bien

bogotano y sin carreta.




Figura 17: Placeholder: Pantallazo del dashboard interactivo 3D.




Figura 18: Placeholder: Resultados estadísticos y diagrama de Markov interactivo.

Conclusiones

El presente trabajo ha desarrollado de manera integral el modelo de colas con pérdida M/M/k/k, desde sus fundamentos matemáticos hasta su aplicación en sistemas de cómputo modernos. Las principales conclusiones son las siguientes:

1. El modelo M/M/k/k admite una solución analítica exacta para la distribución estacionaria, expresada como una distribución de Poisson truncada en k (ecuación (4)). La probabilidad de bloqueo, dada por la fórmula de Erlang B (5), es función únicamente de la carga ofrecida $a = \lambda/\mu$ y del número de servidores k .
2. La ausencia de cola de espera implica que $\mathbb{E}[T_w] = 0$ para las solicitudes aceptadas. Toda la dinámica del sistema se resume en si una solicitud entra o es bloqueada.

3. La simulación de eventos discretos implementada en MATLAB permite validar empíricamente la fórmula de Erlang B bajo tráfico sintético Poisson, y explorar el comportamiento del sistema ante distribuciones de llegada alternativas. Dicho en corto: el simulador hace su tarea, sin misterio.
4. Las trazas Bellcore, caracterizadas por autosimilaridad y dependencia de largo alcance, producen probabilidades de bloqueo significativamente superiores a las predichas por la fórmula clásica para la misma carga media. En entornos de producción es por tanto necesario aplicar modelos más conservadores.
5. El clúster de Kubernetes con k Pods y sin cola interna es una implementación física directa del modelo M/M/k/k. La fórmula de Erlang B, combinada con la recursión de Jagerman, proporciona una herramienta de dimensionamiento precisa y computacionalmente eficiente para determinar el número mínimo de Pods que satisface un nivel de servicio objetivo.
6. La propiedad de insensibilidad de Erlang B respecto a la distribución del tiempo de servicio amplía su aplicabilidad a escenarios reales con tiempos de procesamiento no exponenciales, lo que la convierte en una herramienta de amplio espectro en el diseño de sistemas de comunicaciones y software.

Como trabajo futuro se plantea: (i) extender el análisis al modelo M/M/k/K con cola limitada y comparar las métricas de desempeño; (ii) explorar modelos de tráfico autosimilar (procesos de Pareto compuesto) para el dimensionamiento de clústeres en entornos de microservicios; y (iii) incorporar el efecto del escalado dinámico (*autoscaling*) en el análisis de bloqueo, modelando k como una variable aleatoria dependiente del estado del sistema.

Referencias

- [1] Erlang, A. K. *Solution of Some Problems in the Theory of Probabilities of Significance in Automatic Telephone Exchanges*. Elektroteknikeren, vol. 13, 1917.
- [2] Kleinrock, L. *Queueing Systems, Volume 1: Theory*. John Wiley & Sons, 1975.
- [3] Kleinrock, L. *Queueing Systems, Volume 2: Computer Applications*. John Wiley & Sons, 1976.
- [4] Kendall, D. G. *Stochastic Processes Occurring in the Theory of Queues and Their Analysis by the Method of the Imbedded Markov Chain*. The Annals of Mathematical Statistics, vol. 24, no. 3, pp. 338–354, 1953.

- [5] Jagerman, D.L. *Some Properties of the Erlang Loss Function*. Bell System Technical Journal, vol. 53, no. 3, pp. 525–551, 1974.
- [6] Bonald, T., & Proutière, A. *Insensitive Bandwidth Sharing in Data Networks*. Queueing Systems, vol. 44, no. 1, pp. 69–100, 2003.
- [7] Leland, W.E., Taqqu, M.S., Willinger, W., & Wilson, D.V. *On the Self-Similar Nature of Ethernet Traffic (Extended Version)*. IEEE/ACM Transactions on Networking, vol. 2, no. 1, pp. 1–15, 1994.
- [8] Greenberg, A., Hamilton, J., Maltz, D.A., & Patel, P. *The Cost of a Cloud: Research Problems in Data Center Networks*. ACM SIGCOMM Computer Communication Review, vol. 39, no. 1, pp. 68–73, 2008.
- [9] Burns, B., Grant, B., Oppenheimer, D., Brewer, E., & Wilkes, J. *Borg, Omega, and Kubernetes*. Communications of the ACM, vol. 59, no. 5, pp. 50–57, 2016.
- [10] Gross, D., Shortle, J.F., Thompson, J.M., & Harris, C.M. *Fundamentals of Queueing Theory* (4th ed.). John Wiley & Sons, 2008.
- [11] Ross, S.M. *Introduction to Probability Models* (10th ed.). Academic Press, 2007.