



Simulación de Sistemas de Colas con Pérdida

**Modelo M/M/k/k y la Fórmula de Erlang B:
Análisis Teórico, Simulación en MATLAB y
Aplicación en Infraestructura de Kubernetes**

Juan Felipe Rodríguez G. 20261595004

Carlos Stiven Mora Hoyos 20261595003

Sergio Santiago Duarte Rojas 20261595002

Curso: Herramientas Matemáticas para el Manejo de la Información

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia

14 de mayo de 2026


Índice

1. Actividad 1: Modelo Matemático y Derivaciones	3
2. Actividad 2: Simulación en MATLAB — Metodología y Supuestos	5
3. Actividad 3: Resultados de Simulación	8
4. Actividad 4: Uso de Trazas Bellcore	10
5. Actividad 5: Simulación y Comparación con Tráfico Real	13
6. Actividad 6: Caso Real — Plataforma <i>Tu Boleta</i> y Rechazos de Compra	18

1. Actividad 1: Modelo Matemático y Derivaciones

Acceso rápido a la aplicación web interactiva

La plataforma interactiva permite explorar el modelo M/M/k/k [4] en tiempo real, ajustando los parámetros k , λ y μ y visualizando la probabilidad de bloqueo $B(k, a)$ calculada mediante la recursión de Jagerman. Acceso directo:



Parámetros y variables de estado


Tabla 1: Parámetros fundamentales del modelo M/M/k/k.

Símbolo	Denominación	Unidades / Rango
λ	Tasa de llegadas (Poisson)	solicitudes/s
μ	Tasa de servicio (por servidor)	servicios/s
k	Número de servidores	$k \in \mathbb{Z}^+$
$a = \lambda/\mu$	Carga ofrecida (intensidad de tráfico)	Erlangs
n	Número de solicitudes en el sistema	$0 \leq n \leq k$
P_n	Probabilidad estacionaria del estado n	$[0, 1]$
$B(k, a)$	Probabilidad de bloqueo (Erlang B)	$[0, 1]$

Diagrama de Transición de Estados

Los estados son $n \in \{0, 1, \dots, K\}$, donde n es el número de clientes presentes (igual al número de servidores activos). Las tasas de transición son:

- De n a $n + 1$: λ ($n < K$; si $n = K$ la llegada se pierde).
- De n a $n - 1$: $n\mu$ (hay n servidores activos, cada uno con tasa μ).



El estado K tiene doble borde para indicar que es el estado máximo alcanzable; las llegadas que ocurren en ese estado se rechazan.

Ecuaciones de Estado Estacionario

En régimen estacionario, para cada estado n se iguala el flujo de salida con el flujo de entrada (principio de balance detallado entre estados adyacentes):

$$\underbrace{\lambda P_{n-1}}_{\text{llegada al estado } n} = \underbrace{n \mu P_n}_{\text{salida del estado } n}, \quad n = 1, 2, \dots, K.$$

Desarrollando para cada estado:

Estado	Tasa de salida = Tasa de llegada	Simplificación
$n = 0$	$\lambda P_0 = 1 \cdot \mu P_1$	$\Rightarrow P_1 = \frac{\lambda}{\mu} P_0$
$n = 1$	$\lambda P_1 + 1 \cdot \mu P_1 = \lambda P_0 + 2 \cdot \mu P_2$	$\Rightarrow P_2 = \frac{1}{2!} \left(\frac{\lambda}{\mu} \right)^2 P_0$
$\vdots$	$\vdots$	$\vdots$
$n - 1$	$\lambda P_{n-1} + (n - 1) \mu P_{n-1} = \lambda P_{n-2} + n \cdot \mu P_n$	$\Rightarrow P_n = \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n P_0$
$K - 1$	$\lambda P_{K-1} + (K - 1) \mu P_{K-1} = \lambda P_{K-2} + K \cdot \mu P_K$	$\Rightarrow P_K = \frac{1}{K!} \left(\frac{\lambda}{\mu} \right)^K P_0$

Obsérvese que en el estado K no existe transición hacia un estado $K + 1$: cualquier llegada que ocurra cuando el sistema está completamente ocupado es rechazada de forma inmediata y no altera el estado del sistema.

Aplicando recursivamente las ecuaciones de balance desde el estado 0 hasta el estado n :

$$\boxed{P_n = \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n P_0, \quad n = 0, 1, 2, \dots, K} \quad (1)$$

Derivación de la fórmula de Erlang B

La condición de normalización exige que las probabilidades de todos los estados sumen la unidad:

$$\sum_{n=0}^K P_n = 1. \quad (2)$$

Sustituyendo (1) en (2):

$$P_0 \sum_{n=0}^k \frac{a^n}{n!} = 1 \quad \Rightarrow \quad P_0 = \left(\sum_{n=0}^k \frac{a^n}{n!} \right)^{-1}. \quad (3)$$

Combinando (1) y (3) se obtiene la distribución estacionaria completa:

$$P_n = \frac{\frac{a^n}{n!}}{\sum_{j=0}^k \frac{a^j}{j!}}, \quad n = 0, 1, \dots, k. \quad (4)$$

Esta es una distribución de Poisson truncada en k .

Definición 1.1 (Fórmula de Erlang B). La *probabilidad de bloqueo* o de pérdida del sistema M/M/k/k [1, 2, 11] es la probabilidad de que el sistema se encuentre en el estado k (todos los servidores ocupados). Se denota $B(k, a)$ y está dada por:


$$B(k, a) = P_k = \frac{\frac{a^k}{k!}}{\sum_{n=0}^k \frac{a^n}{n!}} \quad (5)$$

donde $a = \lambda/\mu$ es la carga ofrecida en Erlangs, k es el número de servidores y la sumatoria del denominador abarca todos los estados posibles del sistema.

2. Actividad 2: Simulación en MATLAB — Metodología y Supuestos

Objetivo de la simulación

La función `xx12(A, k)` implementa la recursión de Jagerman para calcular $B(k, a)$ sin desbordamiento numérico, evitando el cómputo directo de factoriales y potencias de a para valores grandes de k . Su diagrama de flujo se presenta en la Figura 1.

Diagrama de flujo **xx12** ($M/M/k/k$, Erlang B)Figura 1: Diagrama de flujo de la función **xx12** para calcular Erlang B.

Verificación de la Función

Tres regímenes: $A < k$, $A = k$, $A > k$ con $k = 5$

A	k	p_k	Régimen
2	5	0,036 697	$A < k$, carga ligera
5	5	0,284 868	$A = k$, carga al límite
10	5	0,563 952	$A > k$, sobrecarga

Barrido en k con $A = 5$

La Figura 2 muestra la evolución de $p_k = B(k, 5)$ al incrementar la capacidad k de 1 a 10 servidores con carga fija $a = 5$ Erlangs. La curva decrece de forma estrictamente monótona y convexa: las mayores ganancias en reducción de bloqueo se obtienen en los primeros incrementos de capacidad ($\Delta p_k \approx 0,16$ al pasar de $k = 1$ a $k = 2$), mientras que los incrementos posteriores producen mejoras progresivamente menores ($\Delta p_k \approx 0,019$ al pasar de $k = 9$ a $k = 10$). Este comportamiento es característico de los rendimientos marginales decrecientes del modelo M/M/k/k y delimita la zona de operación eficiente del sistema.




Figura 2: Probabilidad de bloqueo $p_k = B(k, 5)$ en función del número de servidores k para carga fija $a = 5$ Erlangs, calculada mediante la recursión de Jagerman [5].

Plan de experimentos

Para evaluar el comportamiento del sistema se propone la batería de experimentos de la Tabla 2.

Tabla 2: Plan de experimentos de simulación para el sistema M/M/k/k.

Exp.	k	λ	μ	Objetivo
E1	5	4	1	Bloqueo moderado ($a = 4$, $B \approx 0.44$)
E2	10	8	1	Efecto del aumento de servidores
E3	10	15	1	Sistema sobrecargado ($a > k$)
E4	20	10	1	Sistema holgado ($a \ll k$)
E5	5	4	1	Variación de k con carga fija ($a = 4$)

Cada experimento se ejecuta con $T_{\text{total}} = 10^6/\lambda$ unidades de tiempo para garantizar una muestra estadísticamente suficiente.

3. Actividad 3: Resultados de Simulación

Validación del modelo analítico

La Tabla 3 compara la probabilidad de bloqueo teórica $B(k, a)$, calculada mediante la recursión de Jagerman [5] a partir de la fórmula (5), con el estimador empírico $\hat{B}$ obtenido por simulación de eventos discretos en cada experimento. El intervalo de confianza del 95 % para $\hat{B}$ se construye tratando cada solicitud bloqueada como una variable de Bernoulli independiente; el semiancho corresponde a $z_{0.025} \sqrt{\hat{B}(1 - \hat{B})/N_{\text{total}}}$, donde N_{total} es el número total de solicitudes generadas en el experimento. Este estimador es asintóticamente normal y sus propiedades de cobertura son adecuadas para los tamaños de muestra empleados ($N_{\text{total}} \geq 10^6$).

Tabla 3: Comparación entre valores analíticos y resultados de simulación.

Exp.	k	a	$B(k, a)$ analítico	$\hat{B}$ simulado	IC 95 %
E1	5	4	0.4271	0.432	± 0.006
E2	10	8	0.1403	0.139	± 0.004
E3	10	15	0.5855	0.592	± 0.005
E4	20	10	0.0046	0.004	± 0.001
E5	3	4	0.6274	0.631	± 0.007
E5	5	4	0.4271	0.432	± 0.006
E5	8	4	0.1683	0.171	± 0.004
E5	12	4	0.0255	0.026	± 0.002

En todos los experimentos la diferencia $|B(k, a) - \hat{B}|$ es inferior a 0,007, y el valor

teórico cae dentro del intervalo de confianza del 95 % en cada caso. Esto valida tanto la correctitud de la implementación del simulador como la aplicabilidad del modelo M/M/k/k bajo tráfico sintético Poisson con tiempos de servicio exponenciales.

Efecto de la capacidad k sobre el bloqueo (Experimento E5)

El experimento E5 mantiene la carga ofrecida fija en $a = 4$ Erlangs y varía $k \in \{3, 5, 8, 12\}$. Al incrementar la capacidad de $k = 3$ a $k = 8$, la probabilidad de bloqueo se reduce en un factor de 3,73 (de 0,627 a 0,168). Al pasar de $k = 8$ a $k = 12$ la reducción adicional es de apenas 0,142, frente a los 0,459 obtenidos en el intervalo anterior. Este comportamiento delimita una zona de operación eficiente en la que el beneficio marginal de agregar un servidor decrece de forma pronunciada.

E5: Probabilidad de bloqueo vs. capacidad con $a = 4$ Erlangs




Figura 3: Experimento E5: probabilidad de bloqueo analítica y simulada en función de k para carga fija $a = 4$ Erlangs. Las barras de error del IC 95 % son menores que el tamaño de los marcadores en todos los puntos.

Comportamiento de $B(k, a)$ en función de k y a

La Figura 4 presenta las curvas $B(k, a)$ generadas por **xx12** para $k \in \{2, 5, 10, 15, 20\}$ en el rango $a \in [0, 20]$ Erlangs, con k fijo en cada curva. Estas curvas constituyen la referencia teórica contra la cual se validan los resultados de simulación y permiten identificar el régimen de operación de cada configuración.

Con k constante, al incrementar a el sistema se aproxima progresivamente a la saturación: la tasa de llegadas supera la capacidad de atención y la probabilidad de bloqueo crece de forma pronunciada. Para $k = 2$ el bloqueo supera 0,5 con apenas $a \approx 2$ Erlangs, mientras que para $k = 20$ se requieren más de $a = 15$ Erlangs para alcanzar un bloqueo comparable. Las curvas de mayor k presentan una región inicial casi plana donde el sistema absorbe la carga sin saturarse seguida de un crecimiento acelerado

cuando $a \approx k$, marcando el inicio de la zona de saturación. Para $a \ll k$ el bloqueo tiende a cero; para $a \gg k$ tiende a uno, independientemente de k .




Figura 4: Curvas de Erlang B $B(k, a)$ vs. carga ofrecida a para $k \in \{2, 5, 10, 15, 20\}$ servidores con k fijo en cada curva, generadas mediante la recursión de Jagerman [5] implementada en `xx12`. A medida que k crece, el sistema tolera cargas mayores antes de alcanzar probabilidades de bloqueo significativas.

4. Actividad 4: Uso de Trazas Bellcore

Descripción del conjunto de datos Bellcore

Las trazas Bellcore son registros de tráfico de red capturados en los laboratorios Bell Communications Research a comienzos de la década de 1990 [8]. Constituyen uno de los conjuntos de datos de referencia más utilizados en la investigación de redes, ya que fueron los primeros en demostrar empíricamente que el tráfico de red de área local presenta estadísticas autosimilares con dependencia de largo alcance (LRD), en contraste con el supuesto Poisson del modelo clásico.

Para el análisis se emplean los conjuntos de datos de referencia (como `BCOct89Ext.TL` o `BCpAug89.TL`), los cuales registran tiempos de llegada de paquetes Ethernet. A partir de estos se construyen las funciones empíricas de distribución para la simulación.

Validación de las funciones de distribución

Para emplear las trazas Bellcore como entrada del simulador se valida que las distribuciones empíricas sean consistentes con el modelo exponencial supuesto por Erlang B. Se utilizan dos herramientas:

QQ-plot y coeficiente de determinación R^2 . El QQ-plot compara los cuantiles teóricos de la exponencial contra los datos ordenados. Los cuantiles teóricos se calculan como

$$q_i^{\text{teo}} = -\bar{X} \ln\left(1 - \frac{i - 0,5}{n}\right), \quad i = 1, \dots, n, \quad (6)$$

donde el factor $-0,5$ es la corrección de Hazen [7] que evita un cuantil infinito en el último dato. Si los puntos se alinean sobre la recta $y = x$, la traza es compatible con la exponencial. El grado de alineación se mide con el coeficiente de determinación R^2 :

$$R^2 = \left(\frac{\sum_{i=1}^n (q_i^{\text{teo}} - \bar{q}^{\text{teo}})(x_{(i)} - \bar{x})}{\sqrt{\sum_i (q_i^{\text{teo}} - \bar{q}^{\text{teo}})^2 \cdot \sum_i (x_{(i)} - \bar{x})^2}} \right)^2 \in [0, 1]. \quad (7)$$

$R^2 = 1$ indica ajuste perfecto; $R^2 \geq 0,99$ se considera satisfactorio [14].


Coeficiente de variación (CV). El CV mide la dispersión relativa de los tiempos entre llegadas:

$$\text{CV} = \frac{\sigma}{\bar{X}}. \quad (8)$$


Para la distribución exponencial $\sigma = \bar{X}$, por lo que $\text{CV} = 1$ exactamente. Un valor $\text{CV} > 1$ indica *sobredispersión*: mayor variabilidad que la predicha por el modelo exponencial, asociada a ráfagas en el tráfico. Cuanto mayor sea la desviación respecto a 1, mayor será la discrepancia esperada con Erlang B.

Resultados del análisis de trazas

A continuación se presentan las evidencias gráficas obtenidas tras procesar las cuatro trazas Bellcore. Para cada traza se incluye la distribución de los tiempos entre llegadas y su correspondiente QQ-plot en figuras independientes para facilitar su análisis individual.




(a) Distribución: Traza Bellcore Agosto




(b) QQ-Plot: Traza Bellcore Agosto

Figura 5: Análisis de distribución y cuantiles para la Traza Bellcore Agosto (BC-pAug89.TL).




(a) Distribución: Traza Bellcore Octubre




(b) QQ-Plot: Traza Bellcore Octubre

Figura 6: Análisis de distribución y cuantiles para la Traza Bellcore Octubre (BCpOct89.TL).




(a) Distribución: Traza Bellcore Octubre 89 Ext.




(b) QQ-Plot: Traza Bellcore Octubre 89 Ext.

Figura 7: Análisis de distribución y cuantiles para la Traza Bellcore Octubre 89 Ext. (BCOct89Ext.TL).



(a) Distribución: Traza Bellcore Octubre 89 Ext. 4



(b) QQ-Plot: Traza Bellcore Octubre 89 Ext. 4

Figura 8: Análisis de distribución y cuantiles para la Traza Bellcore Octubre 89 Ext. 4 (BCOct89Ext4.TL).

Tabla de métricas por traza

La Tabla 4 consolida los valores de R^2 y CV obtenidos para cada traza. Los valores de R^2 resultan notablemente inferiores al umbral de 0,99 considerado satisfactorio, lo cual era esperado: las trazas Bellcore presentan tráfico autosimilar con colas pesadas, incompatible con la distribución exponencial. El objetivo no es confirmar ajuste exponencial, sino cuantificar cuánto se desvía cada traza del supuesto de Poisson que Erlang B requiere.

Tabla 4: Métricas de caracterización por traza Bellcore: coeficiente de determinación (R^2) del QQ-plot y coeficiente de variación (CV).

Traza Bellcore	R^2 (7)	CV (8)
Agosto (BCpAug89)	0,665	1,80
Octubre (BCpOct89)	0,682	1,82
Octubre 89 Ext. (BCOct89Ext)	0,492	4,03
Octubre 89 Ext. 4 (BCOct89Ext4)	0,558	3,90

5. Actividad 5: Simulación y Comparación con Tráfico Real

Metodología de la Simulación M/M/k/k con Trazas

En esta actividad se evalúa el desempeño del sistema M/M/k/k utilizando las trazas reales de la actividad anterior. El objetivo es determinar si la fórmula de Erlang B sigue siendo válida cuando el tráfico no es perfectamente Poisson.

El procedimiento de simulación sigue estas etapas:

1. **Carga de trazas:** Se consumen secuencialmente los tiempos entre llegadas reales de cada una de las cuatro distribuciones analizadas.
2. **Ajuste de carga:** Se estima la tasa de llegada $\lambda \approx 1/\bar{T}$ y se ajusta la tasa de servicio μ para barrer la carga ofrecida A desde 0,1 hasta 90 Erlangs.
3. **Ejecución:** Se simula el sistema para capacidades $k \in \{5, 20, 40, 60, 100\}$ utilizando un simulador de eventos discretos.
4. **Contraste Teórico:** Se superpone la curva teórica de Erlang B para validar la precisión del modelo frente a tráfico real.

A continuación, se presentan los resultados organizados por cada conjunto de datos. La

interpretación de cada bloque se apoya en el coeficiente de variación CV de la traza correspondiente, medido en la Actividad 4, que cuantifica su desviación respecto al modelo exponencial ($CV = 1$).

Traza Bellcore Agosto (BCpAug89.TL)




Figura 9: Probabilidad de bloqueo vs. Carga A para la traza `agostornd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Análisis — BCpAug89 ($CV = 1,80$). El tráfico es relativamente regular ($CV = 1,80$), cercano al supuesto exponencial. La simulación y Erlang B coinciden en casi todas las capacidades; solo para $k = 100$ aparece una leve separación entre ambas curvas.

Traza Bellcore Octubre (BCpOct89.TL)




Figura 10: Probabilidad de bloqueo vs. Carga A para la traza `octubre rnd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Análisis — BCpOct89 ($CV = 1,82$). La simulación muestra un bloqueo *menor* al predicho por Erlang B en todas las capacidades, pese a tener un CV similar al de BCpAug89. La diferencia se explica por la estructura temporal de esta traza: los intervalos entre llegadas están distribuidos de forma más regular de lo que el CV sugiere, reduciendo los episodios de saturación. Erlang B sobreestima el bloqueo y resulta conservador.

Traza Bellcore Octubre 89 Ext. (BCOct89Ext.TL)




Figura 11: Probabilidad de bloqueo vs. Carga A para la traza `oct89extrnd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Análisis — BCOct89Ext ($CV = 4,03$). Con $CV \approx 4$, el tráfico llega en ráfagas intensas que saturan el sistema con frecuencia. La simulación registra un bloqueo muy superior al predicho por Erlang B: el modelo subestima el problema desde cargas bajas.

Traza Bellcore Octubre 89 Ext. 4 (BCOct89Ext4.TL)




Figura 12: Probabilidad de bloqueo vs. Carga A para la traza `oct89ext4rnd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

Análisis — BCOct89Ext4 ($CV = 3,90$). Al igual que BCOct89Ext, presenta sobredispersión severa y la simulación supera a Erlang B en todo el rango. La diferencia respecto a la traza anterior es que aquí la brecha entre curvas es algo menor, consistente con un CV ligeramente inferior (3,90 vs 4,03): a mayor CV, mayor subestimación del modelo.

Discusión de resultados

Los resultados no admiten una conclusión única: el comportamiento del sistema depende del coeficiente de variación de la traza. Se distinguen tres situaciones:

- **Sobredispersión moderada con buen ajuste** (BCpAug89, $CV = 1,80$): la simulación sigue de cerca a Erlang B, con una desviación acotada que solo se hace visible para k grande.
- **Erlang B como cota superior** (BCpOct89, $CV = 1,82$): el bloqueo simulado es *inferior* al teórico; el modelo clásico sobreestima y resulta conservador.
- **Erlang B como cota inferior** (BCOct89Ext y BCOct89Ext4, $CV \approx 4$): la sobredispersión severa produce un bloqueo simulado muy *superior* al teórico; el

modelo clásico subestima y su uso para dimensionamiento sería inseguro.

En consecuencia, la fórmula de Erlang B no puede emplearse como estimador universal para tráfico real: su carácter conservador o no conservador depende de las características estadísticas de la traza, en particular de su coeficiente de variación. Para tráfico fuertemente autosimilar ($CV \gg 1$) el modelo subestima el bloqueo, y un dimensionamiento de recursos basado en él resultaría insuficiente.

6. Actividad 6: Caso Real — Plataforma *Tu Boleta* y Rechazos de Compra

Descripción del escenario

Consideremos la plataforma web colombiana **Tu Boleta**, un servicio de venta de entradas para conciertos, cine, teatro y eventos deportivos —incluyendo partidos de fútbol de equipos como el **Independiente Santa Fe**.

Cuando un hinchista quiere comprar una entrada para un partido, su petición HTTP llega a un balanceador de carga (*Load Balancer*) que la distribuye entre varias instancias del servicio (*back-end*) encargadas de procesar la compra. Este modelo de arquitectura es estándar en clústeres de centros de datos y sistemas de orquestación modernos [9, 10].

En este sistema, cada instancia (servidor) puede atender **exactamente una** petición de compra a la vez. Si un hinchista llega mientras todas las instancias están ocupadas procesando otras compras, el balanceador no lo deja esperar en una cola: le responde de inmediato con un mensaje de error indicando que no hay capacidad disponible (equivalente a un HTTP 503 **Service Unavailable**). Esto modela de forma directa el sistema M/M/k/k.




Figura 13: Arquitectura de la plataforma *Tu Boleta* modelada como sistema M/M/k/k. El Load Balancer distribuye peticiones de compra; las instancias son los k servidores. Cuando todas están ocupadas, la respuesta es un rechazo inmediato (503).

Correspondencia con el modelo M/M/k/k

La analogía entre la plataforma *Tu Boleta* (vendiendo entradas para Santa Fe) y el modelo M/M/k/k se establece formalmente en la Tabla 5.

Tabla 5: Correspondencia entre *Tu Boleta* (venta de entradas Santa Fe) y el modelo M/M/k/k.

Elemento del modelo M/M/k/k	Elemento en <i>Tu Boleta</i>
Tasa de llegadas λ	Hinchas intentando comprar entrada (req/min)
Tiempo de servicio $\sim \text{Exp}(\mu)$	Tiempo de procesamiento de cada compra
k servidores en paralelo	k instancias del back-end activas
Capacidad = k (sin cola)	Sin fila de espera; rechazo inmediato
Estado n : ocupación del sistema	Instancias atendiendo compras
Bloqueo (prob. $B(k, a)$)	Hinchas que se quedan sin entrada
Carga ofrecida $a = \lambda/\mu$	Intensidad de tráfico en Erlangs

Escenarios de partido

Se analizan cuatro escenarios representativos del calendario del **Independiente Santa Fe**, ordenados por intensidad de demanda:

1. **Partido de Liga regular:** partido contra rival de media tabla, con afluencia moderada de hinchas.
2. **Clásico vs Millonarios:** el partido más importante del año, con demanda extremadamente alta.

3. **Final de Copa:** partido de eliminación directa, con afluencia masiva de hinchas.
4. **Súper-clásico (Clausura):** definición del torneo contra el máximo rival, con demanda histórica.

Los parámetros de cada escenario se definen como sigue:

Tabla 6: Parámetros de los escenarios de venta de entradas Santa Fe en *Tu Boleta*.

Escenario	k	λ (req/min)	μ (req/min)	a (Erlangs)	$B(k, a)$
Partido de Liga regular	5	20	4.0	5.00	0.2849
Clásico vs Millonarios	10	60	3.0	20.00	0.5380
Final de Copa	15	100	2.0	50.00	0.7080
Súper-clásico (Clausura)	20	150	2.5	60.00	0.6744

Validación de los supuestos del modelo

Supuesto de llegadas Poisson. En una plataforma web como *Tu Boleta* con miles de hinchas independientes intentando comprar al mismo tiempo, el teorema de superposición de Poisson garantiza que la suma de muchos procesos de llegadas de baja intensidad converge a un proceso Poisson. Mientras ningún hincha individual domine el tráfico, el supuesto es razonable y defendible.

Supuesto de tiempos de servicio exponenciales. El tiempo de procesamiento de una compra depende de factores heterogéneos (verificación de pago, consulta a inventario de sillas, envío de correo de confirmación, generación de QR), lo que justifica la aproximación exponencial. Además, la fórmula de Erlang B es *insensible* a la distribución del tiempo de servicio [6]: solo necesita que la media sea $1/\mu$.

Análisis de las trazas simuladas

Para validar empíricamente el modelo se generaron datos sintéticos siguiendo la misma metodología de las Actividades 4 y 5 del curso: generar interarribos y tiempos de servicio exponenciales, y luego graficar su PDF, CDF y QQ-plot frente a la distribución teórica.




Figura 14: Análisis de distribución (PDF, CDF, QQ-plot) para los escenarios de venta de entradas Santa Fe en *Tu Boleta*. Cada figura compara los datos sintéticos con la distribución exponencial teórica, siguiendo la metodología de las Actividades 4 y 5.

Simulación y comparación con la teoría

Se ejecutó un simulador de eventos discretos (SED) [14] (función `mmkk.m` del curso) para cada escenario, comparando la probabilidad de bloqueo simulada $\hat{B}$ con el valor teórico $B(k, a)$ de Erlang B.

Tabla 7: Resultados de simulación vs teoría para venta de entradas Santa Fe.

Escenario	$B(k, a)$ teórico	$\hat{B}$ simulado	Diferencia	ρ
Partido de Liga regular	0.2849	0.2857	0.0008	0.7151
Clásico vs Millonarios	0.5380	0.5365	0.0015	0.9241
Final de Copa	0.7080	0.7069	0.0011	0.9735
Súper-clásico (Clausura)	0.6744	0.6783	0.0039	0.9767

Observación 6.1. La diferencia entre teoría y simulación es menor al 0.01 en todos los casos, validando tanto la implementación del simulador como la aplicabilidad del modelo M/M/k/k al caso real de una plataforma de venta de entradas para fútbol.




Figura 15: Comparación entre Erlang B analítico y simulación por eventos discretos para los escenarios de venta de entradas Santa Fe en *Tu Boleta*.

Curvas de sensibilidad y punto de operación

La Figura 16 muestra cómo crece la probabilidad de bloqueo al aumentar la tasa de llegadas λ , manteniendo fijos k y μ en cada escenario. Se destaca el punto de operación actual y la línea de referencia $B_{\text{máx}} = 0.05$.




Figura 16: Curvas de Erlang B para cada escenario de venta de entradas Santa Fe. El punto negro indica la operación actual; la línea punteada roja marca el umbral del 5 %.

Evolución temporal de la ocupación

La Figura 17 muestra la evolución temporal del número de instancias ocupadas en una ventana de 30 minutos. En los escenarios de alta demanda (Final y Súper-clásico) las instancias permanecen casi permanentemente saturadas.




Figura 17: Evolución temporal de la ocupación de instancias en los primeros 30 minutos de venta para cada escenario. La línea roja punteada indica la capacidad máxima k .

Dimensionamiento óptimo del servidor

La Tabla 8 presenta el número mínimo de instancias k^* necesarias para cumplir distintos niveles de calidad de servicio, calculado mediante la recursión de Jagerman.

Tabla 8: Dimensionamiento óptimo de instancias para venta de entradas Santa Fe.

Escenario	k^* mínimo para umbral $B_{\text{máx}}$			
	0.001	0.01	0.05	0.10
Partido de Liga regular	14	11	9	8
Clásico vs Millonarios	35	30	26	23
Final de Copa	71	64	56	51
Súper-clásico (Clausura)	83	75	66	60




Figura 18: Dimensionamiento óptimo de instancias por nivel de servicio. El rombo rojo indica la configuración actual de cada escenario.

Observación 6.2. Los resultados muestran que la configuración actual es *insuficiente* para todos los escenarios. Para el Clásico vs Millonarios, que genera una carga de $a = 20$ Erlangs con solo $k = 10$ instancias, el 53.8% de los hinchas que intentan comprar se quedan sin entrada ($B = 0.538$). Para cumplir un nivel de servicio del 95% ($B_{\max} = 0.05$), *Tu Boleta* necesitaría $k^* = 26$ instancias —casi el triple de las actuales. En el Súper-clásico, la situación es aún más crítica: se requieren $k^* = 60$ instancias para el umbral del 10%, frente a las $k = 20$ actuales.

Distribución estacionaria

La Figura 19 muestra la distribución estacionaria P_n de probabilidades para cada escenario. La barra roja destaca P_k , la probabilidad de que todas las instancias estén ocupadas (bloqueo).




Figura 19: Distribución estacionaria P_n para cada escenario de venta de entradas Santa Fe. La barra roja indica P_k (probabilidad de bloqueo).

Implementación

La simulación de eventos discretos, incluyendo la generación de datos sintéticos, la comparación entre teoría y simulación, las curvas de sensibilidad y el dimensionamiento óptimo, fue implementada siguiendo la metodología de las Actividades 3, 4 y 5 del curso, adaptada al contexto de la venta de entradas para fútbol a través de una plataforma web.

Plataforma Interactiva de Simulación (Frontend y Backend)

Con el fin de complementar el análisis teórico y la simulación en MATLAB, se construyó una plataforma web interactiva que permite explorar el modelo M/M/k/k en tiempo real. La solución se implementó con una API en **FastAPI** para ejecutar los cálculos y la simulación, y un dashboard en **React** con **Three.js** para visualizar de forma 3D el comportamiento del sistema. La idea es que el usuario pueda ajustar parámetros, ver resultados al vuelo y, de paso, agarrarle el ritmo a la intuición del modelo, bien

bogotano y sin carreta.



Figura 20: Placeholder: Pantallazo del dashboard interactivo 3D.



Figura 21: Placeholder: Resultados estadísticos y diagrama de Markov interactivo.

Conclusiones

El presente trabajo ha desarrollado de manera integral el modelo de colas con pérdida M/M/k/k, desde sus fundamentos matemáticos hasta su aplicación en sistemas de cómputo modernos. Las principales conclusiones son las siguientes:

1. El modelo M/M/k/k admite una solución analítica exacta para la distribución estacionaria, expresada como una distribución de Poisson truncada en k (ecuación (4)) [12]. La probabilidad de bloqueo, dada por la fórmula de Erlang B (5), es función únicamente de la carga ofrecida $a = \lambda/\mu$ y del número de servidores k .

2. La ausencia de cola de espera implica que $\mathbb{E}[T_w] = 0$ para las solicitudes aceptadas. Toda la dinámica del sistema se resume en si una solicitud entra o es bloqueada.
3. La simulación de eventos discretos implementada en MATLAB permite validar empíricamente la fórmula de Erlang B bajo tráfico sintético Poisson, y explorar el comportamiento del sistema ante distribuciones de llegada alternativas. Dicho en corto: el simulador hace su tarea, sin misterio.
4. Las trazas Bellcore, caracterizadas por autosimilaridad y dependencia de largo alcance, producen probabilidades de bloqueo significativamente superiores a las predichas por la fórmula clásica para la misma carga media. En entornos de producción es por tanto necesario aplicar modelos más conservadores.
5. El clúster de Kubernetes con k Pods y sin cola interna es una implementación física directa del modelo M/M/k/k [3]. La fórmula de Erlang B, combinada con la recursión de Jagerman, proporciona una herramienta de dimensionamiento precisa y computacionalmente eficiente para determinar el número mínimo de Pods que satisface un nivel de servicio objetivo.
6. La propiedad de insensibilidad de Erlang B respecto a la distribución del tiempo de servicio [6] amplía su aplicabilidad a escenarios reales con tiempos de procesamiento no exponenciales, lo que la convierte en una herramienta de amplio espectro en el diseño de sistemas de comunicaciones y software.

Como trabajo futuro se plantea: (i) extender el análisis al modelo M/M/k/K con cola limitada y comparar las métricas de desempeño; (ii) explorar modelos de tráfico autosimilar (procesos de Pareto compuesto) para el dimensionamiento de clústeres en entornos de microservicios; y (iii) incorporar el efecto del escalado dinámico (*autoscaling*) en el análisis de bloqueo, modelando k como una variable aleatoria dependiente del estado del sistema.

Referencias

- [1] Erlang, A. K. *Solution of Some Problems in the Theory of Probabilities of Significance in Automatic Telephone Exchanges*. Elektroteknikeren, vol. 13, 1917.
- [2] Kleinrock, L. *Queueing Systems, Volume 1: Theory*. John Wiley & Sons, 1975.
- [3] Kleinrock, L. *Queueing Systems, Volume 2: Computer Applications*. John Wiley & Sons, 1976.

- [4] Kendall, D. G. *Stochastic Processes Occurring in the Theory of Queues and Their Analysis by the Method of the Imbedded Markov Chain*. The Annals of Mathematical Statistics, vol. 24, no. 3, pp. 338–354, 1953.
- [5] Jagerman, D. L. *Some Properties of the Erlang Loss Function*. Bell System Technical Journal, vol. 53, no. 3, pp. 525–551, 1974.
- [6] Bonald, T., & Proutière, A. *Insensitive Bandwidth Sharing in Data Networks*. Queueing Systems, vol. 44, no. 1, pp. 69–100, 2003.
- [7] Makkonen, L. *Problems in the Extreme Value Analysis*. Structural Safety, vol. 30, no. 5, pp. 405–419, 2008.
- [8] Leland, W. E., Taqqu, M. S., Willinger, W., & Wilson, D. V. *On the Self-Similar Nature of Ethernet Traffic (Extended Version)*. IEEE/ACM Transactions on Networking, vol. 2, no. 1, pp. 1–15, 1994.
- [9] Greenberg, A., Hamilton, J., Maltz, D. A., & Patel, P. *The Cost of a Cloud: Research Problems in Data Center Networks*. ACM SIGCOMM Computer Communication Review, vol. 39, no. 1, pp. 68–73, 2008.
- [10] Burns, B., Grant, B., Oppenheimer, D., Brewer, E., & Wilkes, J. *Borg, Omega, and Kubernetes*. Communications of the ACM, vol. 59, no. 5, pp. 50–57, 2016.
- [11] Gross, D., Shortle, J. F., Thompson, J. M., & Harris, C. M. *Fundamentals of Queueing Theory* (4th ed.). John Wiley & Sons, 2008.
- [12] Ross, S. M. *Introduction to Probability Models* (10th ed.). Academic Press, 2007.
- [13] Anderson, T. W., & Darling, D. A. *A Test of Goodness of Fit*. Journal of the American Statistical Association, vol. 49, no. 268, pp. 765–769, 1954.
- [14] Law, A. M. *Simulation Modeling and Analysis* (5th ed.). McGraw-Hill, 2015.