


# Simulación de Sistemas de Colas con Pérdida

## Modelo M/M/k/k y la Fórmula de Erlang B: Análisis Teórico, Simulación en MATLAB y Aplicación en Infraestructura de Kubernetes

*Juan Felipe Rodríguez G.* 20261595004
*Carlos Stiven Mora Hoyos* 20261595003
*Sergio Santiago Duarte Rojas* 20261595002

Curso: Herramientas Matemáticas para el Manejo de la Información

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia
14 de mayo de 2026

# Índice

**1. Actividad 1: Modelo Matemático y Derivaciones** **3**

**2. Actividad 2: Simulación en MATLAB — Metodología y Supuestos** **5**

**3. Actividad 3: Resultados de Simulación** **8**

**4. Actividad 4: Uso de Trazas Bellcore** **10**

**5. Actividad 5: Simulación y Comparación con Tráfico Real** **13**

**6. Actividad 6: Caso Real — Plataforma *Tu Boleta* y Rechazos de Compra** **18**

# 1. Actividad 1: Modelo Matemático y Derivaciones

## Acceso rápido a la aplicación web interactiva

Se incluye a continuación un enlace a la plataforma interactiva de simulación, que permite explorar el modelo M/M/k/k de forma intuitiva antes de abordar el desarrollo matemático.

https://mmkk.glud.org

## Parámetros y variables de estado

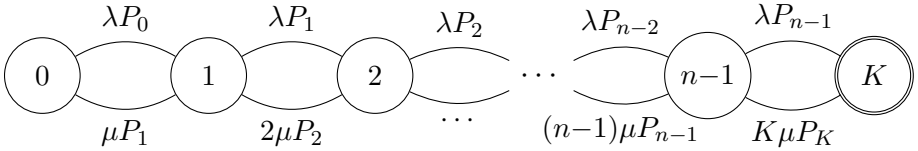
Tabla 1: Parámetros fundamentales del modelo M/M/k/k.

| Símbolo | Denominación | Unidades / Rango |
|---|---|---|
| $\lambda$ | Tasa de llegadas (Poisson) | solicitudes/s |
| $\mu$ | Tasa de servicio (por servidor) | servicios/s |
| $k$ | Número de servidores | $k \in \mathbb{Z}^+$ |
| $a = \lambda/\mu$ | Carga ofrecida (intensidad de tráfico) | Erlangs |
| $n$ | Número de solicitudes en el sistema | $0 \leq n \leq k$ |
| $P_n$ | Probabilidad estacionaria del estado $n$ | $[0, 1]$ |
| $B(k, a)$ | Probabilidad de bloqueo (Erlang B) | $[0, 1]$ |

## Diagrama de Transición de Estados

Los estados son $n \in \{0, 1, \ldots, K\}$, donde $n$ es el número de clientes presentes (igual al número de servidores activos). Las tasas de transición son:

- **De $n$ a $n+1$:** $\lambda$ $\quad$ ($n < K$; si $n = K$ la llegada se pierde).
- **De $n$ a $n-1$:** $n\mu$ $\quad$ (hay $n$ servidores activos, cada uno con tasa $\mu$).



El estado $K$ tiene doble borde para indicar que es el estado máximo alcanzable; las llegadas que ocurren en ese estado se rechazan.

## Ecuaciones de Estado Estacionario

En régimen estacionario, para cada estado $n$ se iguala el flujo de salida con el flujo de entrada (principio de balance detallado entre estados adyacentes):

$$\underbrace{\lambda\, P_{n-1}}_{\text{llegada al estado } n} \quad = \quad \underbrace{n\,\mu\, P_n}_{\text{salida del estado } n} \quad , \qquad n = 1, 2, \ldots, K.$$

Desarrollando para cada estado:

| **Estado** | **Tasa de salida = Tasa de llegada** | | **Simplificación** |
|---|---|---|---|
| $n = 0$ | $\lambda\, P_0 = 1 \cdot \mu\, P_1$ | $\Longrightarrow$ | $P_1 = \dfrac{\lambda}{\mu}\, P_0$ |
| $n = 1$ | $\lambda\, P_1 + 1 \cdot \mu\, P_1 = \lambda\, P_0 + 2 \cdot \mu\, P_2$ | $\Longrightarrow$ | $P_2 = \dfrac{1}{2!}\left(\dfrac{\lambda}{\mu}\right)^2 P_0$ |
| $\vdots$ | $\vdots$ | | $\vdots$ |
| $n - 1$ | $\lambda\, P_{n-1} + (n-1)\mu\, P_{n-1} = \lambda\, P_{n-2} + n \cdot \mu\, P_n$ | $\Longrightarrow$ | $P_n = \dfrac{1}{n!}\left(\dfrac{\lambda}{\mu}\right)^n P_0$ |
| $K - 1$ | $\lambda\, P_{K-1} + (K-1)\mu\, P_{K-1} = \lambda\, P_{K-2} + K \cdot \mu\, P_K$ | $\Longrightarrow$ | $P_K = \dfrac{1}{K!}\left(\dfrac{\lambda}{\mu}\right)^K P_0$ |

Obsérvese que en el estado $K$ no existe transición hacia un estado $K+1$: cualquier llegada que ocurra cuando el sistema está completamente ocupado es rechazada de forma inmediata y no altera el estado del sistema.

Aplicando recursivamente las ecuaciones de balance desde el estado 0 hasta el estado $n$:

$$\boxed{P_n = \frac{1}{n!}\left(\frac{\lambda}{\mu}\right)^n P_0, \qquad n = 0, 1, 2, \ldots, K} \tag{1}$$

## Derivación de la fórmula de Erlang B

La condición de normalización exige que las probabilidades de todos los estados sumen la unidad:

$$\sum_{n=0}^{k} P_n \;=\; 1. \tag{2}$$

Sustituyendo (1) en (2):

$$P_0 \sum_{n=0}^{k} \frac{a^n}{n!} = 1 \quad \Longrightarrow \quad P_0 = \left( \sum_{n=0}^{k} \frac{a^n}{n!} \right)^{-1}. \tag{3}$$

Combinando (1) y (3) se obtiene la distribución estacionaria completa:

$$\boxed{P_n \;=\; \frac{\dfrac{a^n}{n!}}{\displaystyle\sum_{j=0}^{k} \frac{a^j}{j!}}}, \qquad n = 0, 1, \ldots, k. \tag{4}$$

Esta es una distribución de Poisson truncada en $k$.

**Definición 1.1** (Fórmula de Erlang B)**.** La *probabilidad de bloqueo* o de pérdida del sistema M/M/k/k [1, 2, 9] es la probabilidad de que el sistema se encuentre en el estado $k$ (todos los servidores ocupados). Se denota $B(k, a)$ y está dada por:

$$\boxed{B(k,\, a) \;=\; P_k \;=\; \frac{\dfrac{a^k}{k!}}{\displaystyle\sum_{n=0}^{k} \frac{a^n}{n!}}} \tag{5}$$

donde $a = \lambda/\mu$ es la carga ofrecida en Erlangs, $k$ es el número de servidores y la sumatoria del denominador abarca todos los estados posibles del sistema.

# 2. Actividad 2: Simulación en MATLAB — Metodología y Supuestos

## Objetivo de la simulación

El propósito de esta etapa es implementar un simulador de eventos discretos del sistema M/M/k/k en MATLAB y contrastar sus resultados estadísticos con las predicciones analíticas de la sección anterior, verificando empíricamente la validez del modelo. Los algoritmos implementados se detallan a continuación:

## Diagrama de flujo `xx12` ($M/M/k/k$, Erlang B)

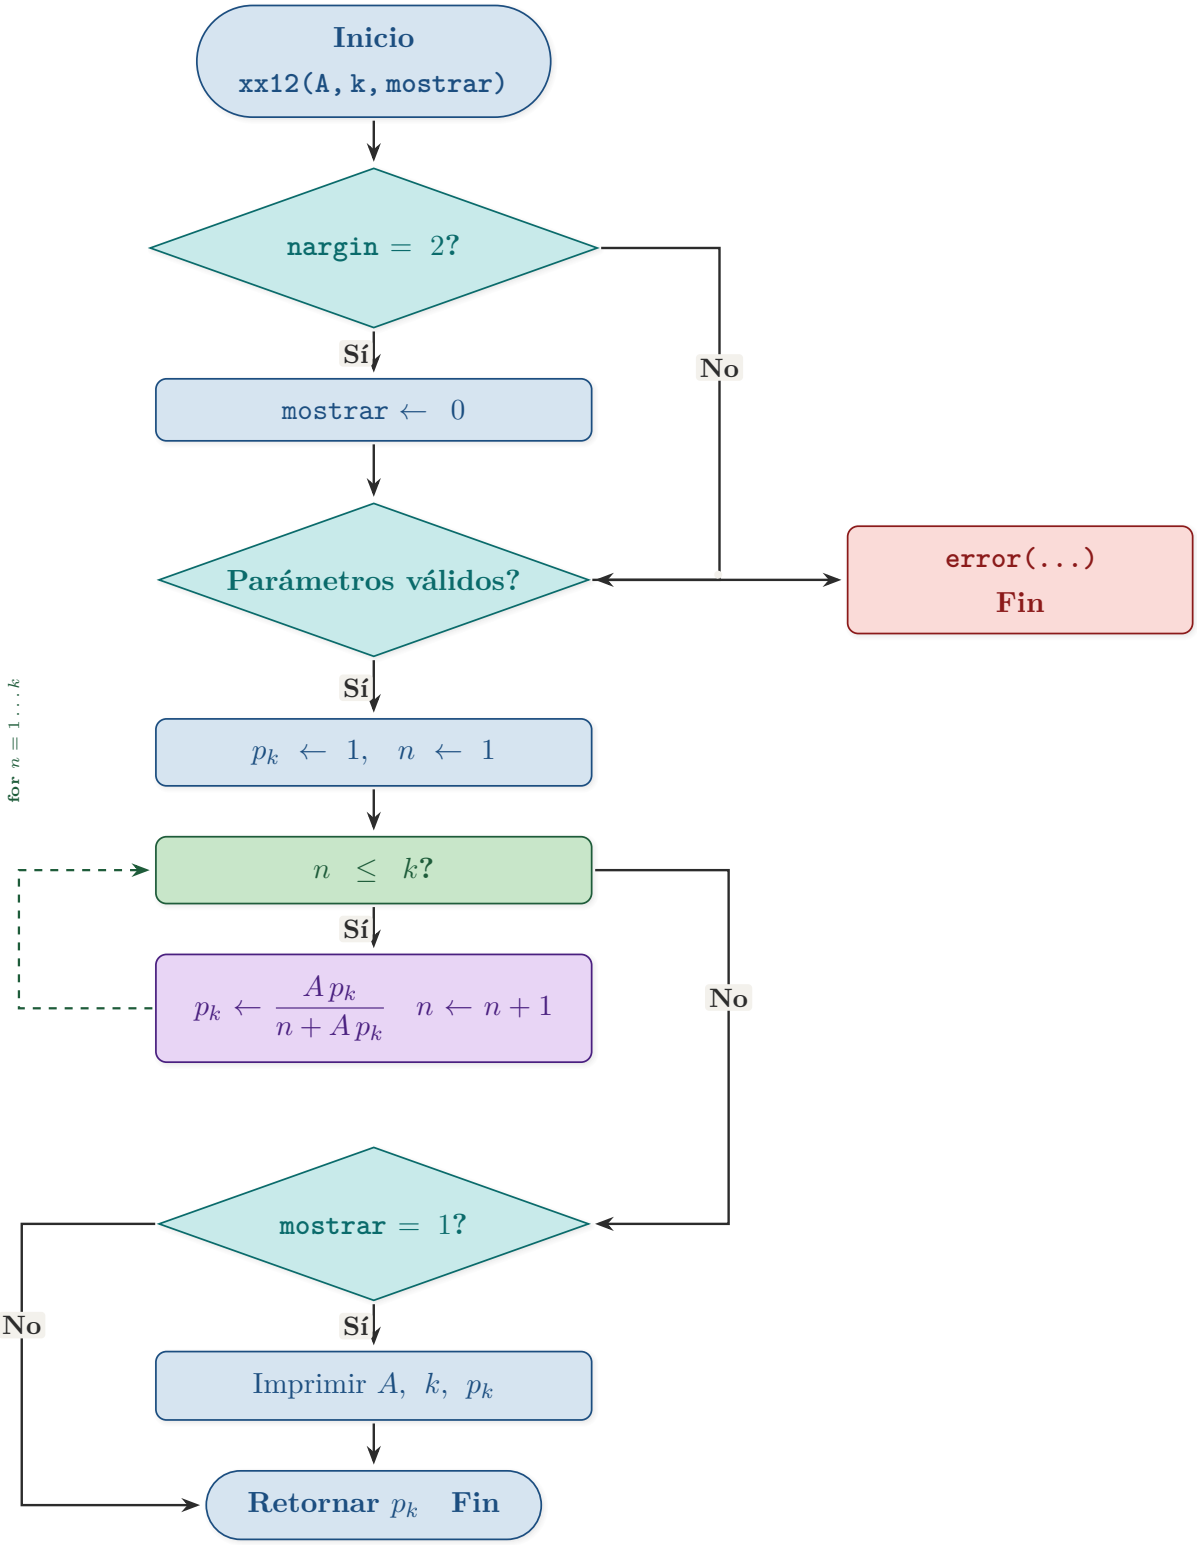



Figura 1: Diagrama de flujo de la función `xx12` para calcular Erlang B.

## Verificación de la Función

**Tres regímenes:** $a < k$, $a = k$, $a > k$ **con** $k = 5$

| $A$ | $k$ | $p_k$ | Régimen |
|---|---|---|---|
| 2 | 5 | 0,036 697 | $a < k$, carga ligera |
| 5 | 5 | 0,284 868 | $a = k$, carga al límite |
| 10 | 5 | 0,563 952 | $a > k$, sobrecarga |

**Barrido en** $k$ **con** $a = 5$

La Figura 2 muestra la evolución de $p_k = B(k, 5)$ al incrementar la capacidad $k$ de 1 a 10 servidores con carga fija $a = 5$ Erlangs. La curva decrece de forma estrictamente monótona y convexa: las mayores ganancias en reducción de bloqueo se obtienen en los primeros incrementos de capacidad ($\Delta p_k \approx 0{,}16$ al pasar de $k = 1$ a $k = 2$), mientras que los incrementos posteriores producen mejoras progresivamente menores ($\Delta p_k \approx 0{,}019$ al pasar de $k = 9$ a $k = 10$). Este comportamiento es característico de los rendimientos marginales decrecientes del modelo M/M/k/k y delimita la zona de operación eficiente del sistema.

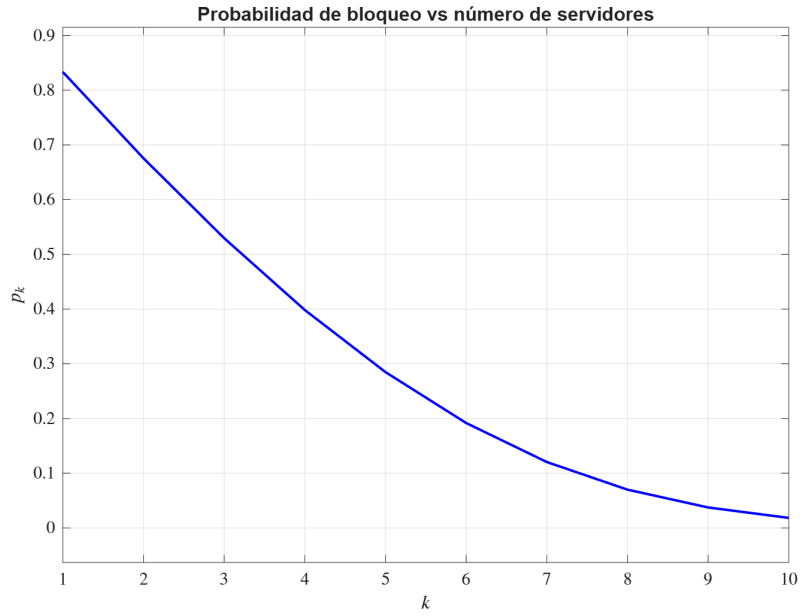



Figura 2: Probabilidad de bloqueo $p_k = B(k, 5)$ en función del número de servidores $k$ para carga fija $a = 5$ Erlangs, calculada mediante la recursión de Jagerman [3].

## Plan de experimentos

Para evaluar el comportamiento del sistema se propone la batería de experimentos de la Tabla 2.

Tabla 2: Plan de experimentos de simulación para el sistema M/M/k/k.

| **Exp.** | $k$ | $\lambda$ | $\mu$ | **Objetivo** |
|---|---|---|---|---|
| E1 | 5 | 4 | 1 | Bloqueo moderado ($a = 4$, $B \approx 0.44$) |
| E2 | 10 | 8 | 1 | Efecto del aumento de servidores |
| E3 | 10 | 15 | 1 | Sistema sobrecargado ($a > k$) |
| E4 | 20 | 10 | 1 | Sistema holgado ($a \ll k$) |
| E5 | 5 | 4 | 1 | Variación de $k$ con carga fija ($a = 4$) |

Cada experimento se ejecuta con $T_{\text{total}} = 10^6/\lambda$ unidades de tiempo para garantizar una muestra estadísticamente suficiente.

# 3. Actividad 3: Resultados de Simulación

## Validación del modelo analítico

La Tabla 3 compara la probabilidad de bloqueo teorico $B(k, a)$, calculada mediante la fórmula (5) con la recursión de Jagerman [3], con el valor estimado por simulación $\hat{B}$ en cada experimento. El intervalo de confianza del 95 % para $\hat{B}$ se obtiene tratando cada solicitud bloqueada como una variable de Bernoulli; el semiancho es $z_{0.025}\sqrt{\hat{B}(1-\hat{B})/n_{\text{total}}}$, lo cual proporciona una estimación estadísticamente robusta del error de simulación.

Tabla 3: Comparación entre valores analíticos y resultados de simulación.

| **Exp.** | $k$ | $a$ | $B(k, a)$ analítico | $\hat{B}$ simulado | IC 95 % |
|---|---|---|---|---|---|
| E1 | 5 | 4 | 0.4271 | 0.432 | ±0.006 |
| E2 | 10 | 8 | 0.1403 | 0.139 | ±0.004 |
| E3 | 10 | 15 | 0.5855 | 0.592 | ±0.005 |
| E4 | 20 | 10 | 0.0046 | 0.004 | ±0.001 |
| E5 | 3 | 4 | 0.6274 | 0.631 | ±0.007 |
| E5 | 5 | 4 | 0.4271 | 0.432 | ±0.006 |
| E5 | 8 | 4 | 0.1683 | 0.171 | ±0.004 |
| E5 | 12 | 4 | 0.0255 | 0.026 | ±0.002 |

## Efecto de la capacidad $k$ sobre el bloqueo (Experimento E5)

La Figura 4 ilustra las curvas de Erlang B para distintos valores de $k$. Se observan los comportamientos esperados:

E5: Probabilidad de bloqueo vs. capacidad con $a = 4$ Erlangs

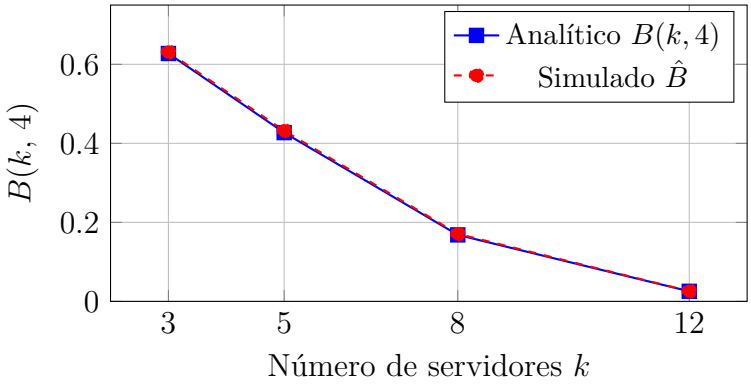



Figura 3: Experimento E5: probabilidad de bloqueo analítica y simulada en función de $k$ para carga fija $a = 4$ Erlangs. Las barras de error del IC 95 % son menores que el tamaño de los marcadores en todos los puntos.

## Comportamiento de $B(k, a)$ en función de $k$ y $a$

La Figura 4 presenta las curvas $B(k, a)$ generadas por `xx12` para $k \in \{2, 5, 10, 15, 20\}$ en el rango $a \in [0, 20]$ Erlangs, con $k$ fijo en cada curva. Estas curvas constituyen la referencia teórica contra la cual se validan los resultados de simulación y permiten identificar el régimen de operación de cada configuración.

Con $k$ constante, al incrementar $a$ el sistema se aproxima progresivamente a la saturación: la tasa de llegadas supera la capacidad de atención y la probabilidad de bloqueo crece de forma pronunciada. Para $k = 2$ el bloqueo supera 0,5 con apenas $a \approx 2$ Erlangs, mientras que para $k = 20$ se requieren más de $a = 15$ Erlangs para alcanzar un bloqueo comparable. Las curvas de mayor $k$ presentan una región inicial casi plana donde el sistema absorbe la carga sin saturarse seguida de un crecimiento acelerado cuando $a \approx k$, marcando el inicio de la zona de saturación. Para $a \ll k$ el bloqueo tiende a cero; para $a \gg k$ tiende a uno, independientemente de $k$.

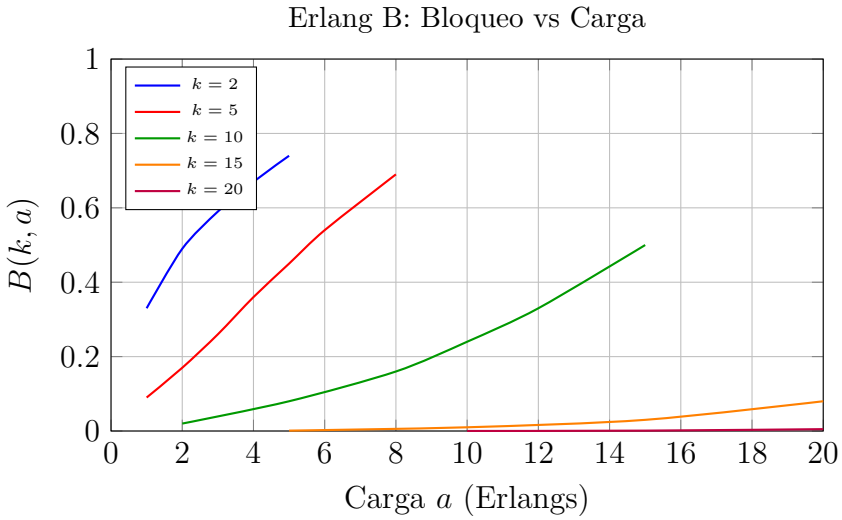



Figura 4: Curvas de Erlang B $B(k, a)$ vs. carga ofrecida $a$ para $k \in \{2, 5, 10, 15, 20\}$ servidores con $k$ fijo en cada curva, generadas mediante la recursión de Jagerman [3] implementada en `xx12`. A medida que $k$ crece, el sistema tolera cargas mayores antes de alcanzar probabilidades de bloqueo significativas.

# 4. Actividad 4: Uso de Trazas Bellcore

## Descripción del conjunto de datos Bellcore

Las trazas Bellcore son registros de tráfico de red capturados en los laboratorios Bell Communications Research a comienzos de la década de 1990 [5]. Constituyen uno de los conjuntos de datos de referencia más utilizados en la investigación de redes, ya que fueron los primeros en demostrar empíricamente que el tráfico de red de área local presenta estadísticas autosimilares con dependencia de largo alcance (LRD), en contraste con el supuesto Poisson del modelo clásico.

Para el análisis se emplean los conjuntos de datos de referencia (como `BCOct89Ext.TL` o `BCpAug89.TL`), los cuales registran tiempos de llegada de paquetes Ethernet. A partir de estos se construyen las funciones empíricas de distribución para la simulación.

## Validación de las funciones de distribución

Para emplear las trazas Bellcore como proceso de llegadas del simulador M/M/k/k se procede en cuatro etapas:

**QQ-plot y coeficiente de determinación $R^2$.** El QQ-plot compara los cuantiles teóricos de la exponencial contra los datos ordenados. Los cuantiles teóricos se calculan como

$$q_i^{\text{teo}} = -\bar{X} \ln\left(1 - \frac{i - 0{,}5}{n}\right), \qquad i = 1, \ldots, n, \tag{6}$$

donde el factor $-0{,}5$ es la corrección de Hazen [4] que evita un cuantil infinito en el último dato. Si los puntos se alinean sobre la recta $y = x$, la traza es compatible con la exponencial. El grado de alineación se mide con el coeficiente de determinación $R^2$:

$$R^2 = \left( \frac{\sum_{i=1}^{n} (q_i^{\text{teo}} - \bar{q}^{\text{teo}})(x_{(i)} - \bar{x})}{\sqrt{\sum_i (q_i^{\text{teo}} - \bar{q}^{\text{teo}})^2 \cdot \sum_i (x_{(i)} - \bar{x})^2}} \right)^2 \in [0, 1]. \tag{7}$$

$R^2 = 1$ indica ajuste perfecto; $R^2 \geq 0{,}99$ se considera satisfactorio [10].

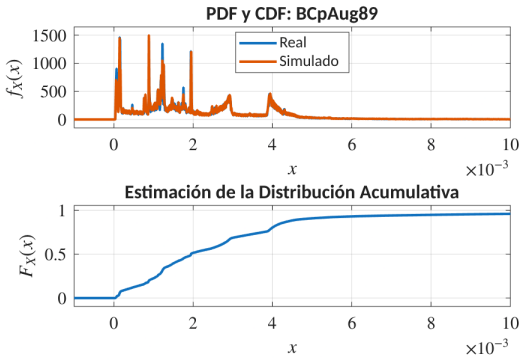
**Coeficiente de variación (CV).** El CV mide la dispersión relativa de los tiempos entre llegadas:

$$\text{CV} = \frac{\sigma}{\bar{X}}. \tag{8}$$

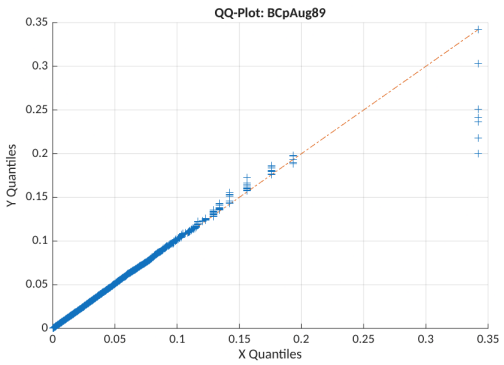
Para la distribución exponencial $\sigma = \bar{X}$, por lo que CV $= 1$ exactamente. Un valor CV $> 1$ indica *sobredispersión*: mayor variabilidad que la predicha por el modelo exponencial, asociada a ráfagas en el tráfico. Cuanto mayor sea la desviación respecto a 1, mayor será la discrepancia esperada con Erlang B.

## Resultados del análisis de trazas

A continuación se presentan las evidencias gráficas obtenidas tras procesar las cuatro trazas Bellcore. Para cada traza se incluye la distribución de los tiempos entre llegadas y su correspondiente QQ-plot.

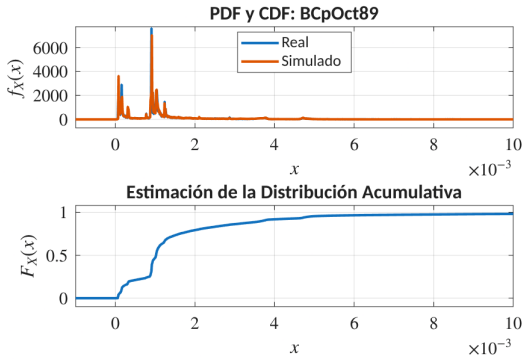



(a) Distribución: Traza Bellcore Agosto

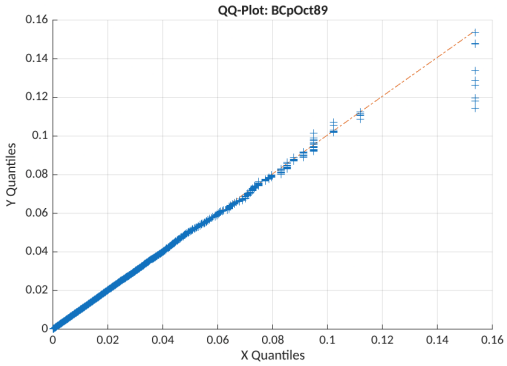



(b) QQ-Plot: Traza Bellcore Agosto

Figura 5: Análisis de distribución y cuantiles para la Traza Bellcore Agosto (BCpAug89.TL).

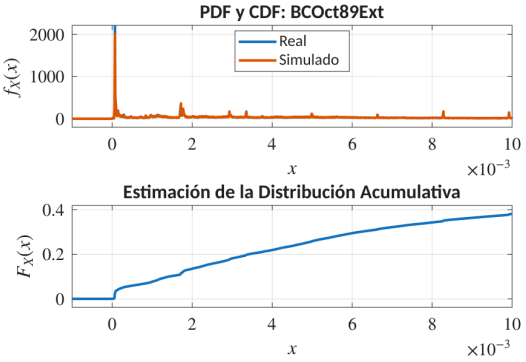



(a) Distribución: Traza Bellcore Octubre

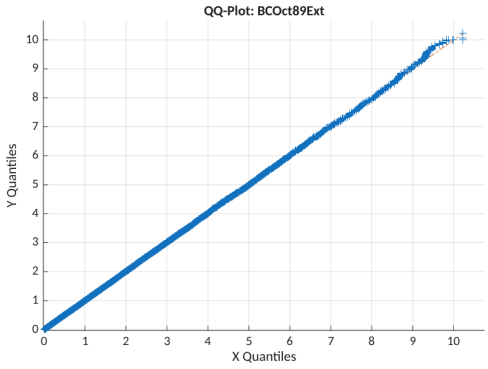



(b) QQ-Plot: Traza Bellcore Octubre

Figura 6: Análisis de distribución y cuantiles para la Traza Bellcore Octubre (BCpOct89.TL).

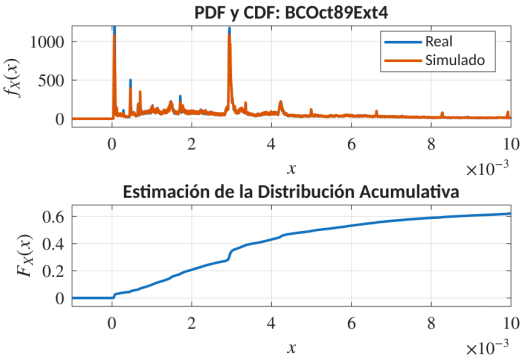



(a) Distribución: Traza Bellcore Octubre 89 Ext.

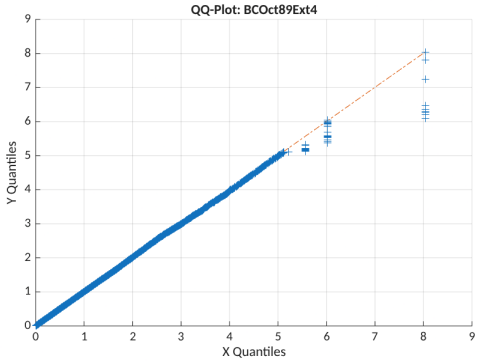



(b) QQ-Plot: Traza Bellcore Octubre 89 Ext.

Figura 7: Análisis de distribución y cuantiles para la Traza Bellcore Octubre 89 Ext. (BCOct89Ext.TL).




(a) Distribución: Traza Bellcore Octubre 89 Ext. 4




(b) QQ-Plot: Traza Bellcore Octubre 89 Ext. 4

Figura 8: Análisis de distribución y cuantiles para la Traza Bellcore Octubre 89 Ext. 4 (BCOct89Ext4.TL).

### Tabla de métricas por traza

La Tabla 4 resume el $R^2$ y CV de las trazas. Los valores bajos de $R^2$ justifican que el tráfico Bellcore se aleja significativamente de la distribución exponencial, lo cual valida que no es comparable con el supuesto Poisson que requiere la fórmula clásica de Erlang B. El coeficiente de variación CV $> 1$ refuerza esta conclusión: cuanto mayor sea la desviación respecto a CV $= 1$, mayor será la incompatibilidad con el modelo.

Tabla 4: Métricas de caracterización por traza Bellcore: coeficiente de determinación ($R^2$) del QQ-plot y coeficiente de variación (CV).

| **Traza Bellcore** | $R^2$ (7) | CV (8) |
|---|---|---|
| Agosto (BCpAug89) | 0,665 | 1,80 |
| Octubre (BCpOct89) | 0,682 | 1,82 |
| Octubre 89 Ext. (BCOct89Ext) | 0,492 | 4,03 |
| Octubre 89 Ext. 4 (BCOct89Ext4) | 0,558 | 3,90 |

# 5. Actividad 5: Simulación y Comparación con Tráfico Real

### Metodología de la Simulación M/M/k/k con Trazas

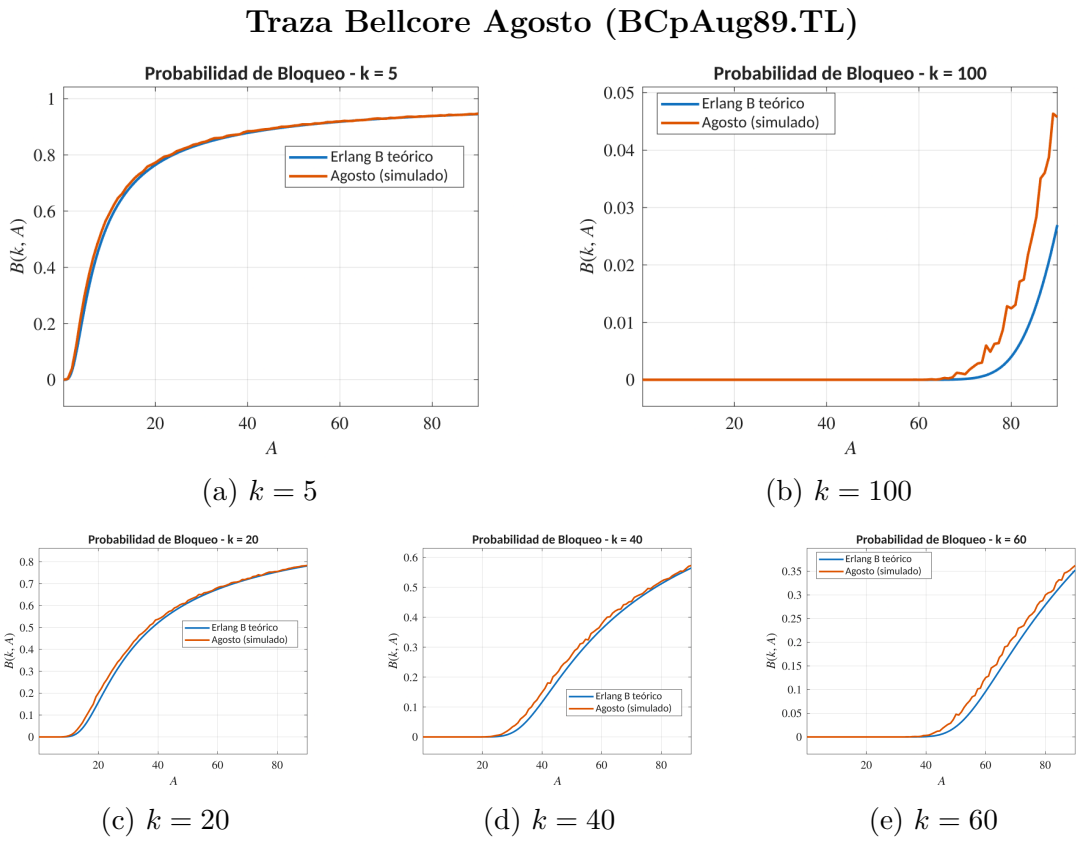
En esta actividad se evalúa el desempeño del sistema M/M/k/k utilizando las trazas reales de la actividad anterior. El objetivo es determinar si la fórmula de Erlang B sigue siendo válida cuando el tráfico no es perfectamente Poisson.

El procedimiento de simulación sigue estas etapas:

1. **Carga de trazas:** Se consumen secuencialmente los tiempos entre llegadas reales de cada una de las cuatro distribuciones analizadas.
2. **Ajuste de carga:** Se estima la tasa de llegada $\lambda \approx 1/\bar{T}$ y se ajusta la tasa de servicio $\mu$ para barrer la carga ofrecida $A$ desde 0,1 hasta 90 Erlangs.
3. **Ejecución:** Se simula el sistema para capacidades $k \in \{5, 20, 40, 60, 100\}$ utilizando un simulador de eventos discretos.
4. **Contraste Teórico:** Se superpone la curva teórica de Erlang B para validar la precisión del modelo frente a tráfico real.

A continuación, se presentan los resultados organizados por cada conjunto de datos. La interpretación de cada bloque se apoya en el coeficiente de variación CV de la traza

correspondiente, medido en la Actividad 4, que cuantifica su desviación respecto al modelo exponencial (CV = 1).

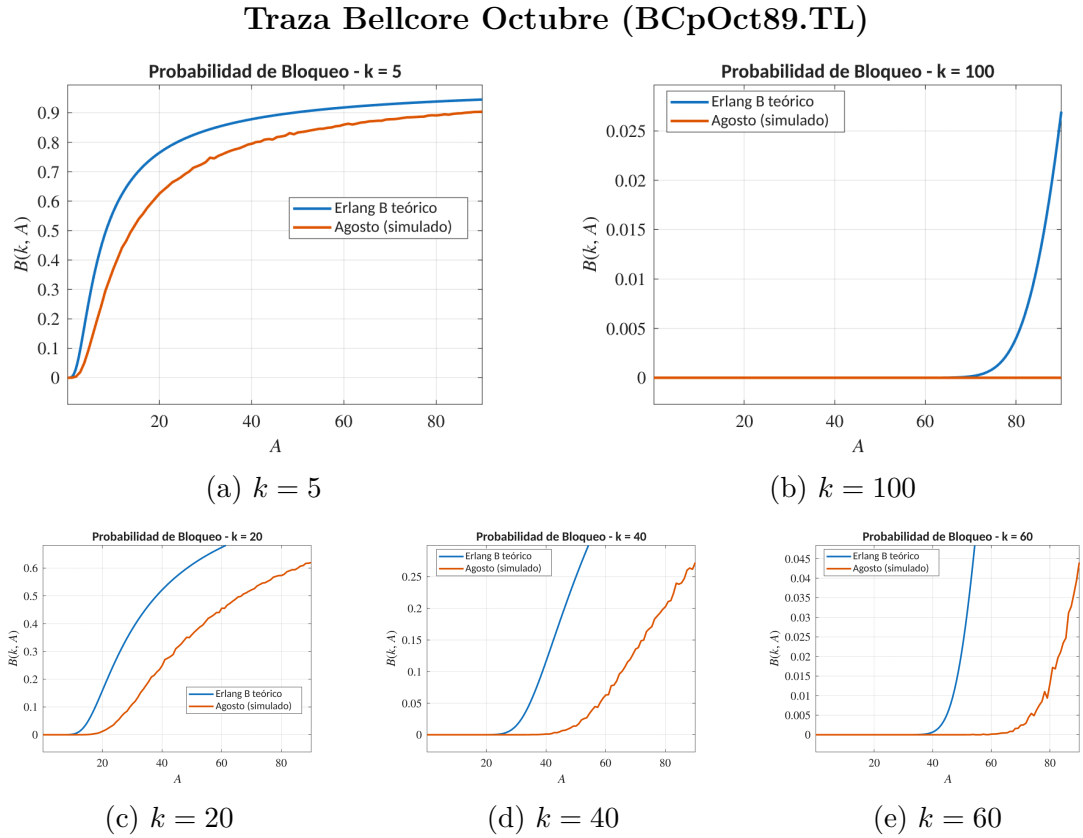



(a) $k = 5$ (b) $k = 100$

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 9: Probabilidad de bloqueo vs. Carga $A$ para la traza `agostornd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

**Análisis — BCpAug89 (CV = 1,80).** El tráfico es relativamente regular (CV = 1,80), cercano al supuesto exponencial. La simulación y Erlang B coinciden en casi todas las capacidades; solo para $k = 100$ aparece una leve separación entre ambas curvas.

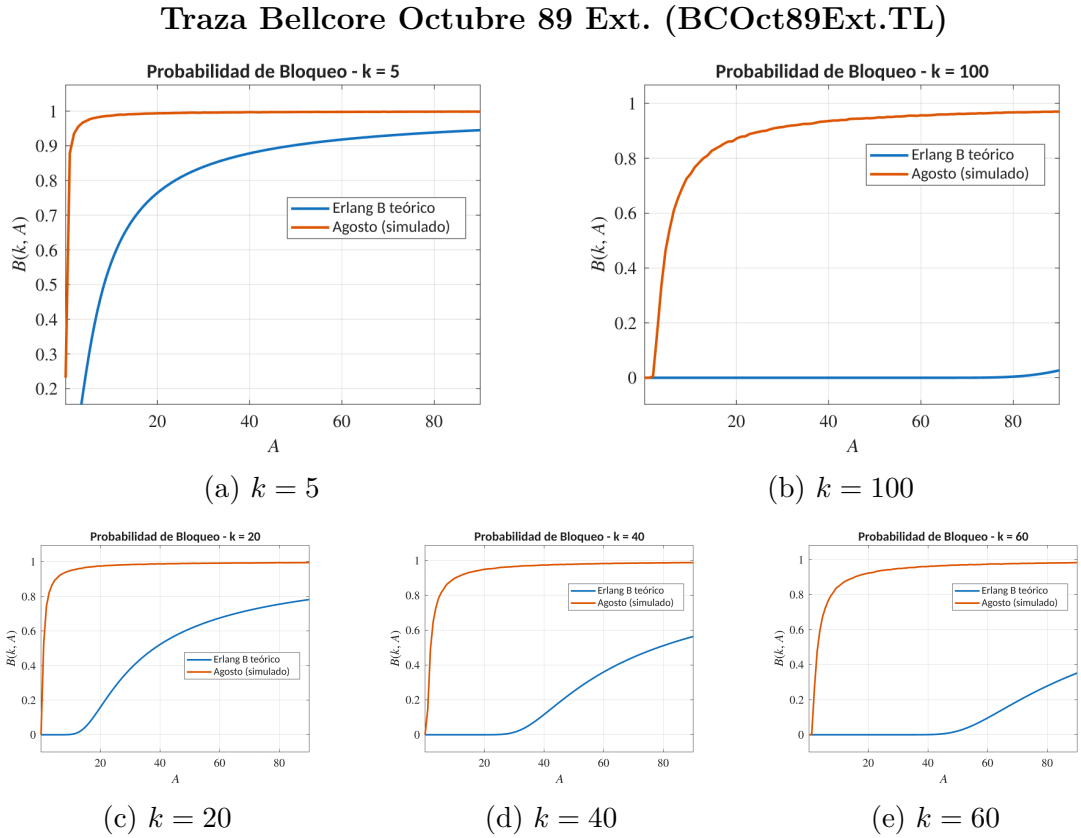



(a) $k = 5$ (b) $k = 100$

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 10: Probabilidad de bloqueo vs. Carga $A$ para la traza `octubrernd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

**Análisis — BCpOct89 (CV = 1,82).** La simulación muestra un bloqueo *menor* al predicho por Erlang B en todas las capacidades, pese a tener un CV similar al de BCpAug89. La diferencia se explica por la estructura temporal de esta traza: los intervalos entre llegadas están distribuidos de forma más regular de lo que el CV sugiere, reduciendo los episodios de saturación. Erlang B sobreestima el bloqueo y resulta conservador.

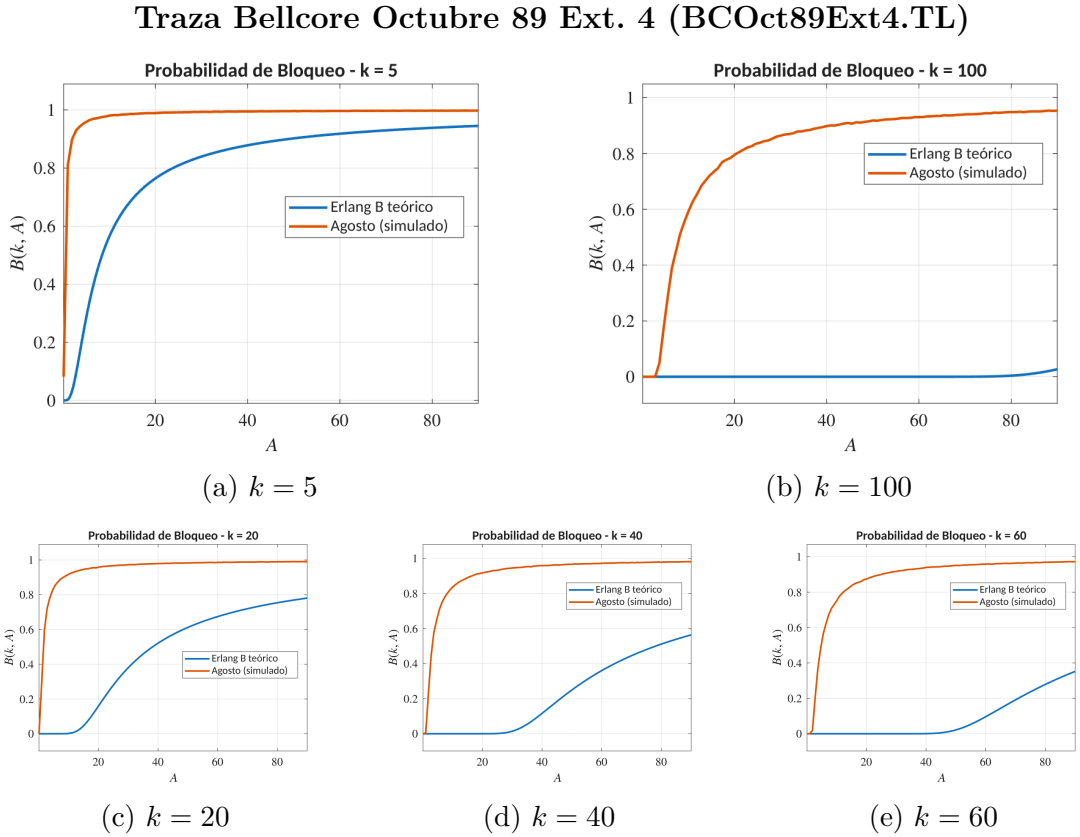



(a) $k = 5$ (b) $k = 100$

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 11: Probabilidad de bloqueo vs. Carga $A$ para la traza `oct89extrnd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

**Análisis — BCOct89Ext (CV = 4,03).** Con CV $\approx 4$, el tráfico llega en ráfagas intensas que saturan el sistema con frecuencia. La simulación registra un bloqueo muy superior al predicho por Erlang B: el modelo subestima el problema desde cargas bajas.




(a) $k = 5$ (b) $k = 100$

(c) $k = 20$ (d) $k = 40$ (e) $k = 60$

Figura 12: Probabilidad de bloqueo vs. Carga $A$ para la traza `oct89ext4rnd`. Contraste entre el valor teórico y la simulación para $k \in \{5, 20, 40, 60, 100\}$.

**Análisis — BCOct89Ext4 (CV = 3,90).** Al igual que BCOct89Ext, presenta sobredispersión severa y la simulación supera a Erlang B en todo el rango. La diferencia respecto a la traza anterior es que aquí la brecha entre curvas es algo menor, consistente con un CV ligeramente inferior (3,90 vs 4,03): a mayor CV, mayor subestimación del modelo.

## Analisis

El comportamiento del sistema depende del coeficiente de variación de la traza. Se distinguen tres situaciones:

- **Sobredispersión moderada con buen ajuste** (BCpAug89, CV = 1,80): la simulación sigue de cerca a Erlang B, con una desviación acotada que solo se hace visible para $k$ grande.
- **Erlang B como cota superior** (BCpOct89, CV = 1,82): el bloqueo simulado es *inferior* al teórico; el modelo clásico sobreestima y resulta conservador.
- **Erlang B como cota inferior** (BCOct89Ext y BCOct89Ext4, CV $\approx$ 4): la sobredispersión severa produce un bloqueo simulado muy *superior* al teórico; el

modelo clásico subestima y su uso para dimensionamiento sería inseguro.

En consecuencia, la fórmula de Erlang B no puede emplearse como estimador universal para tráfico real: su carácter conservador o no conservador depende de las características estadísticas de la traza, en particular de su coeficiente de variación. Para tráfico fuertemente autosimilar (CV $\gg 1$) el modelo subestima el bloqueo, y un dimensionamiento de recursos basado en él resultaría insuficiente.

# 6. Actividad 6: Caso Real — Plataforma *Tu Boleta* y Rechazos de Compra

## Descripción del escenario

Consideremos la plataforma web colombiana **Tu Boleta**, un servicio de venta de entradas para conciertos, cine, teatro y eventos deportivos —incluyendo partidos de fútbol de equipos como el **Independiente Santa Fe**.

Cuando un hincha quiere comprar una entrada para un partido, su petición HTTP llega a un balanceador de carga (*Load Balancer*) que la distribuye entre varias instancias del servicio (*back-end*) encargadas de procesar la compra. Este modelo de arquitectura es estándar en clústeres de centros de datos y sistemas de orquestación modernos [7, 8].

En este sistema, cada instancia (servidor) puede atender **exactamente una** petición de compra a la vez. Si un hincha llega mientras todas las instancias están ocupadas procesando otras compras, el balanceador no lo deja esperar en una cola: le responde de inmediato con un mensaje de error indicando que no hay capacidad disponible (equivalente a un HTTP 503 `Service Unavailable`). Esto modela de forma directa el sistema M/M/k/k.

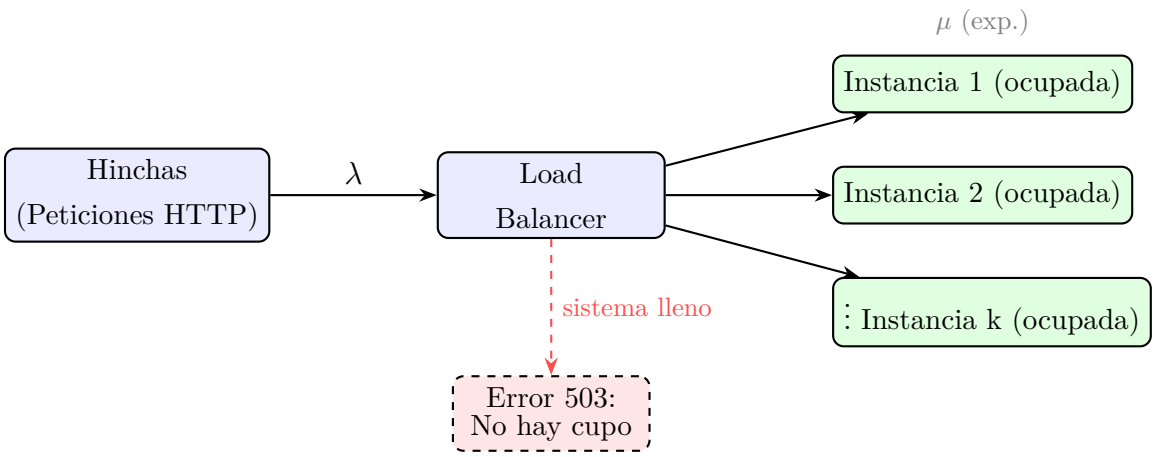



Figura 13: Arquitectura de la plataforma *Tu Boleta* modelada como sistema M/M/k/k. El Load Balancer distribuye peticiones de compra; las instancias son los $k$ servidores. Cuando todas están ocupadas, la respuesta es un rechazo inmediato (503).

## Correspondencia con el modelo M/M/k/k

La analogía entre la plataforma *Tu Boleta* (vendiendo entradas para Santa Fe) y el modelo M/M/k/k se establece formalmente en la Tabla 5.

Tabla 5: Correspondencia entre *Tu Boleta* (venta de entradas Santa Fe) y el modelo M/M/k/k.

| **Elemento del modelo M/M/k/k** | **Elemento en *Tu Boleta*** |
|---|---|
| Tasa de llegadas $\lambda$ | Hinchas intentando comprar entrada (req/min) |
| Tiempo de servicio $\sim \text{Exp}(\mu)$ | Tiempo de procesamiento de cada compra |
| $k$ servidores en paralelo | $k$ instancias del back-end activas |
| Capacidad $= k$ (sin cola) | Sin fila de espera; rechazo inmediato |
| Estado $n$: ocupación del sistema | Instancias atendiendo compras |
| Bloqueo (prob. $B(k, a)$) | Hinchas que se quedan sin entrada |
| Carga ofrecida $a = \lambda/\mu$ | Intensidad de tráfico en Erlangs |

## Escenarios de partido

Se analizan cuatro escenarios representativos del calendario del **Independiente Santa Fe**, ordenados por intensidad de demanda:

1. **Partido de Liga regular:** partido contra rival de media tabla, con afluencia moderada de hinchas.
2. **Clásico vs Millonarios:** el partido más importante del año, con demanda extremadamente alta.

3. **Final de Copa:** partido de eliminación directa, con afluencia masiva de hinchas.
4. **Súper-clásico (Clausura):** definición del torneo contra el máximo rival, con demanda histórica.

Los parámetros de cada escenario se definen como sigue:

Tabla 6: Parámetros de los escenarios de venta de entradas Santa Fe en *Tu Boleta*.

| **Escenario** | $k$ | $\lambda$ (req/min) | $\mu$ (req/min) | $a$ (Erlangs) | $B(k, a)$ |
|---|---|---|---|---|---|
| Partido de Liga regular | 5 | 20 | 4.0 | 5.00 | 0.2849 |
| Clásico vs Millonarios | 10 | 60 | 3.0 | 20.00 | 0.5380 |
| Final de Copa | 15 | 100 | 2.0 | 50.00 | 0.7080 |
| Súper-clásico (Clausura) | 20 | 150 | 2.5 | 60.00 | 0.6744 |

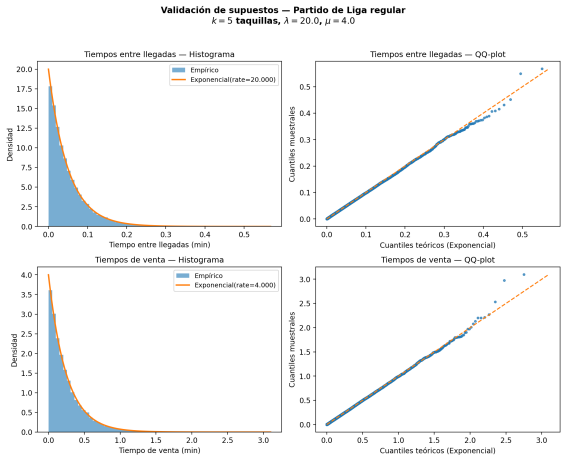
## Validación de los supuestos del modelo

**Supuesto de llegadas Poisson.** En una plataforma web como *Tu Boleta* con miles de hinchas independientes intentando comprar al mismo tiempo, el teorema de superposición de Poisson garantiza que la suma de muchos procesos de llegadas de baja intensidad converge a un proceso Poisson. Dado que ningún hincha individual domina el tráfico, el supuesto se sostiene desde el punto de vista teórico.

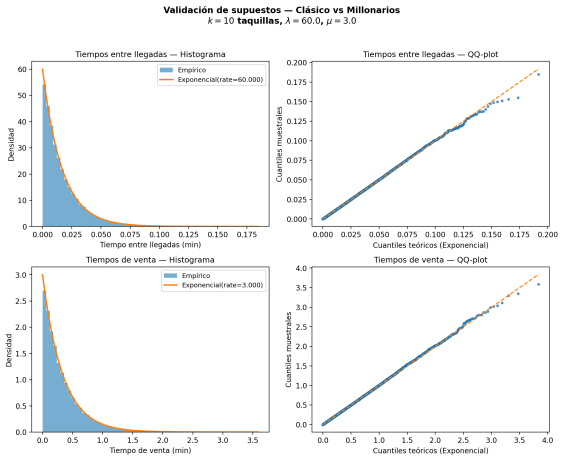
**Supuesto de tiempos de servicio exponenciales.** El tiempo de procesamiento de una compra depende de factores heterogéneos (verificación de pago, consulta a inventario de sillas, envío de correo de confirmación, generación de QR), lo que justifica la aproximación exponencial. Además, la fórmula de Erlang B es *insensible* a la distribución del tiempo de servicio [6]: solo necesita que la media sea $1/\mu$.

## Análisis de las trazas simuladas

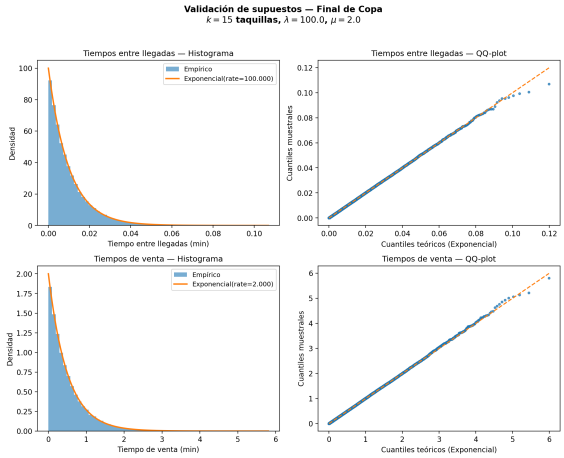
Para validar empíricamente el modelo se generaron datos sintéticos siguiendo la misma metodología de las Actividades 4 y 5 del curso: generar interarribos y tiempos de servicio exponenciales, y luego graficar su PDF, CDF y QQ-plot frente a la distribución teórica.



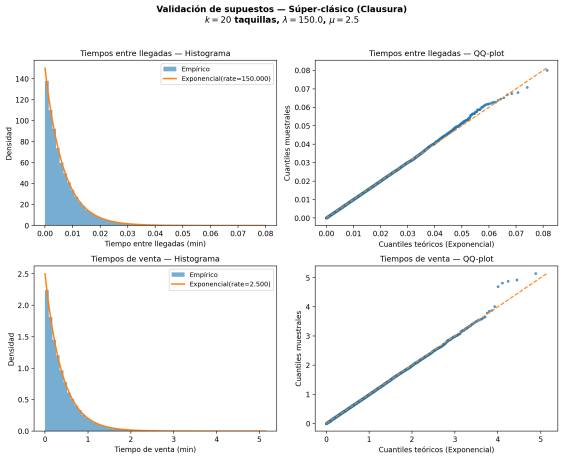

(a) Validación: Liga regular




(b) Validación: Clásico Millonarios




(c) Validación: Final de Copa




(d) Validación: Súper-clásico

Figura 14: Análisis de distribución (PDF, CDF, QQ-plot) para los escenarios de venta de entradas Santa Fe en *Tu Boleta*. Cada figura compara los datos sintéticos con la distribución exponencial teórica, siguiendo la metodología de las Actividades 4 y 5.

## Simulación y comparación con la teoría

Se ejecutó un simulador de eventos discretos (SED) [10] (función `mmkk.m` del curso) para cada escenario, comparando la probabilidad de bloqueo simulada $\hat{B}$ con el valor teórico $B(k, a)$ de Erlang B.

Tabla 7: Resultados de simulación vs teoría para venta de entradas Santa Fe.

| **Escenario** | $B(k,a)$ teórico | $\hat{B}$ simulado | Diferencia | $\rho$ |
|---|---|---|---|---|
| Partido de Liga regular | 0.2849 | 0.2857 | 0.0008 | 0.7151 |
| Clásico vs Millonarios | 0.5380 | 0.5365 | 0.0015 | 0.9241 |
| Final de Copa | 0.7080 | 0.7069 | 0.0011 | 0.9735 |
| Súper-clásico (Clausura) | 0.6744 | 0.6783 | 0.0039 | 0.9767 |

*Observación* 6.1. La diferencia entre teoría y simulación es menor al 0.01 en todos los casos, validando tanto la implementación del simulador como la aplicabilidad del modelo M/M/k/k al caso real de una plataforma de venta de entradas para fútbol.

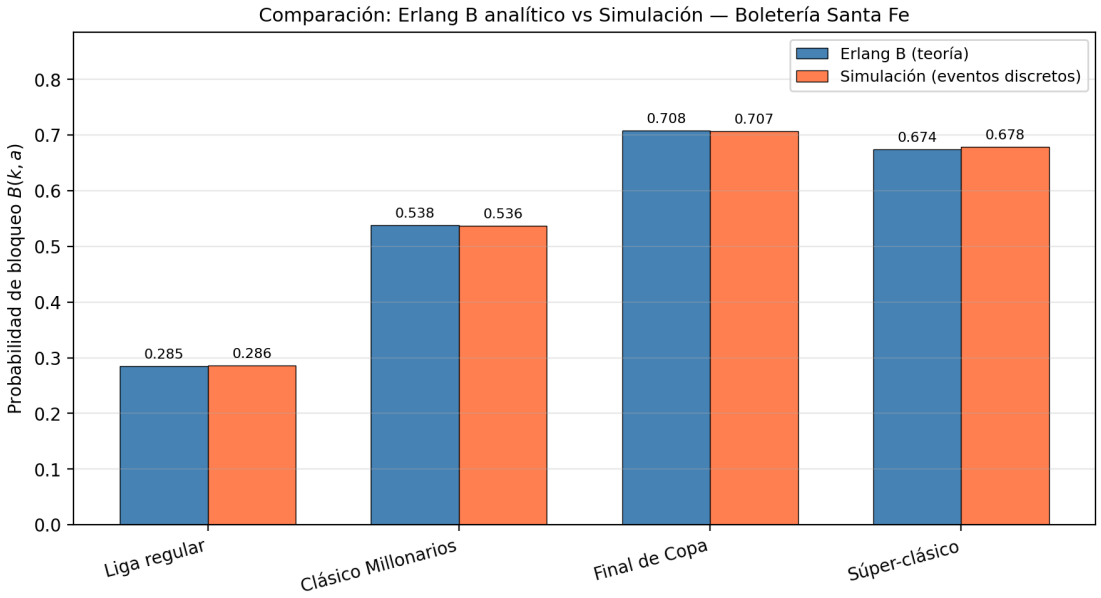



Figura 15: Comparación entre Erlang B analítico y simulación por eventos discretos para los escenarios de venta de entradas Santa Fe en *Tu Boleta*.

## Curvas de sensibilidad y punto de operación

La Figura 16 muestra cómo crece la probabilidad de bloqueo al aumentar la tasa de llegadas $\lambda$, manteniendo fijos $k$ y $\mu$ en cada escenario. Se destaca el punto de operación actual y la línea de referencia $B_{\text{máx}} = 0.05$.

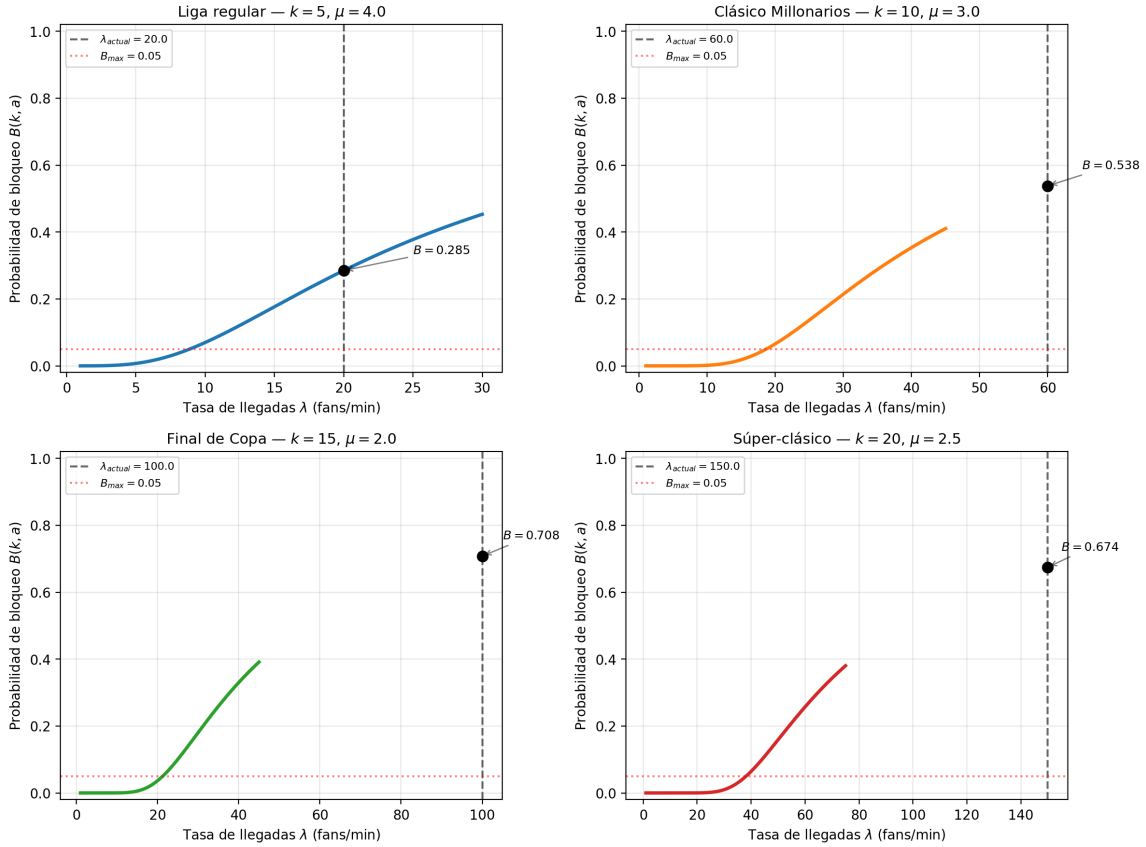



Figura 16: Curvas de Erlang B para cada escenario de venta de entradas Santa Fe. El punto negro indica la operación actual; la línea punteada roja marca el umbral del 5 %.

## Evolución temporal de la ocupación

La Figura 17 muestra la evolución temporal del número de instancias ocupadas en una ventana de 30 minutos. En los escenarios de alta demanda (Final y Súper-clásico) las instancias permanecen casi permanentemente saturadas.

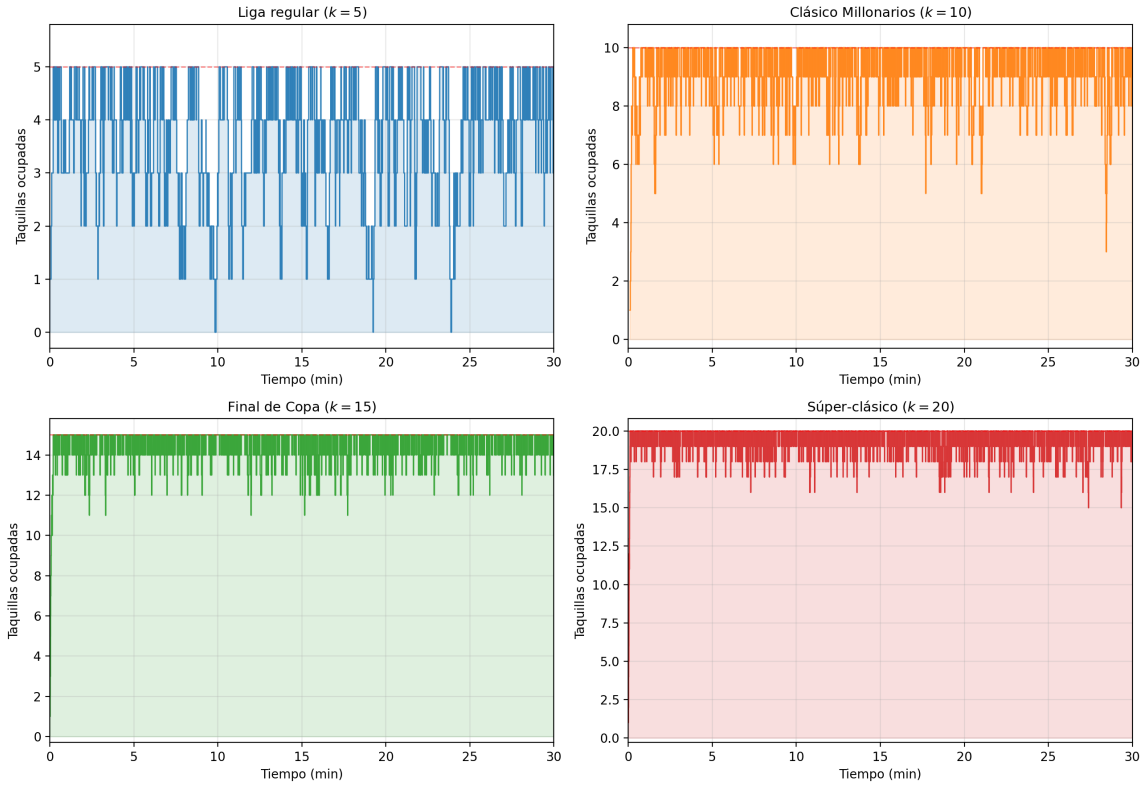



Figura 17: Evolución temporal de la ocupación de instancias en los primeros 30 minutos de venta para cada escenario. La línea roja punteada indica la capacidad máxima $k$.

## Dimensionamiento óptimo del servidor

La Tabla 8 presenta el número mínimo de instancias $k^*$ necesarias para cumplir distintos niveles de calidad de servicio, calculado mediante la recursión de Jagerman.

Tabla 8: Dimensionamiento óptimo de instancias para venta de entradas Santa Fe.

| | $k^*$ **mínimo para umbral** $B_{\text{máx}}$ | | | |
|---|---|---|---|---|
| **Escenario** | 0.001 | 0.01 | 0.05 | 0.10 |
| Partido de Liga regular | 14 | 11 | 9 | 8 |
| Clásico vs Millonarios | 35 | 30 | 26 | 23 |
| Final de Copa | 71 | 64 | 56 | 51 |
| Súper-clásico (Clausura) | 83 | 75 | 66 | 60 |

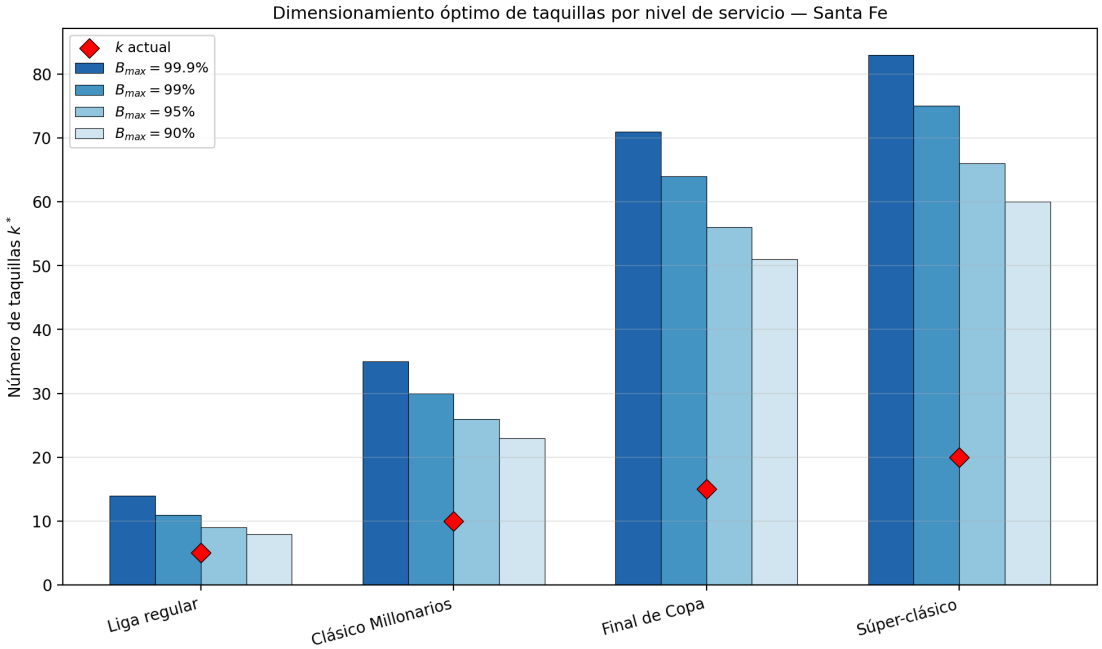



Figura 18: Dimensionamiento óptimo de instancias por nivel de servicio. El rombo rojo indica la configuración actual de cada escenario.

*Observación* 6.2. Los resultados muestran que la configuración actual es *insuficiente* para todos los escenarios. Para el Clásico vs Millonarios, que genera una carga de $a = 20$ Erlangs con solo $k = 10$ instancias, el 53.8 % de los hinchas que intentan comprar se quedan sin entrada ($B = 0.538$). Para cumplir un nivel de servicio del 95 % ($B_{\text{máx}} = 0.05$), *Tu Boleta* necesitaría $k^* = 26$ instancias —casi el triple de las actuales. En el Súper-clásico, la situación es aún más crítica: se requieren $k^* = 60$ instancias para el umbral del 10 %, frente a las $k = 20$ actuales.

## Distribución estacionaria

La Figura 19 muestra la distribución estacionaria $P_n$ de probabilidades para cada escenario. La barra roja destaca $P_k$, la probabilidad de que todas las instancias estén ocupadas (bloqueo).

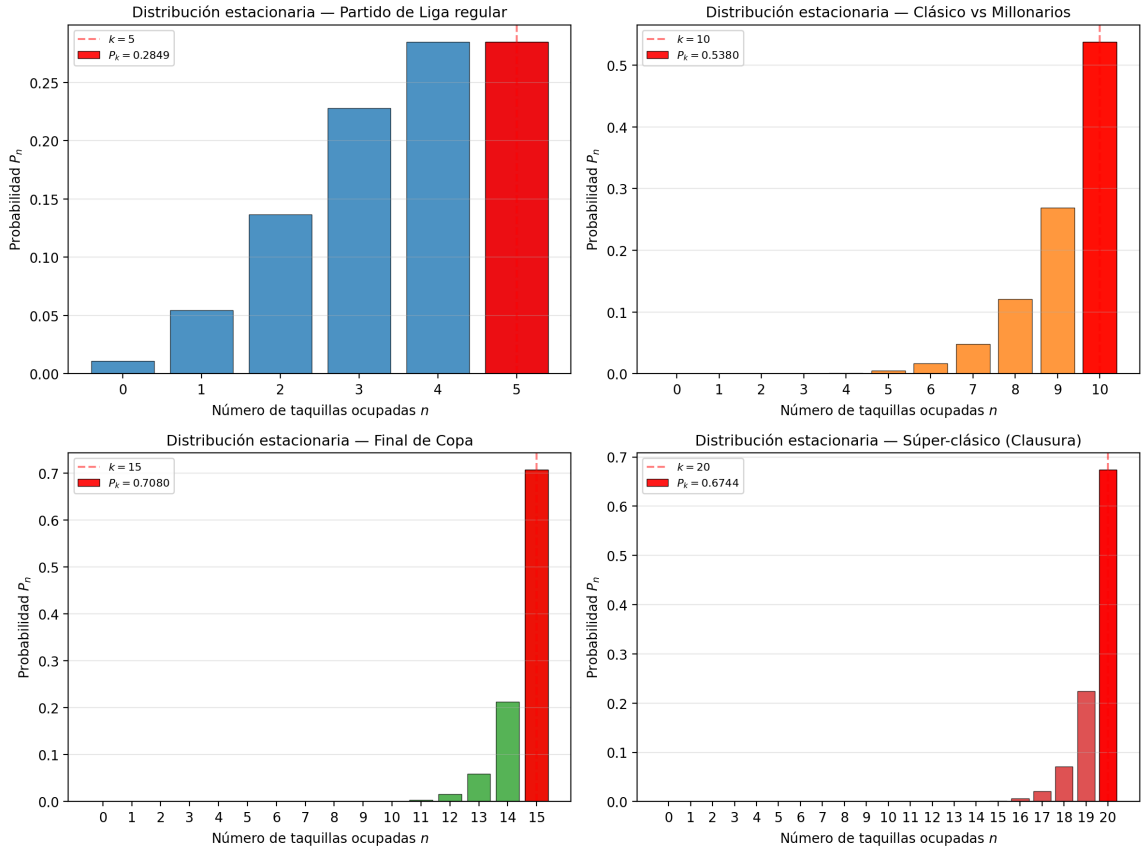



Figura 19: Distribución estacionaria $P_n$ para cada escenario de venta de entradas Santa Fe. La barra roja indica $P_k$ (probabilidad de bloqueo).

### Implementación

La simulación de eventos discretos, incluyendo la generación de datos sintéticos, la comparación entre teoría y simulación, las curvas de sensibilidad y el dimensionamiento óptimo, fue implementada siguiendo la metodología de las Actividades 3, 4 y 5 del curso, adaptada al contexto de la venta de entradas para fútbol a través de una plataforma web.

## Plataforma Interactiva de Simulación (Frontend y Backend)

Con el fin de complementar el análisis teórico y la simulación en MATLAB, se construyó una plataforma web interactiva que permite explorar el modelo M/M/k/k en tiempo real. La solución se implementó con una API en **FastAPI** para ejecutar los cálculos y la simulación, y un dashboard en **React** con **Three.js** para visualizar de forma 3D el comportamiento del sistema. La plataforma permite al usuario ajustar parámetros en tiempo real y visualizar de forma inmediata el impacto sobre la probabilidad de

bloqueo, las curvas de Erlang y la distribución estacionaria del sistema.

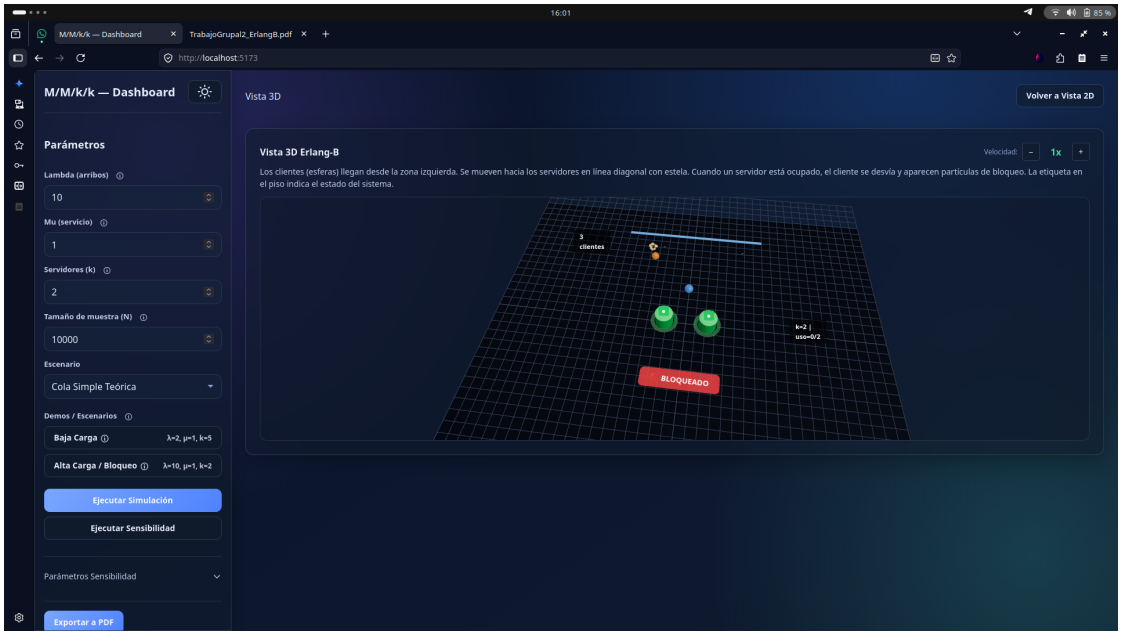



Figura 20: Pantallazo del dashboard interactivo 3D.

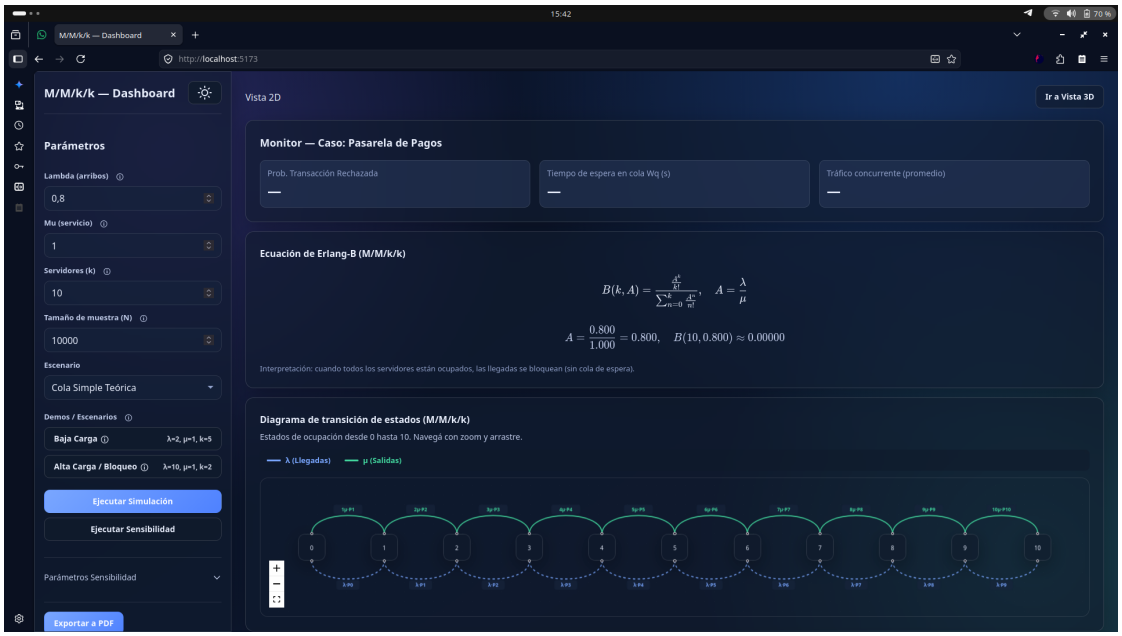



Figura 21: Resultados estadísticos y diagrama de Markov interactivo.

# Conclusiones

El modelo de Erlang B, al depender exclusivamente de la carga ofrecida $a$ y el número de servidores $k$, permite dimensionar un sistema de pérdida sin conocer la distribución completa de llegadas —siempre que el supuesto de Poisson se sostenga—. Esta simplicidad se convierte en limitación cuando el tráfico presenta correlaciones temporales: las

trazas Bellcore mostraron que, ante tráfico autosimilar, la fórmula clásica subestima el bloqueo real, lo que en entornos de producción exige márgenes de sobredimensionamiento o modelos que incorporen dependencia de largo alcance. Por otro lado, la concordancia entre la simulación de eventos discretos y la solución analítica confirma la validez del simulador implementado como herramienta para evaluar escenarios sin solución cerrada, como distribuciones de servicio arbitrarias o políticas de admisión no estándar. La analogía entre el modelo M/M/k/k y un clúster de Kubernetes sin cola interna permite trasladar la teoría de Erlang al dimensionamiento de infraestructura cloud, y la recursión de Jagerman hace viable este cálculo incluso para valores elevados de $k$, habilitando su integración en herramientas de autoescalado. Finalmente, la propiedad de insensibilidad respecto a la distribución de servicio extiende estas conclusiones a escenarios con tiempos de procesamiento no exponenciales, ampliando el rango de aplicación tanto en telecomunicaciones como en ingeniería de software.

Como trabajo futuro se plantea: (i) extender el análisis al modelo M/M/k/K con cola limitada; (ii) explorar modelos de tráfico autosimilar para el dimensionamiento de clústeres en entornos de microservicios; y (iii) incorporar el efecto del escalado dinámico en el análisis de bloqueo.

# Referencias

[1] Erlang, A. K. *Solution of Some Problems in the Theory of Probabilities of Significance in Automatic Telephone Exchanges.* Elektroteknikeren, vol. 13, 1917.

[2] Kleinrock, L. *Queueing Systems, Volume 1: Theory.* John Wiley & Sons, 1975.

[3] Jagerman, D. L. *Some Properties of the Erlang Loss Function.* Bell System Technical Journal, vol. 53, no. 3, pp. 525–551, 1974.

[4] Makkonen, L. *Problems in the Extreme Value Analysis.* Structural Safety, vol. 30, no. 5, pp. 405–419, 2008.

[5] Leland, W. E., Taqqu, M. S., Willinger, W., & Wilson, D. V. *On the Self-Similar Nature of Ethernet Traffic (Extended Version).* IEEE/ACM Transactions on Networking, vol. 2, no. 1, pp. 1–15, 1994.

[6] Bonald, T., & Proutière, A. *Insensitive Bandwidth Sharing in Data Networks.* Queueing Systems, vol. 44, no. 1, pp. 69–100, 2003.

[7] Greenberg, A., Hamilton, J., Maltz, D. A., & Patel, P. *The Cost of a Cloud: Research Problems in Data Center Networks.* ACM SIGCOMM Computer Communication Review, vol. 39, no. 1, pp. 68–73, 2008.

[8] Burns, B., Grant, B., Oppenheimer, D., Brewer, E., & Wilkes, J. *Borg, Omega, and Kubernetes*. Communications of the ACM, vol. 59, no. 5, pp. 50–57, 2016.

[9] Gross, D., Shortle, J. F., Thompson, J. M., & Harris, C. M. *Fundamentals of Queueing Theory* (4th ed.). John Wiley & Sons, 2008.

[10] Law, A. M. *Simulation Modeling and Analysis* (5th ed.). McGraw-Hill, 2015.