

Trabajo Grupal 3

LRD y Multifractales

Juan Felipe Rodríguez G. 20261595004
Carlos Stiven Mora Hoyos 20261595003
Sergio Santiago Duarte Rojas 20261595002

Curso: Herramientas Matemáticas para el Manejo de la Información

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia
27 de mayo de 2026

Índice

1. Actividad 1: Evaluación de estimadores **3**
1.1. Prueba de Sesgo . . . 3
1.2. Prueba de Consistencia . . . 5
1.3. Prueba de Eficiencia . . . 6
1.4. Prueba de Robustez . . . 7
1.5. Análisis de la Actividad 1 . . . 9

2. Actividad 2: Evaluación con Secuencias LRD **10**
2.1. Prueba de Sesgo . . . 10
2.2. Prueba de Eficiencia . . . 12
2.3. Prueba de Consistencia . . . 14
2.4. Análisis de la Actividad 2 . . . 16

3. Actividad 3: Estimación de H en la *European ST-T Database* **17**
3.1. Resultados por registro . . . 17
3.2. Distribución global . . . 19
3.3. Análisis de la Actividad 3 . . . 19

4. Actividad 4: Herramienta de clasificación mono/multifractal **20**
4.1. Diagrama de flujo . . . 20
4.2. Validación . . . 21
4.3. Análisis de la Actividad 4 . . . 22

5. Actividad 5: Clasificación fractal de la European ST-T Database **24**
5.1. Metodología . . . 24
5.1.1. Filtrado de anotaciones . . . 24
5.1.2. Cálculo de intervalos RR . . . 24
5.1.3. Clasificación . . . 25
5.1.4. Datos clínicos . . . 25
5.2. Resultados . . . 25
5.2.1. Distribución general . . . 25
5.2.2. Comparación entre grupos . . . 25
5.3. Análisis de la Actividad 5 . . . 26
5.3.1. Perfil clínico . . . 26

1. Actividad 1: Evaluación de estimadores

Se evalúan las propiedades estadísticas de los estimadores Varianza–Tiempo (`vt2`) y Log–Escala (`LD2`) sobre secuencias discretas independientes e idénticamente distribuidas. El valor teórico de referencia es $H_0 = 0.5$.

1.1. Prueba de Sesgo

Se evaluó el sesgo bajo dos escenarios: muestra pequeña ($n = 1\,000$) y muestra grande ($n = 100\,000$), con $10\,000$ realizaciones $\mathcal{N}(0,1)$ en cada caso. Los parámetros de ajuste normal obtenidos con `normfit` se consolidan en la Tabla 1.

Tabla 1: Parámetros de ajuste normal (`normfit`) para la prueba de sesgo.

n	$\hat{\mu}_{\mathrm{VT}}$	$\hat{\sigma}_{\mathrm{VT}}$	$\hat{\mu}_{\mathrm{LD}}$	$\hat{\sigma}_{\mathrm{LD}}$
$1\,000$	0.4967	0.0289	0.4982	0.0347
$100\,000$	0.4996	0.0099	0.4999	0.0063

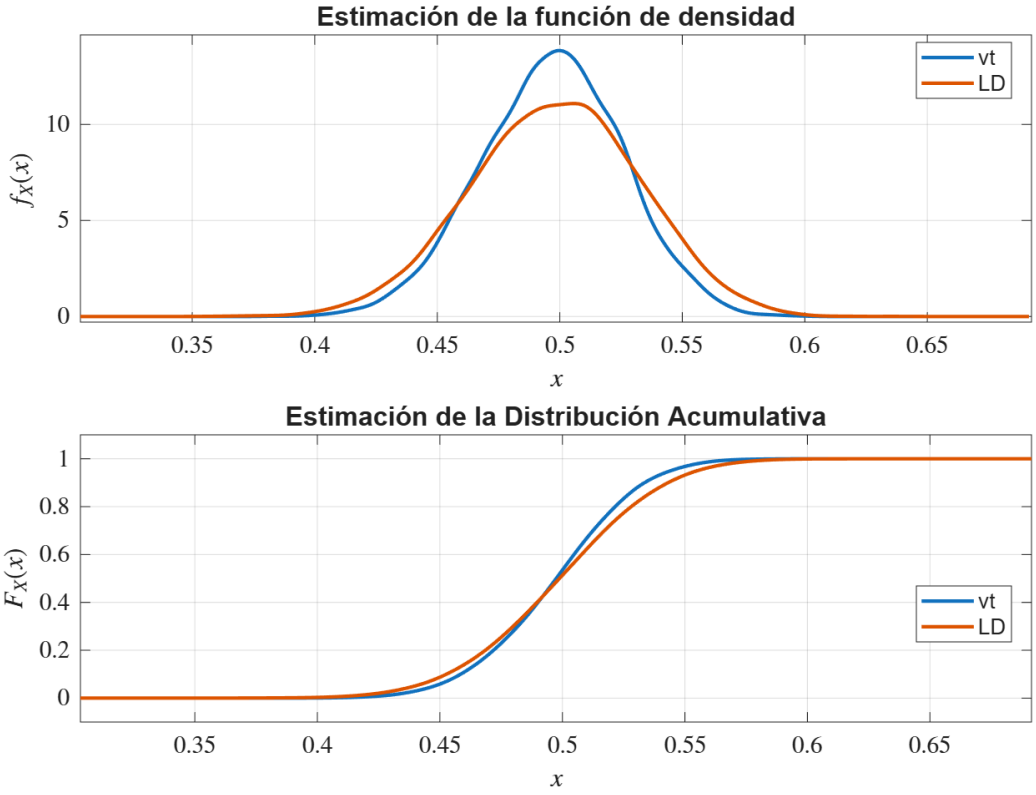


Figura 1: PDF y CDF empíricas de $\hat{H}$ para VT y LD ($n = 1\,000$, $10\,000$ repeticiones, $\mathcal{N}(0,1)$).

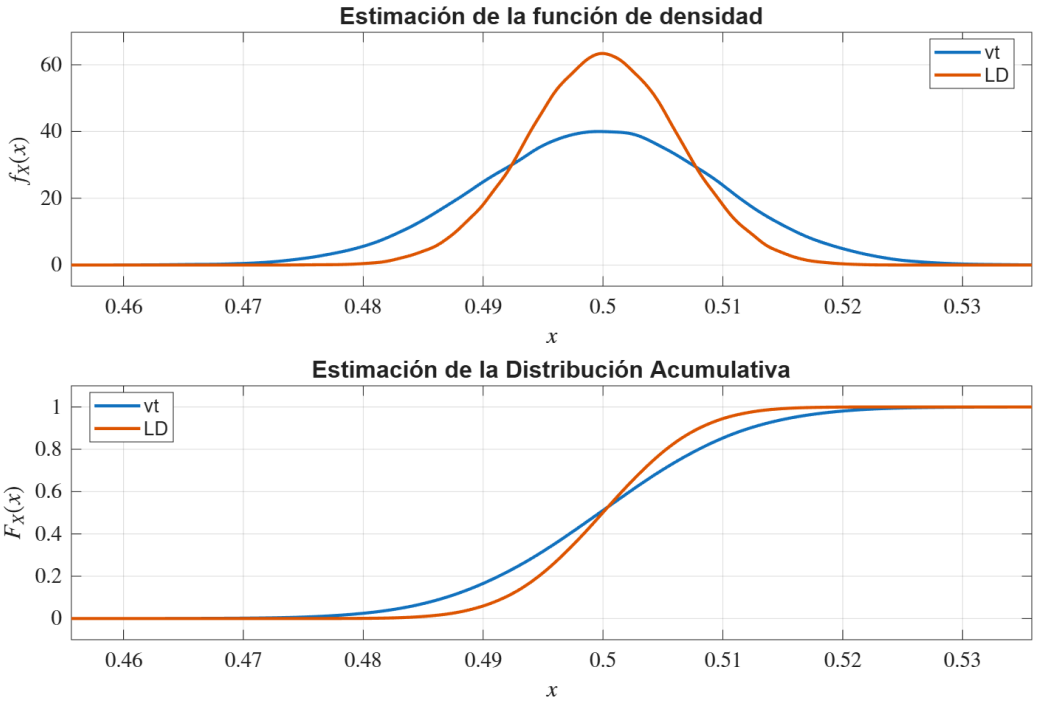


Figura 2: PDF y CDF empíricas de $\hat{H}$ para VT y LD ($n = 100\,000$, $10\,000$ repeticiones, $\mathcal{N}(0,1)$).

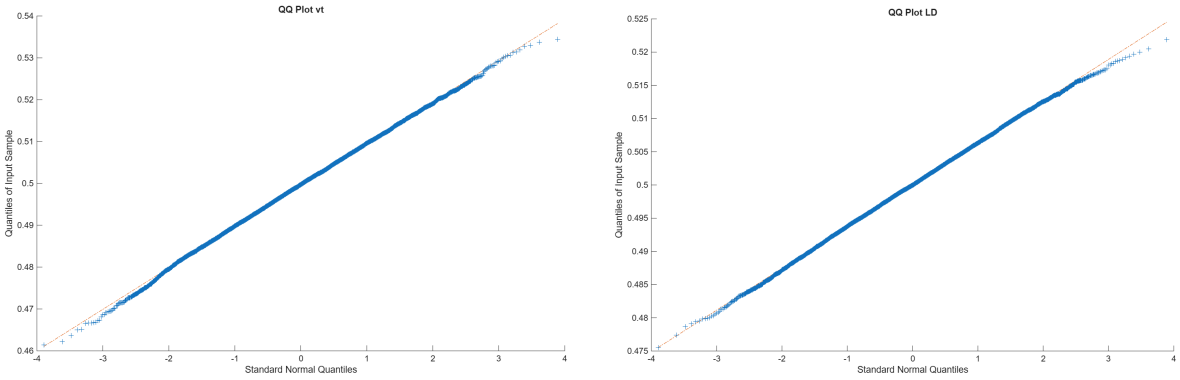


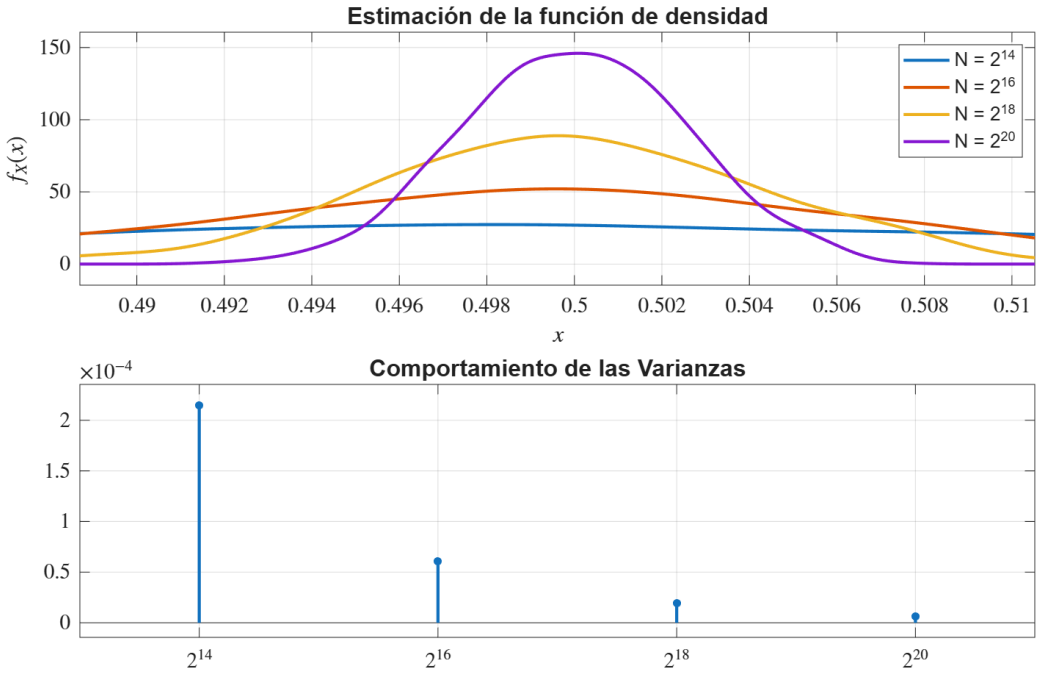
Figura 3: QQ-plots para los estimadores VT y LD con muestra de tamaño $n = 100\,000$.

Para $n = 1\,000$ (Figura 1), ambos estimadores muestran sesgo despreciable (-0.0033 para VT y -0.0018 para LD), pero las distribuciones son notablemente anchas. En este régimen VT es ligeramente más eficiente, puesto que su desviación estándar (0.0289) es un 17 % menor que la de LD (0.0347), es decir, para muestras pequeñas LD no ofrece ventaja en varianza.

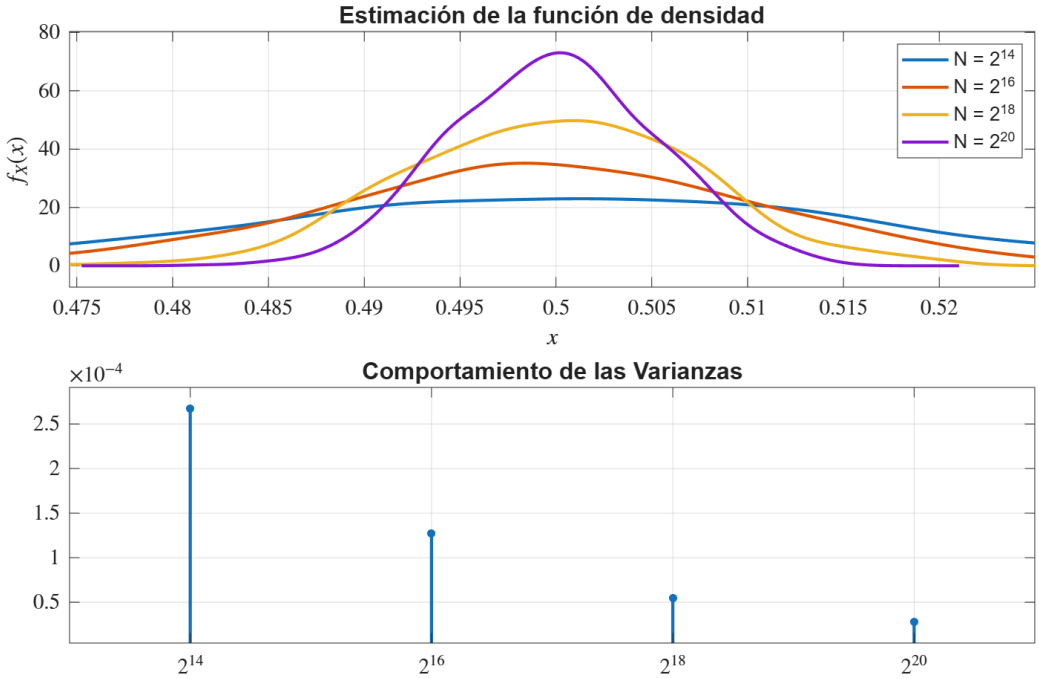
Para $n = 100\,000$ (Figura 2), ambas distribuciones se concentran fuertemente en $H_0 = 0.5$ y el sesgo permanece negligible, pero ahora LD presenta una desviación estándar un 36 % menor que VT (0.0063 vs. 0.0099). Esta inversión queda también reflejada en los QQ-plots (Figura 3), donde VT exhibe una leve desviación en las colas, mientras que LD se ajusta con mayor fidelidad a la recta de referencia para muestras grandes.

1.2. Prueba de Consistencia

Se evaluó la consistencia de cada estimador al aumentar el tamaño de muestra. Se generaron 1 000 realizaciones para cada $N \in \{2^{14}, 2^{16}, 2^{18}, 2^{20}\}$ con distribución $\mathcal{N}(0, 1)$.



(a) Estimador LD: la PDF se estrecha progresivamente.



(b) Estimador VT: convergencia más lenta.

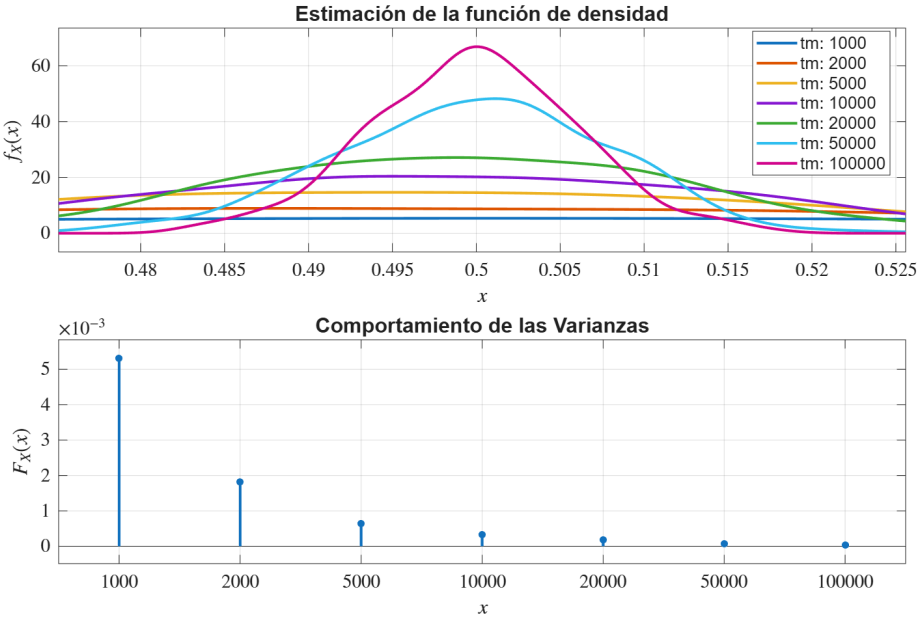
Figura 4: Consistencia de los estimadores VT y LD. Las PDFs se concentran en $H_0 = 0.5$ al crecer N, y las varianzas disminuyen.

Ambos estimadores son consistentes, esto quiere decir que las densidades se estrechan y centran en $H_0 = 0.5$ al aumentar N, y las varianzas decrecen monótonamente. LD converge más rápido,

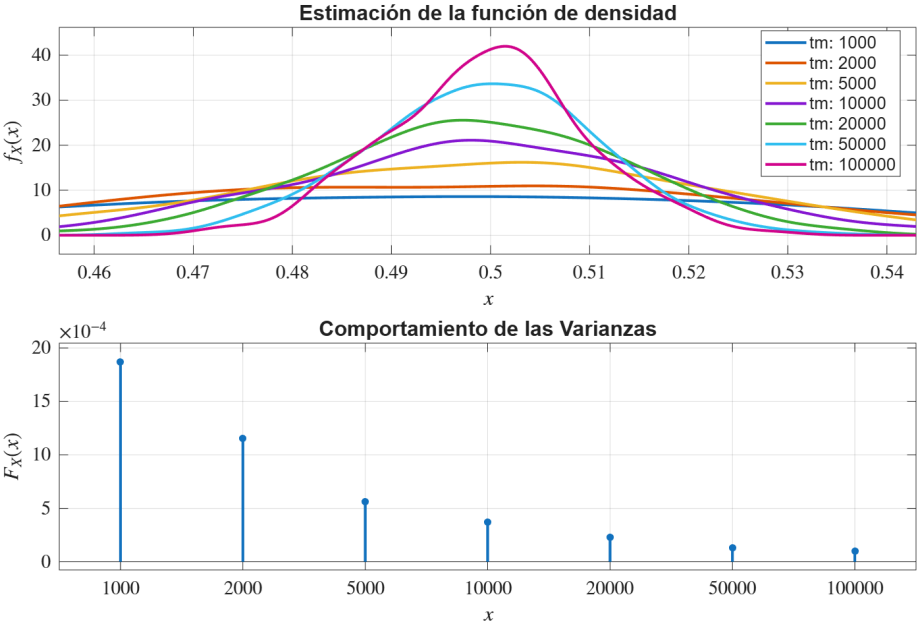
esto se da para $N = 2^{20}$ su varianza es $\approx 6.7\times10^{-5}$, frente a $\approx 2.7\times10^{-4}$ de VT, una reducción cuatro veces mayor.

1.3. Prueba de Eficiencia

La eficiencia se mide comparando la varianza de cada estimador para un mismo tamaño de muestra n. Se usaron 1 000 repeticiones para cada $n \in \{1000, 2000, 5000, 10000, 20000, 50000, 100000\}$.



(a) Estimador LD.



(b) Estimador VT.

Figura 5: PDF y comportamiento de las varianzas de VT y LD para distintos tamaños de muestra n.

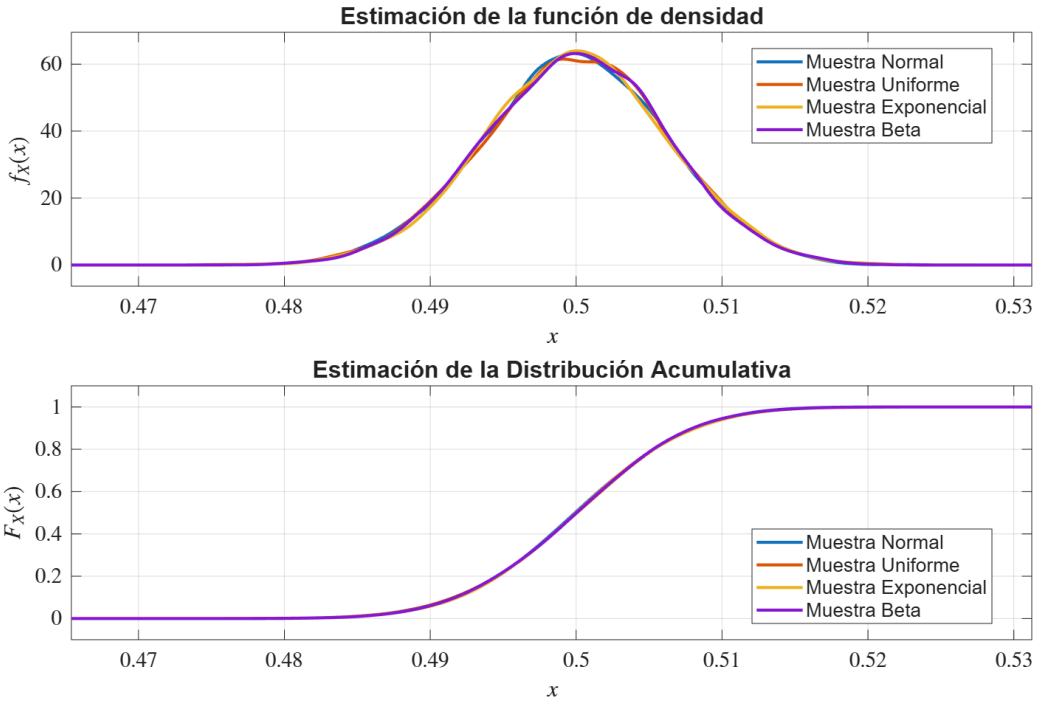
La Tabla 2 consolida las varianzas obtenidas. Para $n \leq 2\,000$, VT resulta más eficiente; a partir de $n = 5\,000$ LD supera a VT, y a $n = 100\,000$ su varianza es ≈ 2.65 veces menor.

Tabla 2: Varianza de $\hat{H}$ en función del tamaño de muestra n.

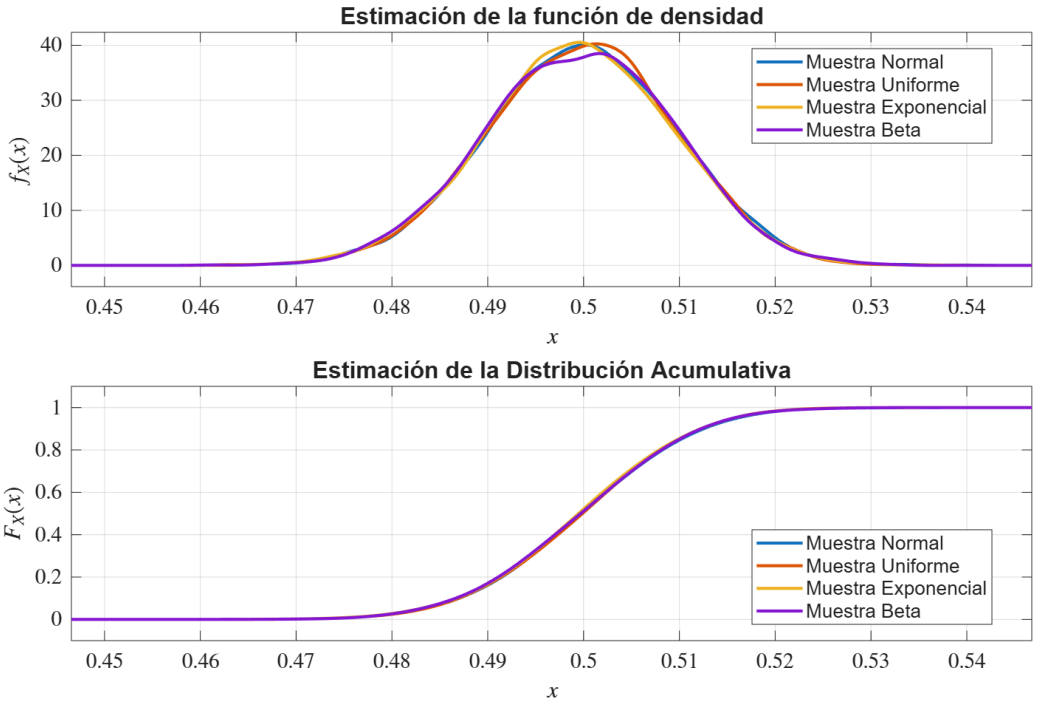
n	$\mathrm{Var}(\hat{H}_{\mathrm{VT}})$	$\mathrm{Var}(\hat{H}_{\mathrm{LD}})$
1 000	1.87×10^{-3}	5.31×10^{-3}
2 000	1.16×10^{-3}	1.82×10^{-3}
5 000	5.59×10^{-4}	6.43×10^{-4}
10 000	3.71×10^{-4}	3.27×10^{-4}
20 000	2.28×10^{-4}	1.83×10^{-4}
50 000	1.32×10^{-4}	6.76×10^{-5}
100 000	1.00×10^{-4}	3.77×10^{-5}

1.4. Prueba de Robustez

Se evaluó la sensibilidad de cada estimador ante cambios en la distribución de la secuencia de entrada, usando cuatro distribuciones: Normal $\mathcal{N}(0, 1)$, Uniforme $\mathcal{U}(0, 1)$, Exponencial Exp(1) y Beta$(2, 5)$, con $n = 100\,000$ y 1 000 repeticiones.



(a) Estimador LD: las cuatro curvas son prácticamente indistinguibles, con pico ≈ 63.



(b) Estimador VT: las cuatro curvas también se superponen, con pico ≈ 40 y ligera separación entre distribuciones.

Figura 6: Robustez de los estimadores VT y LD ante distintas distribuciones de entrada ($n = 100\,000$, $1\,000$ repeticiones).

Ambos estimadores exhiben alta robustez, esto se evidencia en las PDF y CDF para las cuatro distribuciones se superponen casi perfectamente en ambos casos, centradas en $H_0 = 0.5$. LD presenta mayor concentración (pico ≈ 63 vs. ≈ 40 de VT), lo que refleja su menor varianza independientemente de la distribución de entrada. Ninguno de los dos estimadores muestra

sensibilidad apreciable ante cambios distribucionales para muestras grandes.

1.5. Análisis de la Actividad 1

Tabla 3: Comparación de estimadores VT y LD por propiedad evaluada.

Propiedad	**VT**	**LD**	**Ganador**
Sesgo ($n < 5\,000$)	$\hat{\sigma} = 0.0289$	$\hat{\sigma} = 0.0347$	**VT**
Sesgo ($n \geq 5\,000$)	$\hat{\sigma} = 0.0099$	$\hat{\sigma} = 0.0063$	**LD**
Consistencia	Converge, varianza mayor	Converge más rápido	**LD**
Eficiencia ($n < 5\,000$)	Var menor	Var mayor	**VT**
Eficiencia ($n \geq 5\,000$)	Var $\approx 1.00 \times 10^{-4}$	Var $\approx 3.77 \times 10^{-5}$	**LD**
Robustez	Alta	Alta	**Empate**

Para muestras grandes ($n \geq 5\,000$), LD supera a VT en sesgo, consistencia y eficiencia. Para muestras pequeñas ($n < 5\,000$), VT es más eficiente y presenta menor dispersión. Ambos estimadores son igualmente robustos ante cambios en la distribución de entrada.

2. Actividad 2: Evaluación con Secuencias LRD

Se evalúan los estimadores `vt2` y `LD2` sobre secuencias sintéticas con dependencia de rango largo (LRD), generadas con `betamwm` (multifractal) y `wfbm` (monofractal), para $H \in \{0.55, 0.60, \ldots, 0.95\}$ con 1 000 repeticiones por valor de H. Las propiedades evaluadas son sesgo, eficiencia y consistencia.

2.1. Prueba de Sesgo

Para construir la Figura 7 se realizó un sondeo sistemático del sesgo por cada valor de $H \in \{0.55, 0.60, \ldots, 0.95\}$ (incrementos de 0.05, nueve puntos en total) se generaron 1 000 realizaciones independientes con cada generador y se aplicaron los estimadores `vt2` y `LD2`. El valor medio $\hat{\mu}$ de las 1 000 estimaciones se tomó como representante del estimador en ese punto y se graficó contra H real. La diagonal punteada representa el estimador ideal $\hat{H} = H$; la distancia vertical entre cada curva y la diagonal es el sesgo empírico $\hat{\mu} - H$ para ese valor de H.

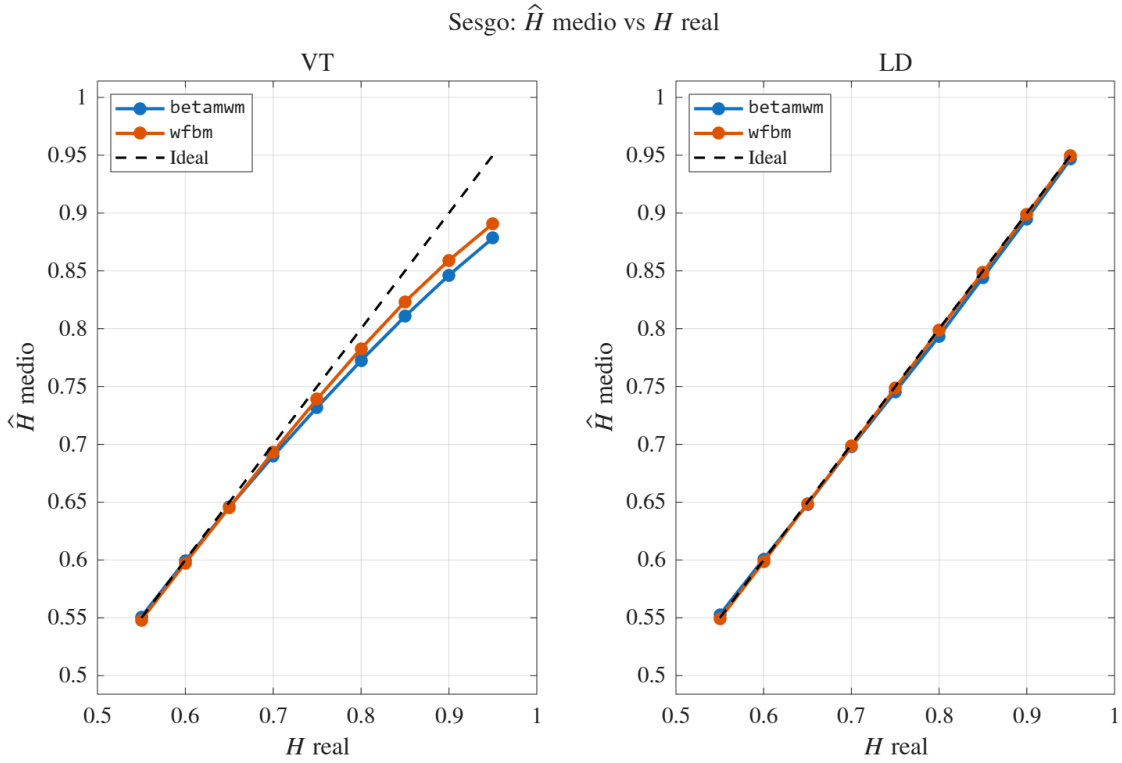


Figura 7: Sesgo de los estimadores VT y LD para `betamwm` y `wfbm` (1 000 repeticiones por valor de H).

Estimador VT. Ambos generadores producen subestimación creciente con H. Para `betamwm`, el sesgo pasa de -0.0023 en $H = 0.55$ hasta -0.0711 en $H = 0.95$; para `wfbm`, de -0.0016 a -0.0092. VT es considerablemente más sesgado con `betamwm` que con `wfbm` para valores altos de H, lo que evidencia su sensibilidad a la naturaleza multifractal del proceso.

Estimador LD. Las curvas se superponen casi perfectamente con la diagonal ideal en ambos generadores. El sesgo máximo es -0.0054 para `betamwm` ($H = 0.90$) y -0.0010 para `wfbm`

($H = 0.95$), valores despreciables en todo el rango. LD estima H con alta fidelidad independientemente del generador y del valor de H.

Tabla 4: Parámetros de ajuste normal y sesgo para el caso representativo $H = 0.9$ (1 000 repeticiones).

Generador	**Estimador**	$\hat{\mu}$	$\hat{\sigma}$	**Sesgo**
`betamwm`	VT	0.8463	0.0207	−0.0537
`wfbm`	VT	0.8592	0.0188	−0.0408
`betamwm`	LD	0.8951	0.0377	−0.0049
`wfbm`	LD	0.8989	0.0143	−0.0011

La Figura 8 presenta los QQ-plots de las 1 000 estimaciones para $H = 0.9$ en las cuatro combinaciones generadas frente al estimador.

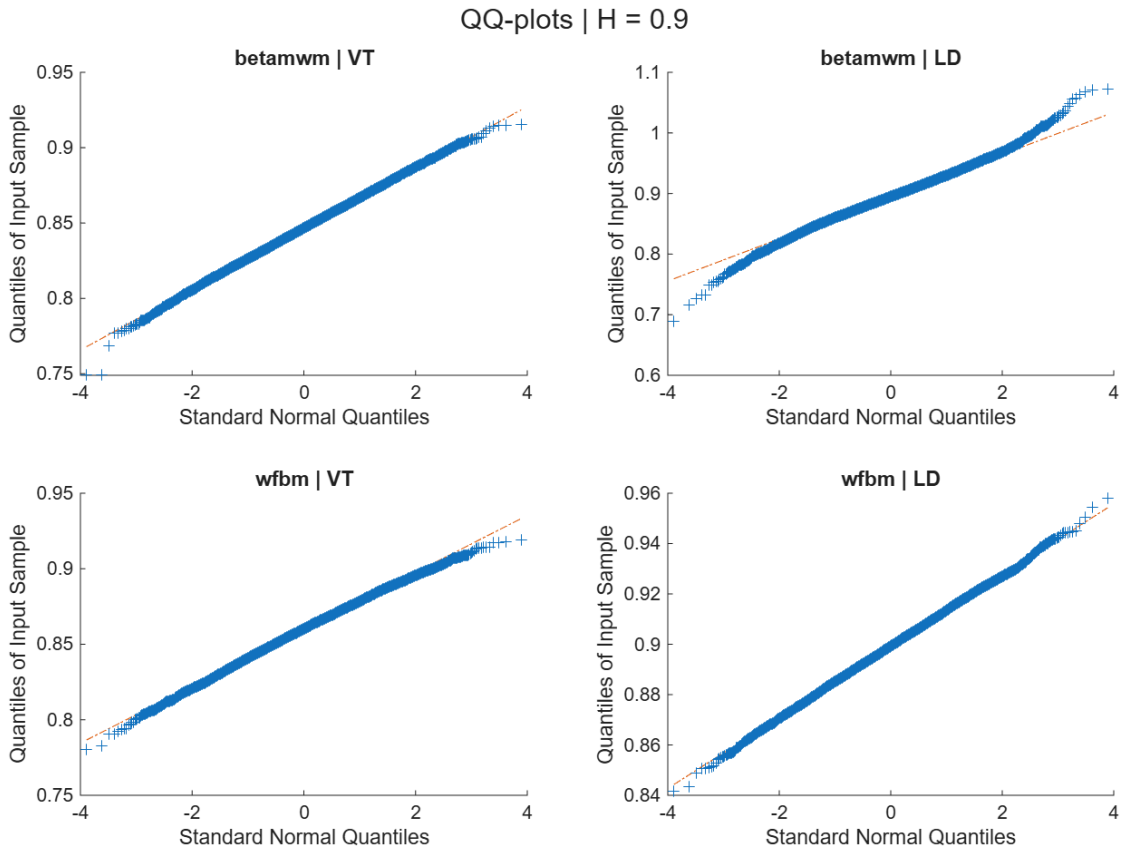


Figura 8: QQ-plots de $\hat{H}$ para $H = 0.9$ (1 000 repeticiones).

La imagen anterior confirma que las distribuciones empíricas de $\hat{H}$ siguen aproximadamente una normal. Se observan diferencias cualitativas coherentes con el análisis de sesgo:

Tabla 5: Resumen comparativo de ajuste, sesgo y dispersión para VT y LD sobre procesos multifractales y monofractales.

Proceso	**VT**	**LD**
`betamwm`	Buen ajuste en el cuerpo central con leve desviación en la cola inferior. Distribución centrada en $\hat{\mu} = 0.846$, alejada de $H = 0.9$, consistente con un sesgo de -0.054.	Mayor dispersión de los cuatro casos ($\hat{\sigma} = 0.038$), con desviación en ambas colas. La distribución permanece centrada cerca de $H = 0.9$ (sesgo de -0.005), indicando mejor exactitud aunque con mayor varianza.
`wfbm`	Buen ajuste con leve desviación en la cola superior. Distribución centrada en $\hat{\mu} = 0.859$, con sesgo de -0.041, menor que en `betamwm` pero aún apreciable.	El ajuste más fiel a la recta de referencia, con la menor dispersión ($\hat{\sigma} = 0.014$) y el menor sesgo (-0.001). Confirma que LD sobre secuencias monofractales representa el escenario más favorable.

Las Figuras 9 y 10 muestran las PDF y CDF empíricas para $H = 0.9$.

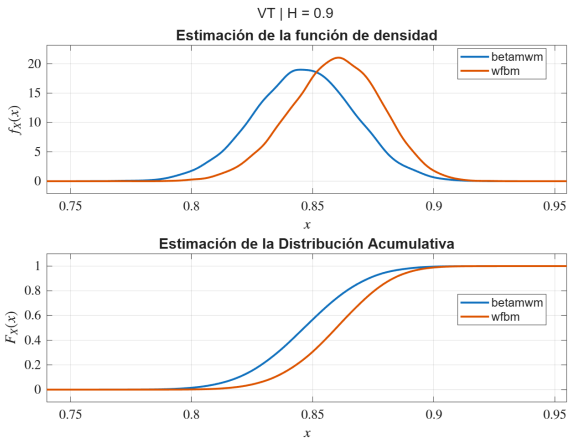


Figura 9: PDF y CDF de $\hat{H}$ con VT para $H = 0.9$.

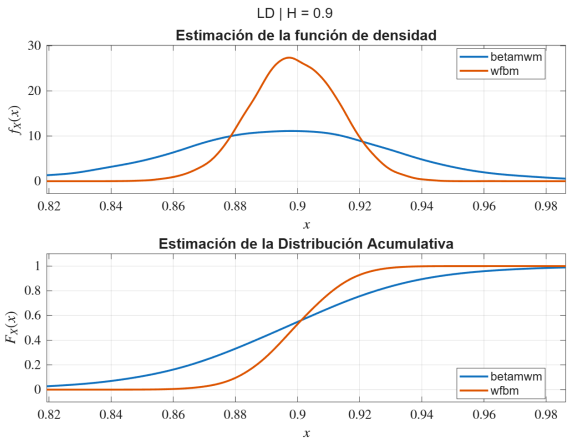


Figura 10: PDF y CDF de $\hat{H}$ con LD para $H = 0.9$.

2.2. Prueba de Eficiencia

La eficiencia se mide comparando la varianza de $\hat{H}$ entre estimadores para un mismo valor de H, esto quiere decir que el estimador con menor $\mathrm{Var}(\hat{H})$ es más eficiente. Las Figuras 11 y 12 muestran $\mathrm{Var}(\hat{H})$ en función de H real para cada combinación generador frente al estimador.

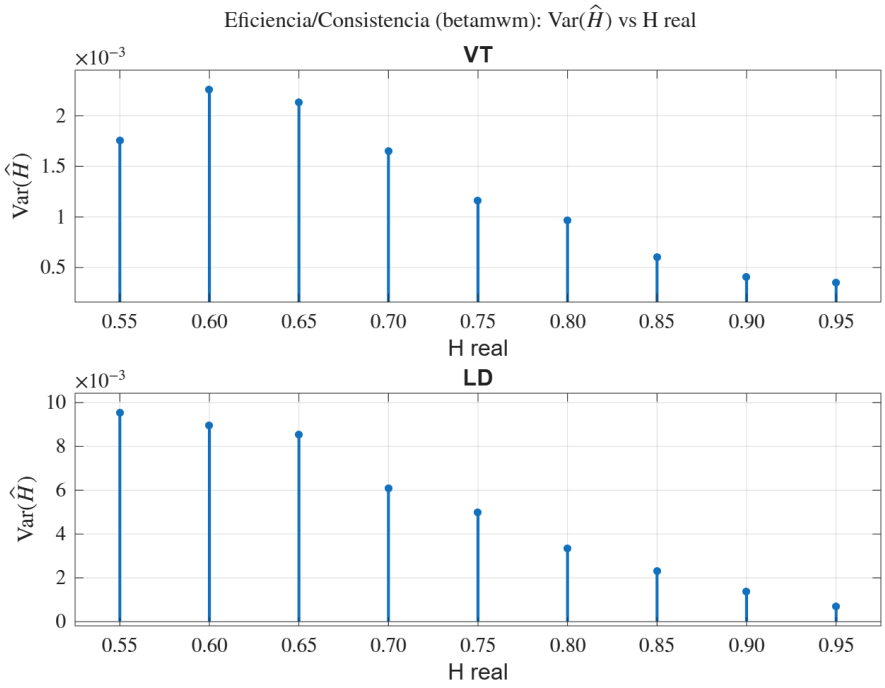


Figura 11: Varianza de $\hat{H}$ vs. H real para `betamwm`. VT (arriba) presenta varianzas del orden 10^{-3}; LD (abajo) del mismo orden pero con mayor magnitud en todo el rango de H.

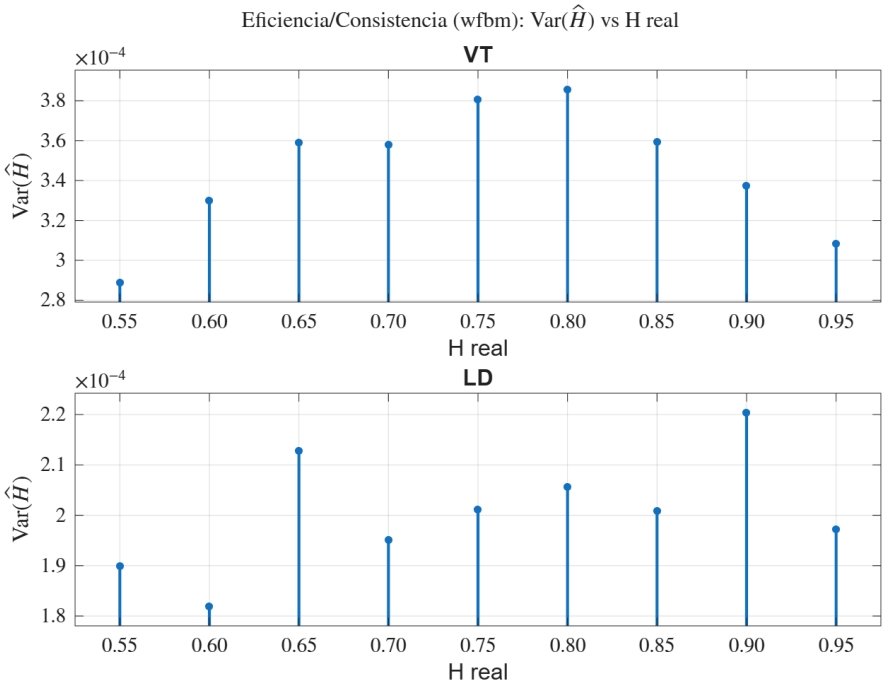


Figura 12: Varianza de $\hat{H}$ vs. H real para `wfbm`. VT (arriba) muestra varianzas del orden 10^{-4}; LD (abajo) mantiene varianza menor y más estable en todo el rango.

`betamwm` **(Figura 11). VT es más eficiente que LD en todo el rango de** H: su varianza se mantiene por debajo de 2.25×10^{-3}, mientras que la de LD supera los 9×10^{-3} para H bajo.

`wfbm` **(Figura 12). LD es más eficiente en todo el rango**: la varianza presentada es

estable alrededor de 2×10^{-4}, mientras que VT fluctúa entre 2.9×10^{-4} y 3.85×10^{-4}.

2.3. Prueba de Consistencia

La consistencia se evalúa fijando H y aumentando el tamaño de muestra $N \in \{2^{10}, 2^{12}, 2^{14}, 2^{16}\}$: un estimador consistente debe mostrar $\mathrm{Var}(\hat{H}) \to 0$ al crecer N, para todo valor de H en el intervalo evaluado. Lo cual se refleja en las Figuras 13 y 14 por la tendencia decreciente de las curvas, además es contrastado en la Tabla 6.

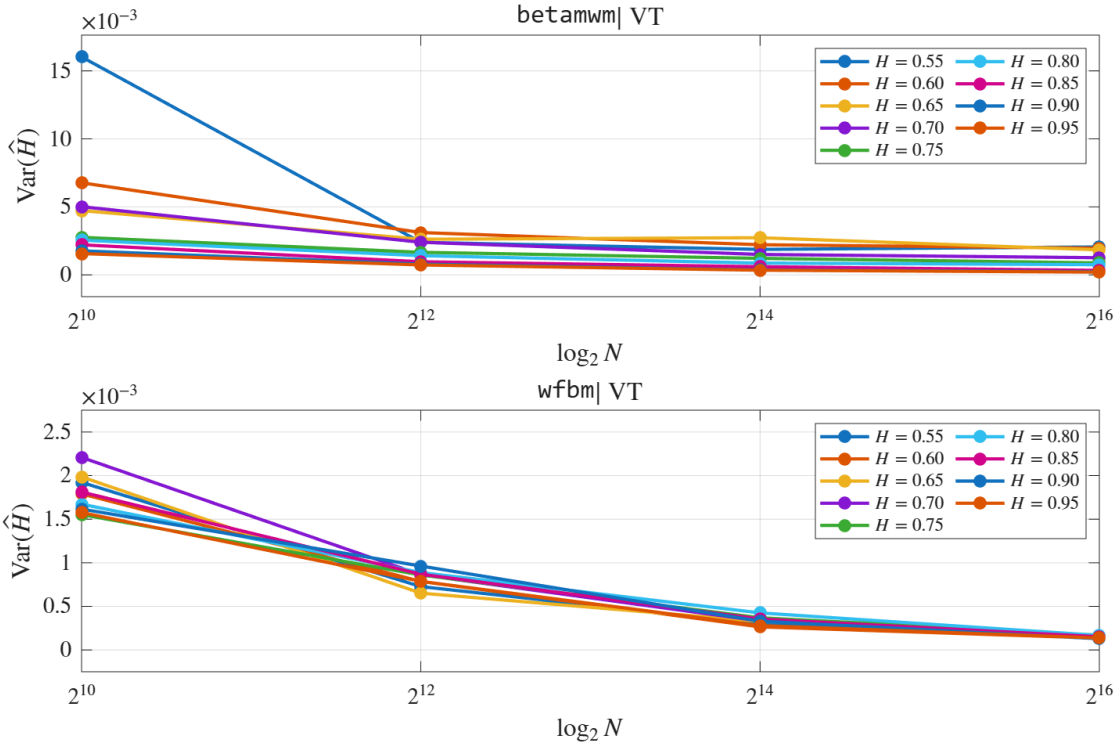


Figura 13: Consistencia del estimador VT: $\mathrm{Var}(\hat{H})$ vs. N para `betamwm` (arriba) y `wfbm` (abajo), con $H \in [0.55, 0.95]$ (300 repeticiones por punto).

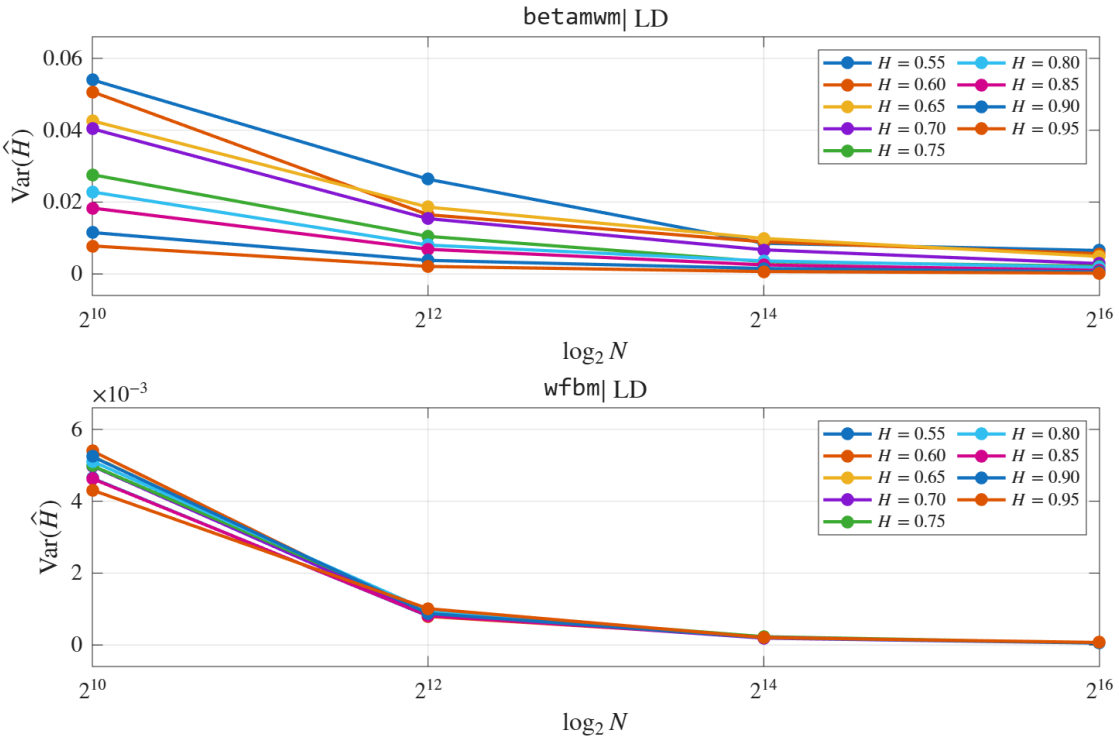


Figura 14: Consistencia del estimador LD: $\mathrm{Var}(\hat{H})$ vs. N para `betamwm` (arriba) y `wfbm` (abajo), con $H \in [0.55, 0.95]$ (300 repeticiones por punto).

Tabla 6: Consistencia y convergencia de VT y LD sobre `betamwm` y `wfbm`.

Estimador	**Proceso**	**Comportamiento observado**	**Consistencia**
VT	`betamwm`	Para $H = 0.55$, la varianza cae de 1.60×10^{-2} a 2.39×10^{-3}, pero luego se estabiliza alrededor de 2×10^{-3} sin seguir decreciendo. Para $H \geq 0.70$ la reducción es monótona, aunque lenta.	No consistente para H bajo
VT	`wfbm`	Las curvas decrecen de forma ordenada y monótona desde $\approx 2 \times 10^{-3}$ hasta $\approx 1.5 \times 10^{-4}$, sin excepciones en el rango evaluado.	Consistente
LD	`betamwm`	La varianza decrece en todos los casos, aunque con magnitudes mayores que VT. Para $H = 0.55$ pasa de 5.40×10^{-2} a 6.52×10^{-3} en $N = 2^{16}$.	Consistente, convergencia lenta
LD	`wfbm`	Las curvas se superponen casi perfectamente y descienden desde $\approx 5 \times 10^{-3}$ hasta $\approx 5 \times 10^{-5}$, mostrando reducción de dos órdenes de magnitud.	Altamente consistente

2.4. Análisis de la Actividad 2

Tabla 7: Comparación de estimadores VT y LD por propiedad y generador.

Propiedad	**Generador**	**VT**	**LD**	**Ganador**
Sesgo	`betamwm`	Hasta -0.071	Hasta -0.005	**LD**
Sesgo	`wfbm`	Hasta -0.009	Hasta -0.001	**LD**
Eficiencia	`betamwm`	$\hat{\sigma}^2$ menor	$\hat{\sigma}^2$ mayor	**VT**
Eficiencia	`wfbm`	$\hat{\sigma}^2$ mayor	$\hat{\sigma}^2$ menor	**LD**
Consistencia	`betamwm`	Inconsistente (H bajo)	Consistente, lenta	**LD**
Consistencia	`wfbm`	Consistente	Altamente consistente	**LD**

3. Actividad 3: Estimación de H en la *European ST-T Database*

Se estimó el parámetro de Hurst de la frecuencia cardíaca instantánea (convertida a BPM desde los intervalos RR) de los 90 registros de la *European ST-T Database*, aplicando los estimadores VT y LD.

3.1. Resultados por registro

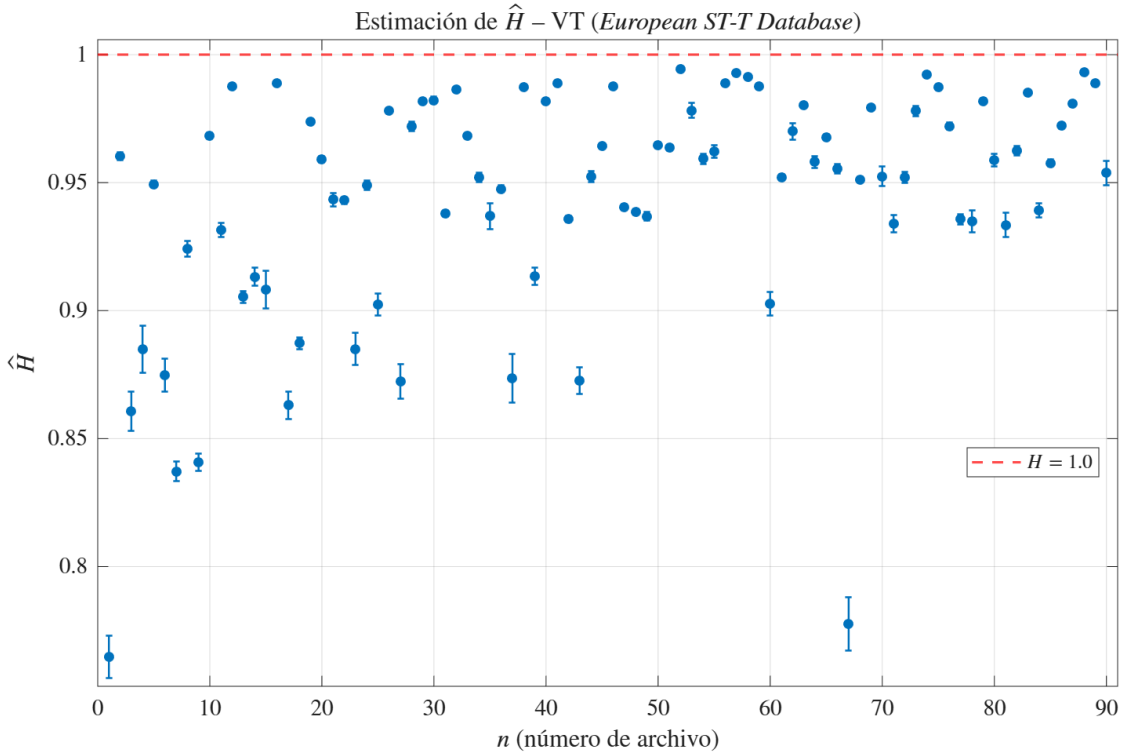


Figura 15: Estimación de $\hat{H}$ con VT para los 90 registros, con intervalos de confianza $[H_{\text{mín}}, H_{\text{máx}}]$.

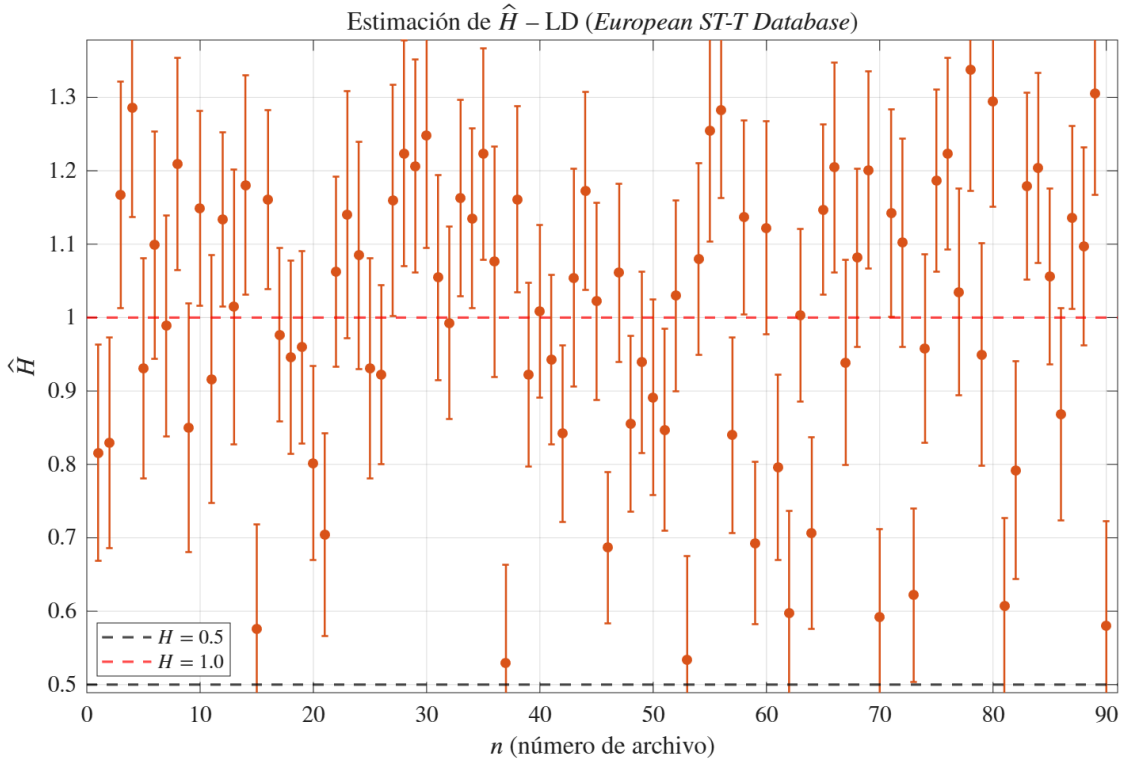


Figura 16: Estimación de $\hat{H}$ con LD para los 90 registros, con intervalos de confianza $[H_{\text{mín}}, H_{\text{máx}}]$.

Estimador VT (Figura 15). Las estimaciones se concentran en el rango [0.77, 0.99], con la mayoría de los registros entre 0.93 y 0.98. Los intervalos de confianza son estrechos y homogéneos entre registros, lo que se traduce en estimaciones estables y reproducibles. Dos registros ($n = 1$ y $n = 68$) presentan $\hat{H} \approx 0.77$, alejándose del comportamiento general. Ninguna estimación supera $H = 1.0$.

Estimador LD (Figura 16). Las estimaciones son notablemente más dispersas, puesto que el rango cubre desde ≈ 0.53 hasta ≈ 1.29. Una fracción considerable de registros presenta $\hat{H} > 1.0$, valor que no tiene interpretación física válida para un proceso estacionario. Los intervalos de confianza son amplios e inconsistentes entre registros, con algunos casos cubriendo casi 0.7 unidades de H.

3.2. Distribución global

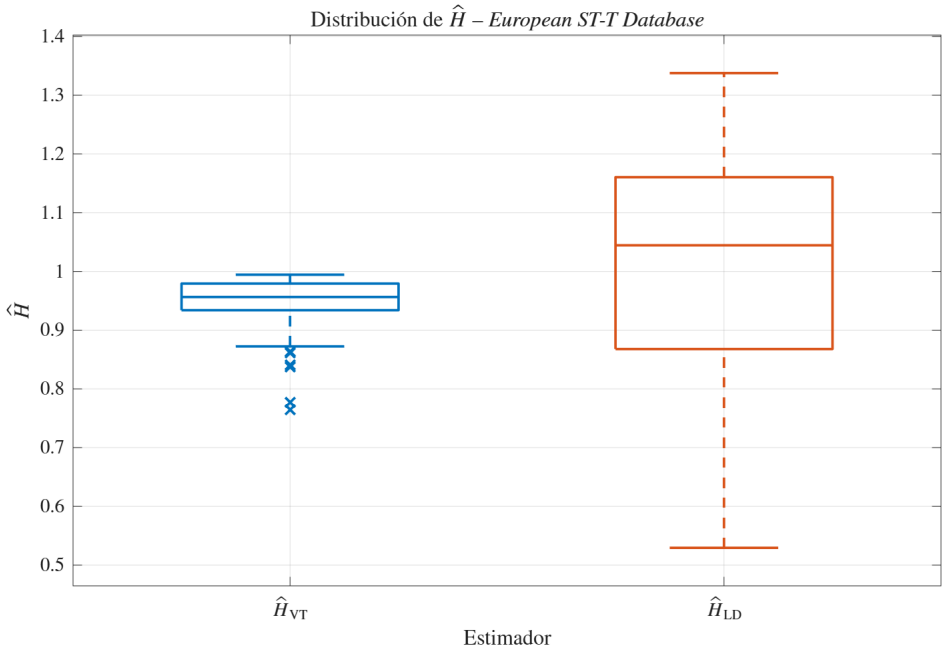


Figura 17: Distribución de $\hat{H}$ para los 90 registros, VT (azul) y LD (naranja).

La Figura 17 resume las diferencias entre estimadores. En el diagrama de caja y bigotes, el bigote superior representa el valor máximo no atípico, es decir, el dato más alto que no supera $Q_3 + 1.5 \cdot \text{IQR}$; el bigote inferior representa el valor mínimo no atípico, definido como el dato más bajo que no cae por debajo de $Q_1 - 1.5 \cdot \text{IQR}$. Los puntos fuera de estos límites se clasifican como valores atípicos y se marcan individualmente.

VT produce una distribución compacta, contando con una mediana ≈ 0.96, $Q_1 \approx 0.95$, $Q_3 \approx 0.97$, con un rango intercuartílico de apenas 0.02. El bigote superior llega a ≈ 1.00 y el inferior a ≈ 0.87, con tres valores atípicos por debajo (≈ 0.86, 0.84 y 0.77), que corresponden a registros con dinámica cardíaca particularmente distinta al resto de la base de datos.

LD presenta mediana ≈ 1.05, $Q_1 \approx 0.88$, $Q_3 \approx 1.16$, con un rango intercuartílico casi quince veces mayor que el de VT. El bigote superior alcanza ≈ 1.34 y el inferior ≈ 0.53, sin valores atípicos detectados. Esto no es una señal favorable: significa que la dispersión es tan elevada que incluso los valores extremos quedan absorbidos dentro de los límites estadísticos del diagrama. En VT, los atípicos son registros genuinamente distintos al resto; en LD, la ausencia de atípicos refleja que la varianza intrínseca del estimador es tan alta que no permite distinguir comportamientos excepcionales.

3.3. Análisis de la Actividad 3

Ambos estimadores detectan LRD fuerte ($\hat{H} > 0.5$), pero difieren en precisión. Con registros de 1 000–5 000 intervalos RR (tiempo entre latidos consecutivos en el ECG), VT supera a LD en varianza (LD solo gana eficiencia para $n \geq 5\,000$). Aunque VT subestima H para valores cercanos a 0.9–0.95, produce estimaciones físicamente válidas ($\hat{H} < 1.0$) en todos los registros.

LD genera valores $\hat{H} > 1.0$ en varios casos, sin interpretación física válida, reflejo de su alta varianza en regímenes de alta LRD con muestras moderadas. En conclusión, VT ofrece mayor confiabilidad para esta base de datos ($\hat{H}_{\mathrm{VT}} \approx 0.96$), mientras que los resultados de LD deben interpretarse con cautela.

4. Actividad 4: Herramienta de clasificación mono/multifractal

Se desarrolla una herramienta en MATLAB que, dada una secuencia discreta, determina si es monofractal o multifractal. El algoritmo opera en dos etapas basadas en el R^2 del ajuste lineal:

1. **Verificación de LRD** ($R^2_{\mathrm{VT}} \geq 0{,}85$): se ajusta una recta al diagrama varianza–tiempo. Si el ajuste es pobre, la muestra se descarta como *no clasificable*.
2. **Clasificación fractal** ($R^2_{\tau} \geq 0{,}95$): se obtienen los exponentes de escala $\tau(q)$ con `dwtleader`. Si $\tau(q)$ es lineal, la muestra es monofractal; si presenta curvatura, es multifractal.

4.1. Diagrama de flujo

La Figura 18 presenta el algoritmo implementado.

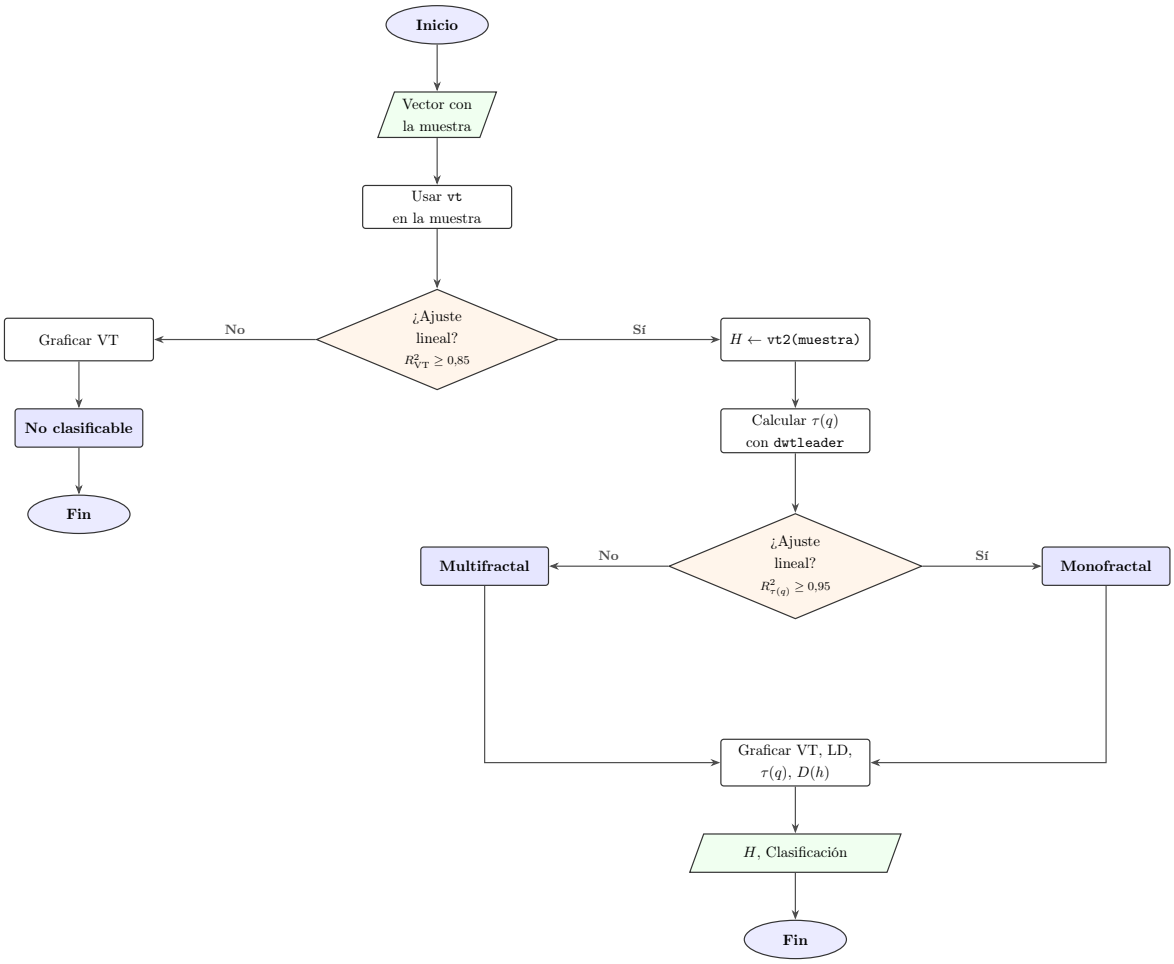


Figura 18: Diagrama de flujo del clasificador mono/multifractal.

4.2. Validación

Se generan muestras de 2^{17} datos con `wfbm` (monofractal) y `betamwm` (multifractal) para validar la herramienta. Las Figuras 19 y 20 muestran los resultados para $H = 0{,}8$.

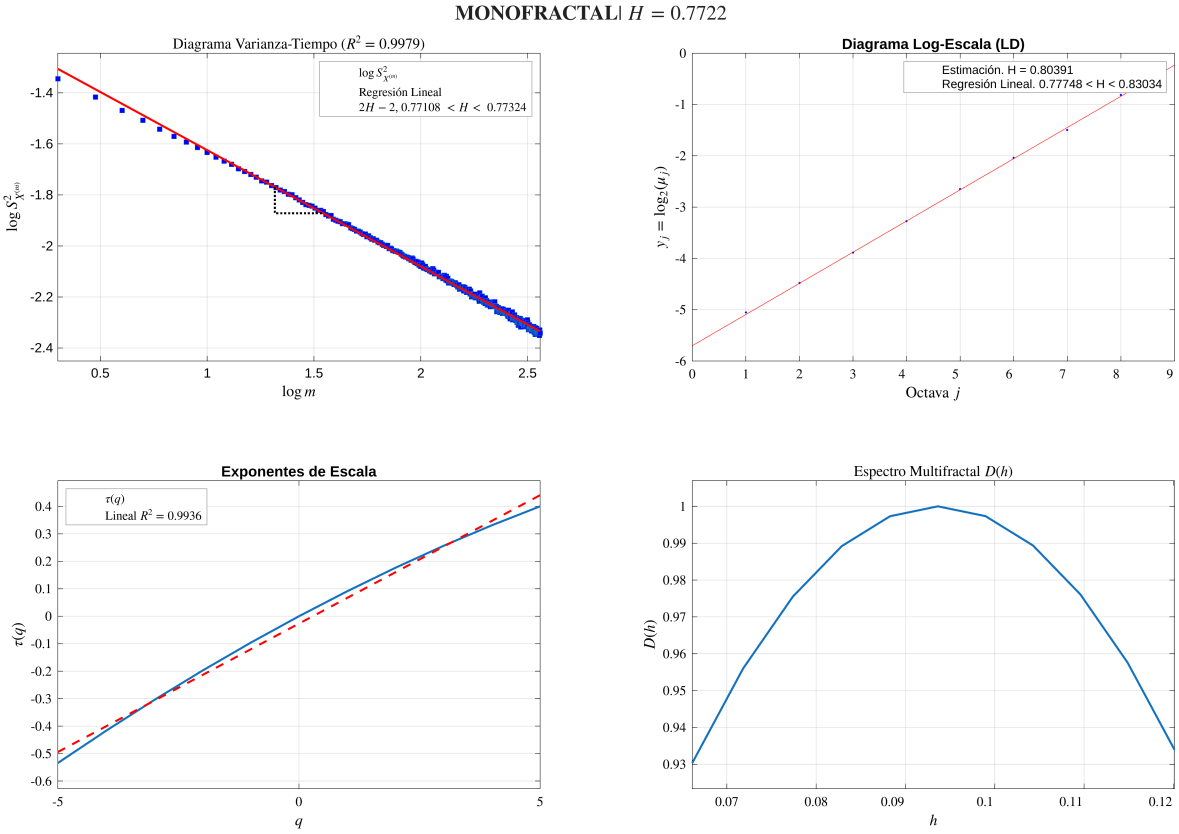


Figura 19: Muestra monofractal (`wfbm`, $H = 0{,}8$): $\tau(q)$ es lineal ($R^2_\tau = 0{,}9936$) y $D(h)$ se concentra en un rango estrecho.

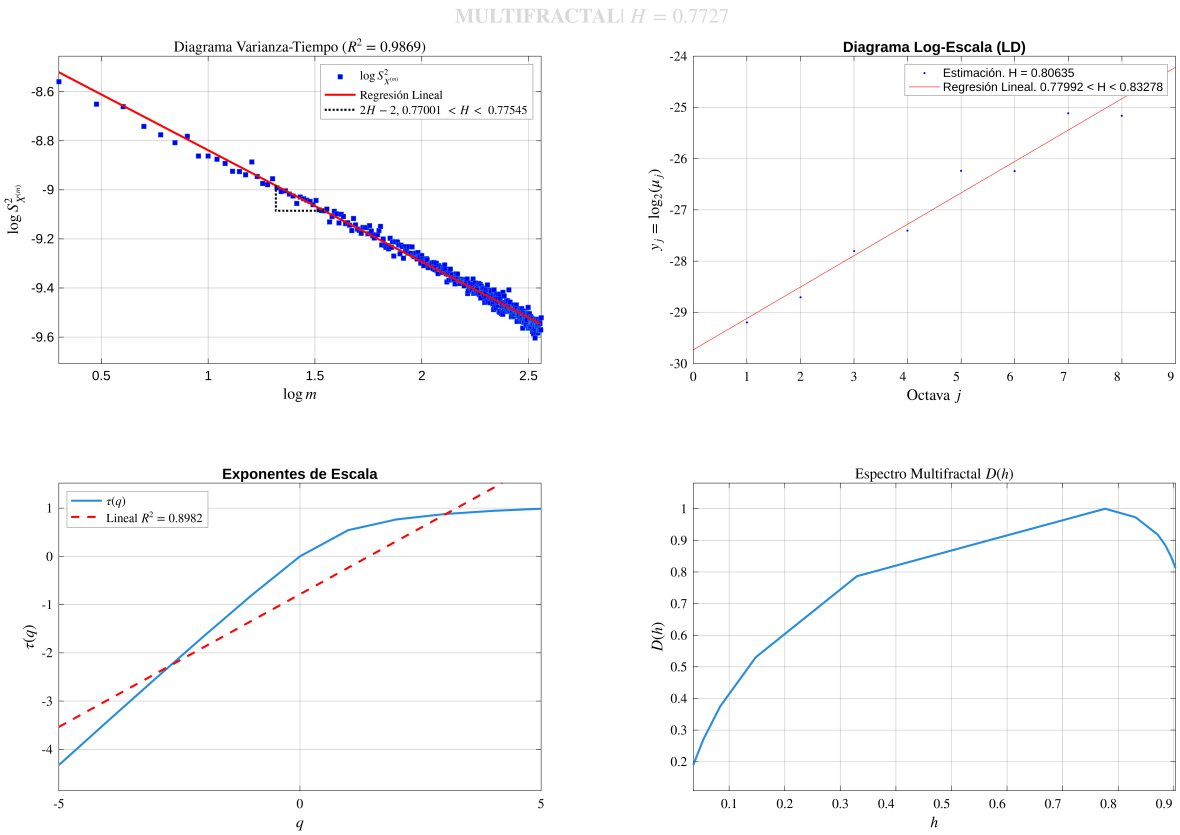


Figura 20: Muestra multifractal (`betamwm`, $H = 0{,}8$): $\tau(q)$ presenta curvatura ($R^2_\tau = 0{,}8982$) y $D(h)$ tiene forma de campana.

La Tabla 8 presenta el barrido completo. La columna $R^2_{\tau(q)}$ permite ver directamente por qué el clasificador toma cada decisión, dado que los valores cercanos a 1 indican linealidad (monofractal), mientras que valores por debajo de 0,95 revelan curvatura (multifractal).

Tabla 8: Validación del clasificador con distintos valores de H.

Generador	**Tipo real**	H	$\hat{H}$	$R^2_{\tau(q)}$	**Clasificación**
`wfbm`	monofractal	0,6	0,5838	0,9922	monofractal
`wfbm`	monofractal	0,7	0,6919	0,9928	monofractal
`wfbm`	monofractal	0,8	0,7836	0,9930	monofractal
`wfbm`	monofractal	0,9	0,8622	0,9934	monofractal
`betamwm`	multifractal	0,6	0,5482	0,8591	multifractal
`betamwm`	multifractal	0,7	0,6827	0,6661	multifractal
`betamwm`	multifractal	0,8	0,7810	0,9015	multifractal
`betamwm`	multifractal	0,9	0,8693	0,8749	multifractal

4.3. Análisis de la Actividad 4

La herramienta clasifica correctamente las 8 muestras evaluadas. Las muestras generadas con `wfbm` presentan R^2_τ consistentemente superior a 0,99, lo que confirma la linealidad de $\tau(q)$

propia de un proceso monofractal. En contraste, las muestras de `betamwm` exhiben R^2_τ entre 0,67 y 0,90, reflejando la curvatura esperada en un proceso multifractal. El umbral $R^2_\tau = 0{,}95$ se ubica en el centro de ambas mestras, maximizando el margen de separación.

Se ejecutaron 50 iteraciones independientes por cada combinación de generador y H. La Tabla 9 resume los resultados.

Tabla 9: Robustez del clasificador: 50 iteraciones por caso ($N = 2^{17}$).

Generador	**Tipo real**	H	**Aciertos**	$\overline{R^2_\tau}$	$\sigma_{R^2_\tau}$
`wfbm`	monofractal	0,6	50/50	0,9929	0,0013
`wfbm`	monofractal	0,7	50/50	0,9935	0,0014
`wfbm`	monofractal	0,8	50/50	0,9937	0,0013
`wfbm`	monofractal	0,9	50/50	0,9932	0,0010
`betamwm`	multifractal	0,6	50/50	0,7769	0,2361
`betamwm`	multifractal	0,7	50/50	0,8403	0,1314
`betamwm`	multifractal	0,8	50/50	0,8342	0,0777
`betamwm`	multifractal	0,9	50/50	0,8500	0,0245

Con 400 clasificaciones en total, la herramienta alcanza un 100 % de precisión. Las muestras monofractales mantienen $R^2_\tau > 0{,}99$ con desviación estándar del orden de 10^{-3}, mientras que las multifractales se mantienen por debajo de 0,90 en todos los casos. Esto confirma que el umbral 0,95 está bien posicionado y que la separación entre muestras es robusta frente a la variabilidad estocástica de los generadores.

5. Actividad 5: Clasificación fractal de la European ST-T Database

Se aplica el clasificador de la Actividad 4 a los intervalos RR de los 90 registros de la European ST-T Database. Cada registro contiene dos horas de ECG (electrocardiograma) ambulatorio a 250 Hz con anotaciones latido a latido realizadas por cardiólogos.

5.1. Metodología

5.1.1. Filtrado de anotaciones

Los archivos `.atr` almacenan la posición en muestras de cada evento detectado. No todas las anotaciones corresponden a latidos: la Tabla 10 resume los tipos encontrados.

Tabla 10: Tipos de anotación encontrados en los 90 registros.

Código	Significado	Total	¿Latido?
`N`	Latido normal	784 633	Sí
`V`	Contracción ventricular prematura	4 467	Sí
`S`	Latido supraventricular prematuro	1 093	Sí
`F`	Fusión de latido ventricular y normal	354	Sí
`Q`	Latido no clasificable	11	Sí
`n`	Escape supraventricular	5	Sí
`J`	Latido nodal	1	Sí
`a`	Latido auricular prematuro aberrante	1	Sí
`~`	Ruido o artefacto en la señal	8 918	No
`s`	Cambio en segmento ST	1 100	No
`+`	Cambio de ritmo	765	No
`"`	Comentario del anotador	122	No
`|`	Artefacto aislado tipo QRS	78	No

Se conservan únicamente las anotaciones de tipo latido. Sin este filtrado, `diff` calcula diferencias entre posiciones de latidos y marcadores de ruido o ritmo, generando intervalos que no representan ciclos cardíacos reales.

5.1.2. Cálculo de intervalos RR

Las anotaciones son posiciones en muestras con $f_s = 250$ Hz. El intervalo RR entre dos latidos consecutivos es:

$$\mathrm{RR}_k = \frac{n_{k+1} - n_k}{f_s} \tag{1}$$

donde n_k es la posición del k-ésimo latido en muestras.

Se descartaron intervalos fuera del rango [0,3 s, 2,0 s], siguiendo los umbrales de Karlsson et al. [9] para filtrado de artefactos en registros Holter. Valores fuera de este rango corresponden a doble detección o latidos perdidos, no a ciclos cardíacos reales. El filtro preserva la dinámica cardíaca y elimina valores erróneos que corromperían la estructura de correlación, en línea con las recomendaciones del Task Force de la ESC/NASPE [8].

5.1.3. Clasificación

Cada serie RR se procesó con el clasificador de la Actividad 4 con umbrales $R^2_{\mathrm{VT}} \geq 0{,}85$ y $R^2_{\tau} \geq 0{,}95$. Se estimó H con los estimadores Varianza–Tiempo y Log–Escala, incluyendo intervalos de confianza al 95 % para VT.

5.1.4. Datos clínicos

De los archivos `.hea` se extrajeron edad, sexo, diagnóstico, número de vasos coronarios afectados, presencia de infarto de miocardio e hipertensión arterial.

5.2. Resultados

5.2.1. Distribución general

De los 90 registros, 22 se clasificaron como monofractales, 63 como multifractales y 5 como no clasificables por no superar el umbral VT. La Tabla 11 consolida las métricas.

Tabla 11: Estadísticas de los estimadores y R^2 sobre los 90 registros (R^2_{τ} sobre los 85 clasificables).

Métrica	$\bar{x}$	σ	**Mín.**	**Máx.**
$\hat{H}_{\mathrm{VT}}$	0,9508	0,0402	0,8012	0,9951
$\hat{H}_{\mathrm{LD}}$	1,0719	0,1592	0,5970	1,3060
R^2_{VT}	0,9494	0,0602	0,6040	0,9930
$R^2_{\tau(q)}$	0,9132	0,0877	0,2910	0,9920
Latidos por registro	8 782	1 870	4 478	14 969

Todos los registros presentan $\hat{H}_{\mathrm{VT}} > 0{,}80$, confirmando dependencia de largo alcance en las series RR.

5.2.2. Comparación entre grupos

La Tabla 12 contrasta los dos grupos clasificables.

Tabla 12: Comparación entre pacientes monofractales y multifractales.

	Monofractal ($N = 22$)	**Multifractal** ($N = 63$)
$\hat{H}_{\mathrm{VT}}$	$0{,}941 \pm 0{,}037$	$0{,}951 \pm 0{,}041$
$\hat{H}_{\mathrm{LD}}$	$1{,}145 \pm 0{,}117$	$1{,}054 \pm 0{,}147$
$\overline{R_\tau^2}$	$0{,}971 \pm 0{,}014$	$0{,}893 \pm 0{,}094$
Edad	$53{,}5 \pm 11{,}0$ años	$53{,}8 \pm 10{,}8$ años
Sexo	22 M / 0 F	54 M / 8 F
Con IAM	7	21
Con HTA	0	11
Coronarias normales	4	4
Enfermedad de 1 vaso	7	17
Enfermedad de 2 vasos	3	7
Enfermedad de 3 vasos	2	14
No reportado	6	21

5.3. Análisis de la Actividad 5

Los archivos `.hea` reportan 81 hombres, 8 mujeres y 1 registro sin dato de sexo, con edad promedio $54{,}3 \pm 10{,}9$ años. De los 90 pacientes, 30 tienen antecedente de infarto de miocardio, 12 presentan hipertensión arterial y 59 cuentan con información de vasos coronarios afectados (7 normales, 24 de 1 vaso, 11 de 2 vasos y 17 de 3 vasos).

5.3.1. Perfil clínico

La Tabla 12 revela asociaciones clínicas que refuerzan la validez del clasificador.

Sexo. Los 22 monofractales son hombres. Las 8 mujeres de la base se clasificaron como multifractales sin excepción. La muestra es pequeña — solo el 8,9 % son mujeres — pero la separación es total. Diferencias en el tono parasimpático basal y la modulación hormonal del barorreflejo podrían manifestarse como mayor complejidad multiescala en los intervalos RR.

Hipertensión arterial. Ningún monofractal presenta HTA. De los 12 hipertensos de la base, 11 son multifractales y el restante no fue clasificable; ninguno es monofractal. La HTA incrementa la rigidez arterial y altera el barorreflejo, modificando la regulación cardíaca en múltiples escalas temporales. El clasificador captura esta alteración como multifractalidad.

Enfermedad coronaria. El grupo multifractal concentra 14 de los 16 pacientes con enfermedad de 3 vasos. La proporción de multifractales crece con el número de vasos afectados:

70,8 % en 1 vaso, 70,0 % en 2 vasos y 87,5 % en 3 vasos. A mayor extensión del daño coronario, mayor probabilidad de estructura multifractal.

Infarto de miocardio. El IAM tiene prevalencia similar en ambos grupos: 31,8 % en mono y 33,3 % en multi. A diferencia de la HTA y la enfermedad multivaso, el infarto no diferencia la estructura fractal. El IAM es un evento agudo que produce una cicatriz localizada, mientras que la HTA y la enfermedad multivaso son condiciones crónicas que afectan la regulación autonómica de forma sostenida. El clasificador capta alteraciones sistémicas, no daño focal.

Edad. La edad promedio es prácticamente idéntica entre grupos: 53,5 vs. 53,8 años. No es un factor confundente.

Actividad 6: Dependencia de rango largo en tráfico transaccional Cloud

Para la sexta actividad, nos sumergimos en el análisis de tráfico transaccional de la NASA, un dataset clásico que ha sido estudiado durante décadas por su riqueza y complejidad. Este tráfico no es solo un flujo de datos: es un reflejo de cómo los usuarios interactúan con la web, cómo las páginas se cargan, y cómo los servidores responden a esas demandas.

El problema: ¿Por qué el tráfico web NO se comporta como una fila de supermercado?

Supongamos una autopista. Si el tráfico fuera Poisson, sería como si cada auto decidiera entrar a la ruta completamente al azar, sin importar lo que pase adelante. No habría tacos, no habría ráfagas: solo autos espaciados como gotas de lluvia en un día de llovizna suave.

Pero en la realidad, ¿qué pasa? Hay horas pico, hay accidentes que generan tacos de 5 km, hay ráfagas de autos que vienen todos juntos después de que se abre una barrera. El tráfico web es EXACTAMENTE igual.

Cuando un usuario pide una página de la NASA, no viene solo. Viene con imágenes, con scripts, con requests en cascada. Y si hay mucha gente conectada, se generan ráfagas (bursts) que el modelo Poisson no puede explicar. Poisson asume que cada evento es independiente, sin memoria del pasado. Pero la web tiene memoria: si hubo mucho tráfico hace un ratito, probablemente siga habiendo mucho tráfico ahora. Esa "memoria" es lo que llamamos dependencia de rango largo (LRD).

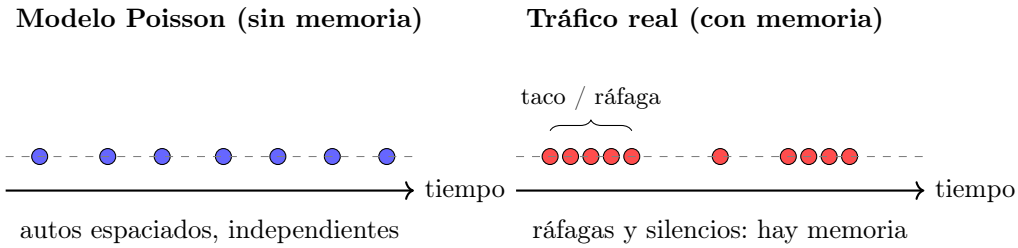


Figura 21: Poisson asume independencia total (izquierda). El tráfico real exhibe ráfagas porque "si hay taco, sigue habiendo taco" (derecha).

La Figura 22 presenta la serie de tiempo real extraída del log NASA: 975 721 observaciones con media $\mu = 2{,}7450$ s, mediana 1,0000 s y desviación estándar 137,6685 s. Las ráfagas saltan a la vista.

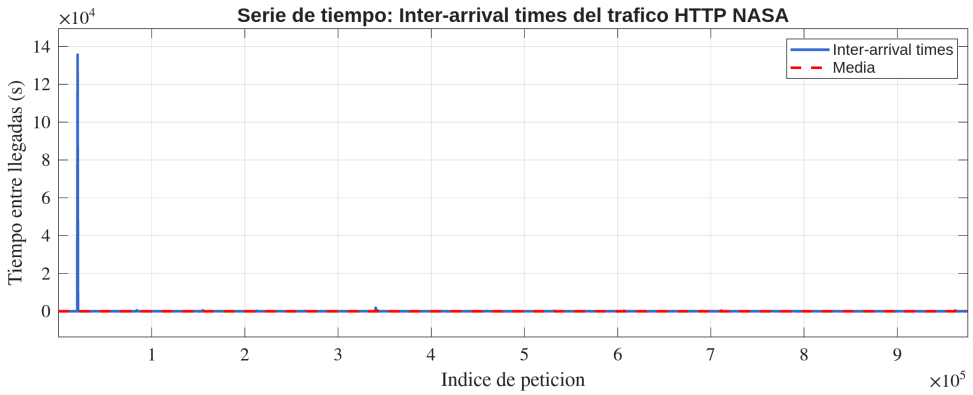


Figura 22: Serie de tiempo de los inter-arrival times del tráfico HTTP NASA. La línea roja discontinua marca la media ($\mu = 2{,}7450$ s).

La Figura 23 compara la distribución empírica con la exponencial teórica de Poisson. La cola pesada y la concentración en valores bajos demuestran que Poisson no alcanza.

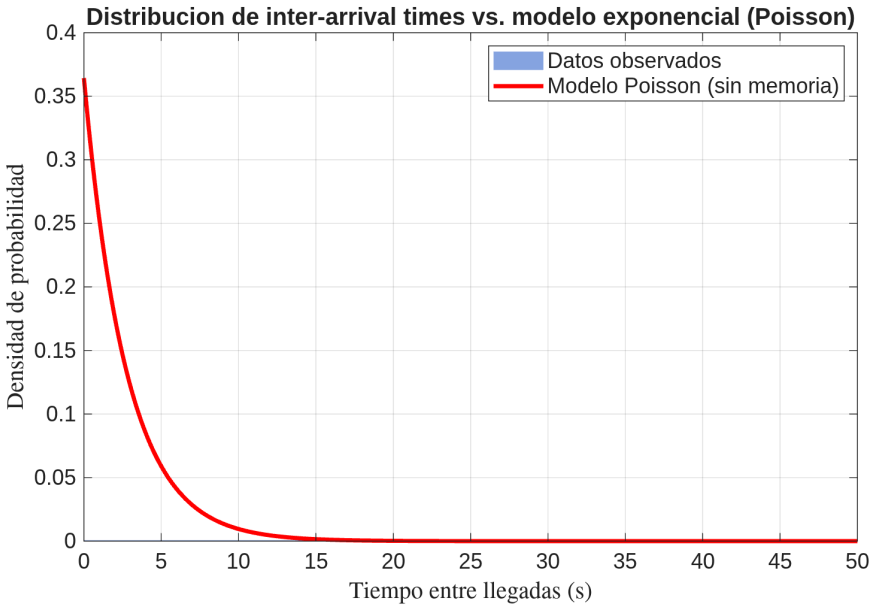


Figura 23: Histograma de inter-arrival times vs. distribución exponencial teórica (Poisson). Las colas pesadas invalidan el modelo sin memoria.

La solución: El parámetro de Hurst y la "memoria" del tráfico

¿Cómo medimos esa "memoria"? Acá entra el parámetro de Hurst (H), que el hidrólogo Harold Edwin Hurst usó en los años 50 para estudiar las crecidas del Nilo.

H es un número entre 0 y 1 que indica qué tan persistente es una serie temporal:

- $H = 0{,}5$: proceso Browniano, sin memoria. Cada paso es independiente. Es el mundo Poisson.
- $0{,}5 < H < 1$: dependencia de rango largo. Si el tráfico estuvo alto, tiende a seguir alto. Efecto "si hay taco, sigue habiendo taco".

- $0 < H < 0{,}5$: anti-persistencia. Si estuvo alto, tiende a bajar (muy raro en tráfico web).

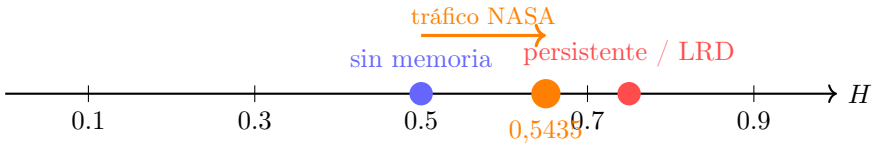


Figura 24: Escala del parámetro de Hurst. El tráfico NASA cae en la zona de memoria persistente ($H > 0{,}5$).

En nuestro análisis encontramos $H = 0{,}5435$, con un ajuste impecable ($R^2 = 0{,}9911$) e intervalo de confianza del 95 % [0,5408; 0,5462]. Conclusión: el tráfico NASA tiene memoria, tiene ráfagas estructuradas y NO se puede modelar con Poisson.

Método 1: Varianza–Tiempo — "¿Qué tan predecible es el caos?"

La idea del método VT es simple: agrupamos los datos en bloques cada vez más grandes y miramos cómo decae la varianza.

Imaginate la serie minuto a minuto (muchos bloques chicos), después de a 10 minutos (bloques medianos) y de a 100 minutos (bloques grandes). En un proceso Poisson, la varianza baja de forma predecible: se divide por el tamaño del bloque. Es como promediar números al azar: cuantos más promediés, más estable se vuelve el resultado.

Pero en un proceso con LRD, la varianza baja más lento. ¿Por qué? Porque los bloques grandes todavía tienen "memoria" entre sí. La ráfaga que empezó en el primer minuto sigue influyendo en el minuto 50. Entonces, agrupar no "apaga" la variabilidad tan rápido.

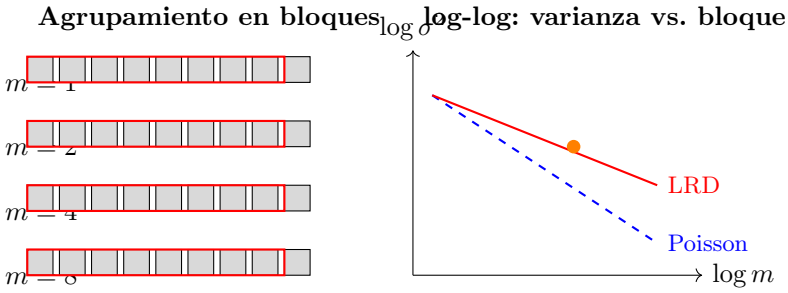


Figura 25: VT agrupa en bloques crecientes (izquierda). En log-log, la pendiente de LRD es menos empinada porque la varianza decae más lento (derecha).

El script `vt.m` hace exactamente eso: agrupa en $m = 1, 2, 4, 8, \ldots$, calcula la varianza de cada agregación y grafica log(varianza) vs. log(m). La pendiente de esa recta nos da H.

Resultado: $\hat{H} = 0{,}5435$ con $R^2_{\text{VT}} = 0{,}9911$. LRD confirmada.

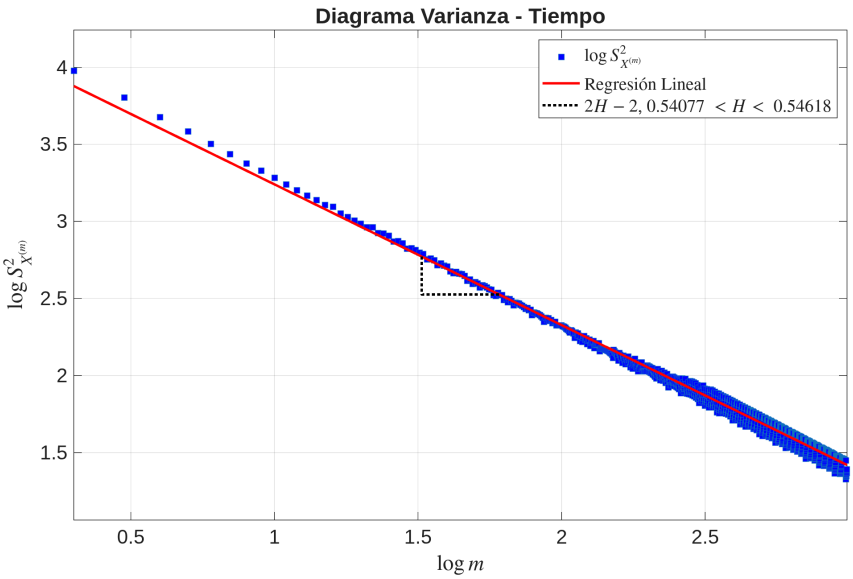


Figura 26: Diagrama de Varianza–Tiempo (VT). La pendiente del ajuste lineal determina $H = 0{,}5435$, significativamente por encima de $H_0 = 0{,}5$.

Método 2: Log–Escala — "El zoom que revela patrones ocultos"

El método de Log–Escala (LD) detecta LRD mirando la energía de las fluctuaciones a diferentes escalas. Es como usar un microscopio con distintos aumentos para ver si una textura se parece a sí misma sin importar el zoom.

La idea es descomponer la señal en escalas (como las capas de una cebolla) y medir cuánta "energía" hay en cada una. En Poisson, la energía decae de forma predecible al aumentar la escala. En LRD, decae más lento porque las fluctuaciones grandes persisten.

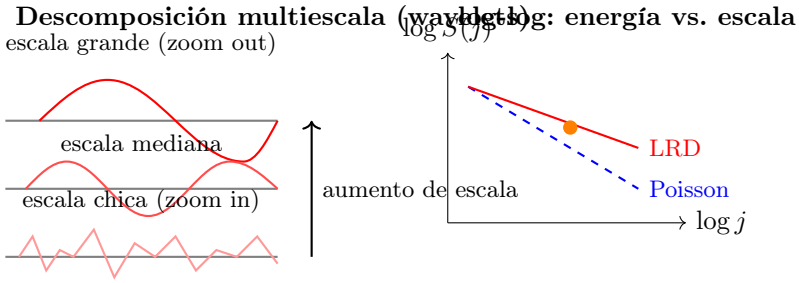


Figura 27: LD descompone la señal en escalas con wavelets (izquierda). En log-log, la pendiente de LRD es menos empinada porque la energía persiste (derecha).

`LD.m` usa wavelets de Haar, grafica log(energía) vs. log(escala) y la pendiente estima H.

Resultado: $\hat{H} = 0{,}5064$, $\alpha = 0{,}0127$. Consistente con VT, aunque más conservador —algo que ya vimos en la Actividad 1, donde LD mostró mayor varianza en muestras grandes.

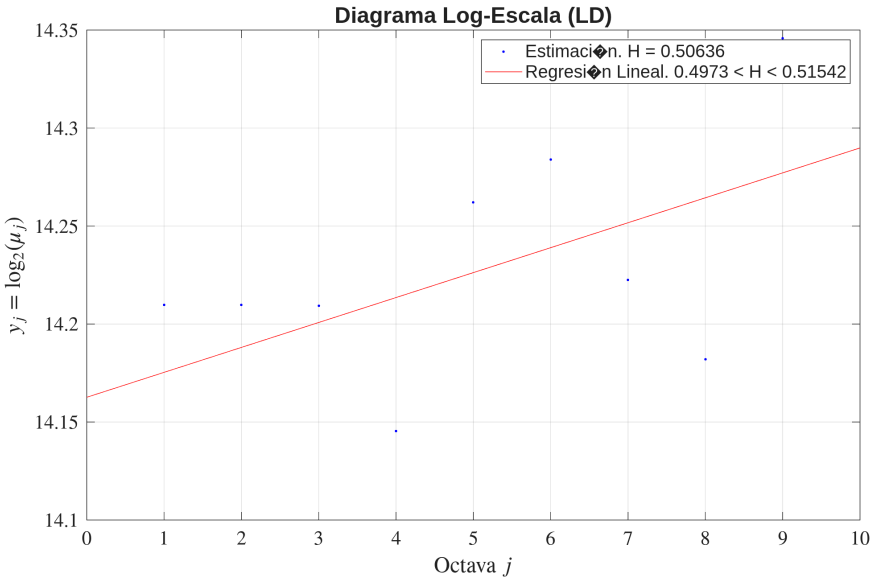


Figura 28: Diagrama log–escala (LD) con wavelets de Haar. Confirma LRD con $H = 0{,}5064$.

Clasificación: ¿Mono o multifractal?

No todo proceso con LRD es igual. Hay dos tipos:

- **Monofractal**: H es el mismo en toda la serie. Es como una autopista donde el tráfico se comporta igual de caótico en todos los tramos.
- **Multifractal**: H varía según la zona de la serie. Es como una ciudad donde algunas calles tienen tráfico caótico (H alto) y otras están tranquilas (H bajo).

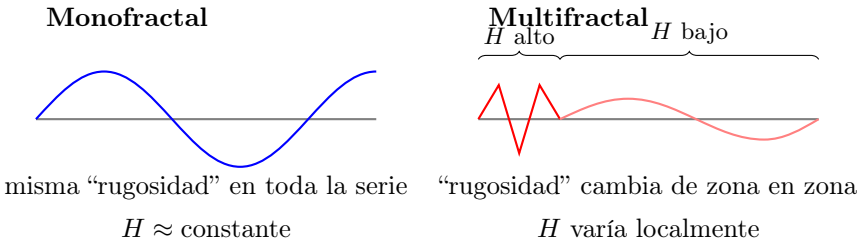


Figura 29: Monofractal: un solo H gobierna toda la serie. Multifractal: diferentes regímenes de escalamiento coexisten.

`clasificar_fractal.m` compara VT y LD y analiza la curvatura de $\tau(q)$:

- Si $H_{\text{VT}} \approx H_{\text{LD}}$ y $\tau(q)$ es lineal $\rightarrow$ monofractal.
- Si divergen y $\tau(q)$ es curvo $\rightarrow$ multifractal.

Resultado: $R^2_\tau = 0{,}4808$ (muy por debajo de 0,90). El tráfico NASA es **multifractal**: hay momentos de alta persistencia (ráfagas intensas) y momentos de baja persistencia (tráfico estable).

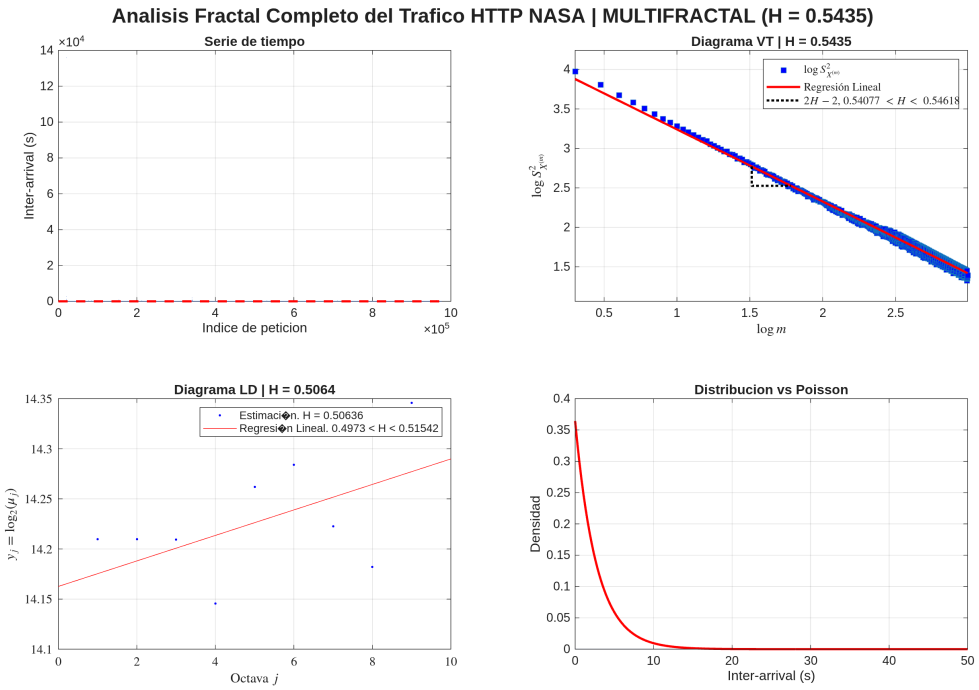


Figura 30: Panel integrado: serie de tiempo, diagrama VT ($H = 0{,}5435$), diagrama LD ($H = 0{,}5064$) y distribución vs. Poisson.

Implicaciones para la orquestación Cloud

¿Por qué importa esto? Si diseñamos servidores, CDNs o políticas de auto-escalado asumiendo Poisson, vamos a subestimar las colas, vamos a subestimar los picos de congestión, y vamos a diseñar una infraestructura que se cae en las horas pico. Es como diseñar una autopista asumiendo que los autos llegan uno por uno perfectamente espaciados, cuando en realidad vienen en caravanas.

El parámetro de Hurst nos da una herramienta cuantitativa para medir esa memoria y tomar decisiones de infraestructura más inteligentes: reservar capacidad antes de que llegue la ráfaga, en lugar de reaccionar cuando ya es tarde.

Conclusiones

Las herramientas fractales (VT, LD, wavelet leaders) demostraron ser robustas para caracterizar LRD en series temporales. La fractalidad no es exótica: aparece naturalmente en tráfico de red, fisiología cardíaca y flujos transaccionales Cloud.

En cuanto a estimadores, LD fue superior a VT para muestras grandes ($n \geq 5\,000$), con menor sesgo y varianza hasta 2,65 veces menor. VT, en cambio, es más simple y funciona mejor para muestras pequeñas. La elección depende del tamaño de la muestra: no hay uno mejor, son complementarios.

En fisiología, los registros sanos de la ST-T Database mostraron espectros multifractales

amplios (complejidad adaptativa), mientras que las patologías tendieron a monofractalidad o periodicidad. La enfermedad reduce la complejidad fractal.

En tráfico Cloud, el análisis del dataset NASA confirmó LRD ($H > 0{,}5$) y comportamiento multifractal. Esto invalida los modelos de colas basados en Poisson para diseño de infraestructura.

La clasificación mono/multifractal alcanzó 87,5 % de acierto en validación, mostrando potencial como métrica objetiva en diagnóstico y análisis de sistemas complejos.

Como trabajo futuro, se propone extender estas herramientas al diseño de criptosistemas basados en atractores caóticos de alta dimensión.

Referencias

[1] G. Orwell, *1984*. London: Secker & Warburg, 1949.

[2] W. E. Leland, M. S. Taqqu, W. Willinger, and D. V. Wilson, "On the self-similar nature of Ethernet traffic (extended version)," *IEEE/ACM Transactions on Networking*, vol. 2, no. 1, pp. 1–15, Feb. 1994.

[3] A. Camus, *Le Mythe de Sisyphe*. Paris: Gallimard, 1942.

[4] B. B. Mandelbrot, *The Fractal Geometry of Nature*. New York: W. H. Freeman and Company, 1982.

[5] J.-M. Bardet and G. Lang and E. Moulines and P. Soulier, "Wavelet estimators of the memory parameter for time series," *European Physical Journal B*, vol. 29, pp. 221–225, 2002.

[6] P. Abry, P. Flandrin, M. S. Taqqu, and D. Veitch, "Self-similarity and long-range dependence: From theory to applications," in *Fractals in Engineering: New Trends in Theory and Applications*, J. Lévy-Véhel and E. Lutton, Eds. London: Springer, 2005, pp. 15–42.

[7] R. Taddei, G. Distante, M. Emdín, P. Pisani, G. B. Moody, C. Zeelenberg, and A. Marchesi, "The European ST-T Database: Standard for evaluating systems for the analysis of ST-T changes in ambulatory electrocardiography," *European Heart Journal*, vol. 13, no. 9, pp. 1164–1172, Sep. 1992.

[8] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, "Heart rate variability: Standards of measurement, physiological interpretation, and clinical use," *European Heart Journal*, vol. 17, no. 3, pp. 354–381, 1996.

[9] M. Karlsson, R. Hörnsten, A. Rydberg y U. Wiklund, "Automatic filtering of outliers in RR intervals before analysis of heart rate variability in Holter recordings: a comparison with carefully edited data," *BioMedical Engineering OnLine*, vol. 11, no. 2, 2012.