

Trabajo Grupal 3

LRD y Multifractales

Juan Felipe Rodríguez G. 20261595004
Carlos Stiven Mora Hoyos 20261595003
Sergio Santiago Duarte Rojas 20261595002

Curso: Herramientas Matemáticas para el Manejo de la Información

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia
27 de mayo de 2026

Índice

1. Actividad 1: Evaluación de estimadores **3**
1.1. Prueba de Sesgo . . . 3
1.2. Prueba de Consistencia . . . 5
1.3. Prueba de Eficiencia . . . 6
1.4. Prueba de Robustez . . . 8
1.5. Resumen de la Actividad 1 . . . 10

2. Actividad 2: Evaluación con Secuencias LRD **10**
2.1. Prueba de Sesgo . . . 10
2.2. Prueba de Eficiencia . . . 14
2.3. Prueba de Consistencia . . . 17
2.4. Resumen de la Actividad 2 . . . 19

3. Actividad 3: Estimación de H en la *European ST-T Database* **19**
3.1. Resultados por registro . . . 20
3.2. Distribución global . . . 21
3.3. Interpretación . . . 22

4. Actividad 4: Herramienta de clasificación mono/multifractal **22**
4.1. Diagrama de flujo . . . 23
4.2. Validación . . . 23
4.3. Análisis . . . 25

5. Actividad 5: Clasificación fractal de la European ST-T Database **25**

6. Actividad 6: Escenario real con LRD **25**

1. Actividad 1: Evaluación de estimadores

Se evalúan las propiedades estadísticas de los estimadores Varianza–Tiempo (`vt2`) y Log–Escala (`LD2`) sobre secuencias discretas independientes e idénticamente distribuidas. El valor teórico de referencia es $H_0 = 0.5$.

1.1. Prueba de Sesgo

Se evaluó el sesgo bajo dos escenarios: muestra pequeña ($n = 1\,000$) y muestra grande ($n = 100\,000$), con $10\,000$ realizaciones $\mathcal{N}(0,1)$ en cada caso. Los parámetros de ajuste normal obtenidos con `normfit` se consolidan en la Tabla 1.

Tabla 1: Parámetros de ajuste normal (`normfit`) para la prueba de sesgo.

n	$\hat{\mu}_{\mathrm{VT}}$	$\hat{\sigma}_{\mathrm{VT}}$	$\hat{\mu}_{\mathrm{LD}}$	$\hat{\sigma}_{\mathrm{LD}}$
$1\,000$	0.4967	0.0289	0.4982	0.0347
$100\,000$	0.4996	0.0099	0.4999	0.0063

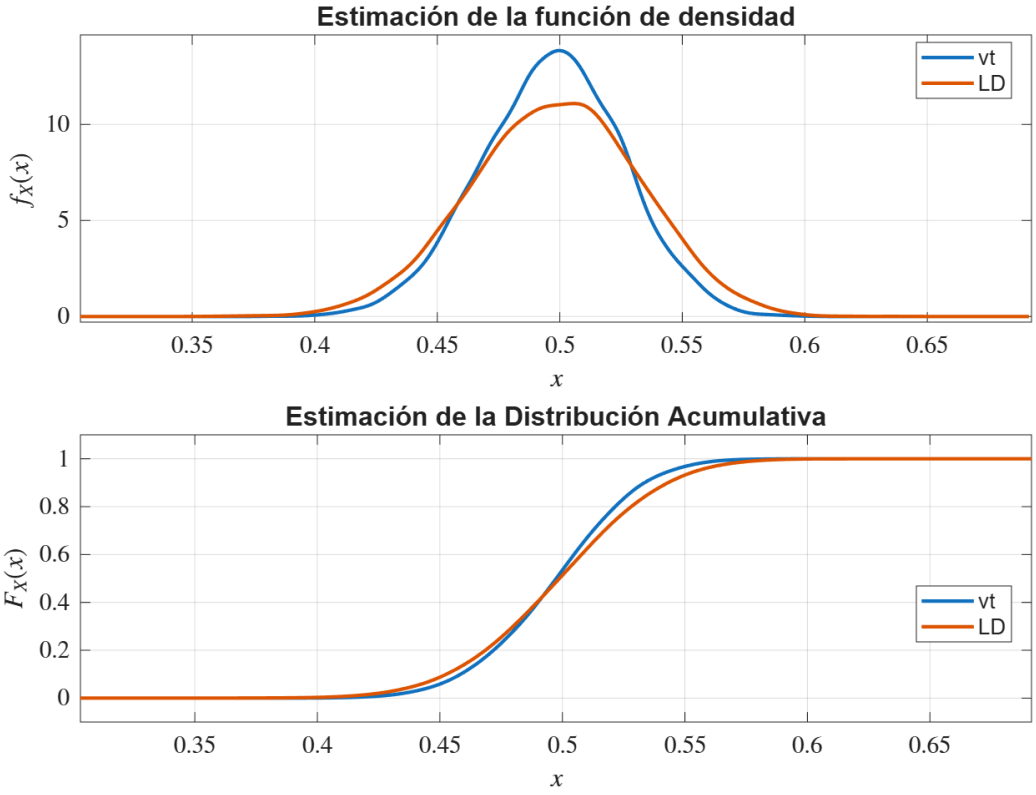


Figura 1: PDF y CDF empíricas de $\hat{H}$ para VT y LD ($n = 1\,000$, $10\,000$ repeticiones, $\mathcal{N}(0,1)$).

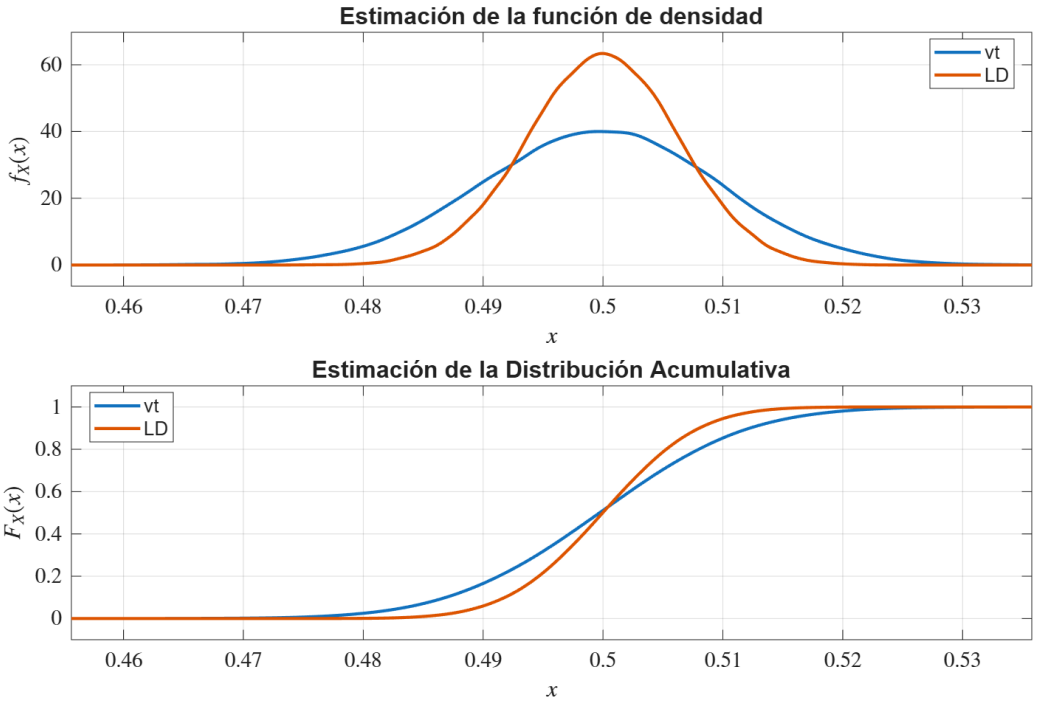
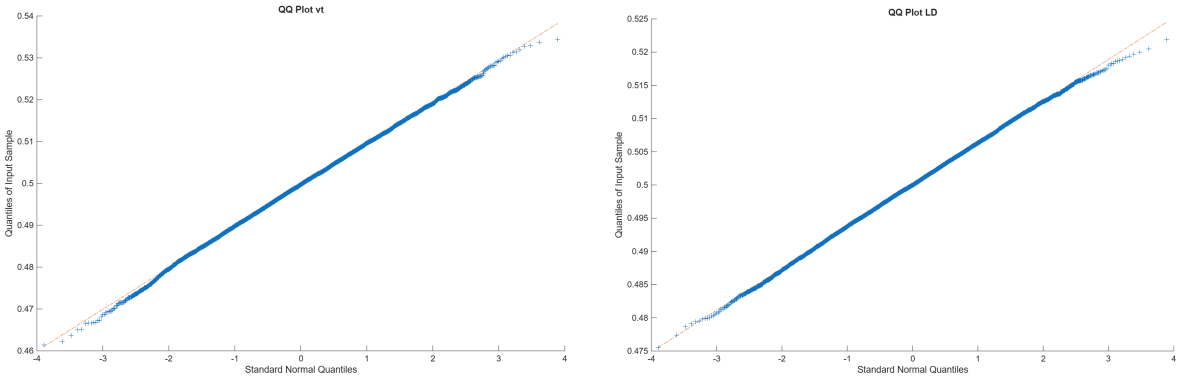


Figura 2: PDF y CDF empíricas de $\hat{H}$ para VT y LD ($n = 100\,000$, $10\,000$ repeticiones, $\mathcal{N}(0,1)$).



(a) QQ-plot estimador VT ($n = 100\,000$). (b) QQ-plot estimador LD ($n = 100\,000$).

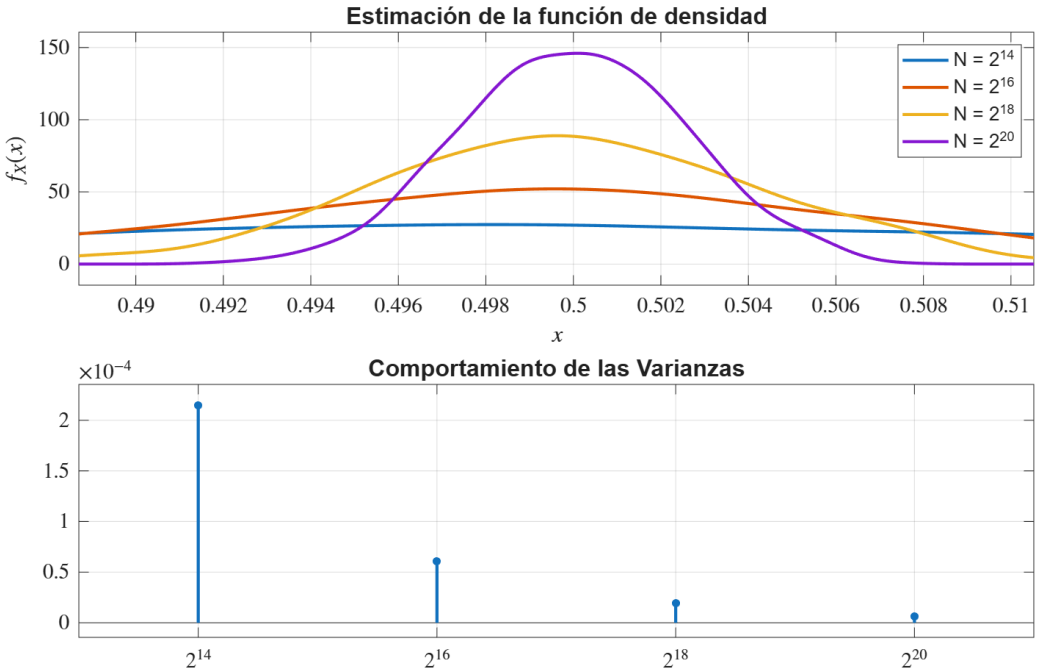
Figura 3: La alineación con la recta de referencia confirma distribución normal en ambos estimadores, justificando el uso de `normfit`.

Para $n = 1\,000$ (Figura 1), ambos estimadores muestran sesgo despreciable (-0.0033 para VT y -0.0018 para LD), pero las distribuciones son notablemente anchas. En este régimen VT es ligeramente más eficiente: su desviación estándar (0.0289) es un 17 % menor que la de LD (0.0347), es decir, para muestras pequeñas LD no ofrece ventaja en varianza.

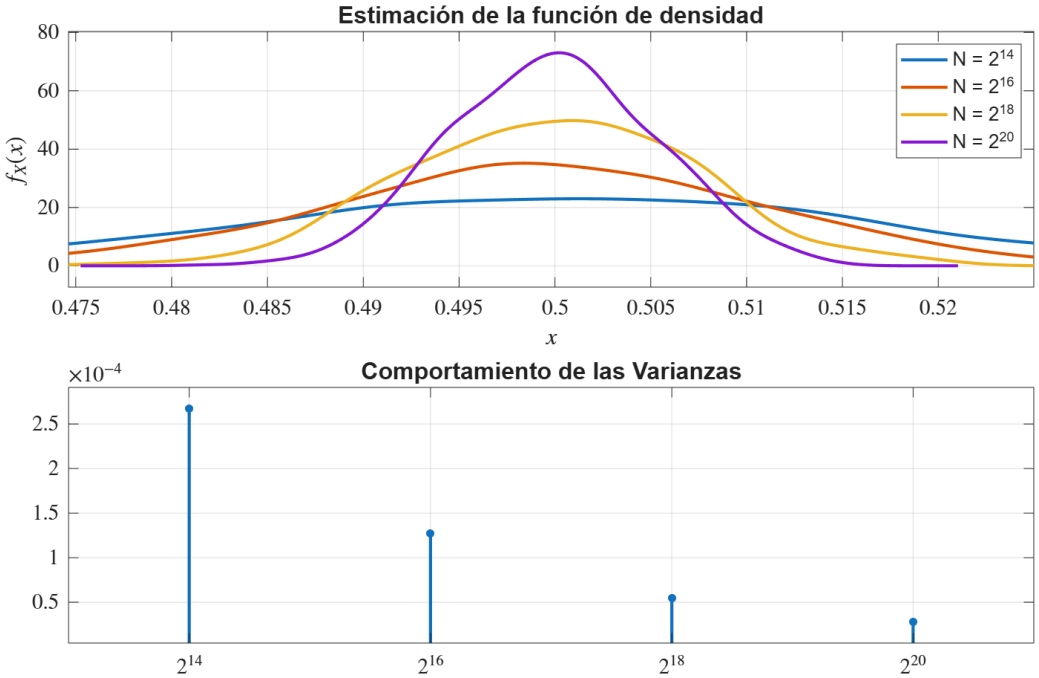
Para $n = 100\,000$ (Figura 2), la situación se invierte: ambas distribuciones se concentran fuertemente en $H_0 = 0.5$ y el sesgo permanece negligible, pero ahora LD presenta una desviación estándar un 36 % menor que VT (0.0063 vs. 0.0099). Esta inversión queda también reflejada en los QQ-plots (Figura 3): VT exhibe una leve desviación en las colas, mientras que LD se ajusta con mayor fidelidad a la recta de referencia para muestras grandes.

1.2. Prueba de Consistencia

Se evaluó la convergencia de cada estimador al aumentar el tamaño de muestra. Se generaron 1 000 realizaciones para cada $N \in \{2^{14}, 2^{16}, 2^{18}, 2^{20}\}$ con distribución $\mathcal{N}(0, 1)$.



(a) Estimador LD: la PDF se estrecha progresivamente y la varianza cae de 2.13×10^{-4} ($N = 2^{14}$) a 6.7×10^{-5} ($N = 2^{20}$).



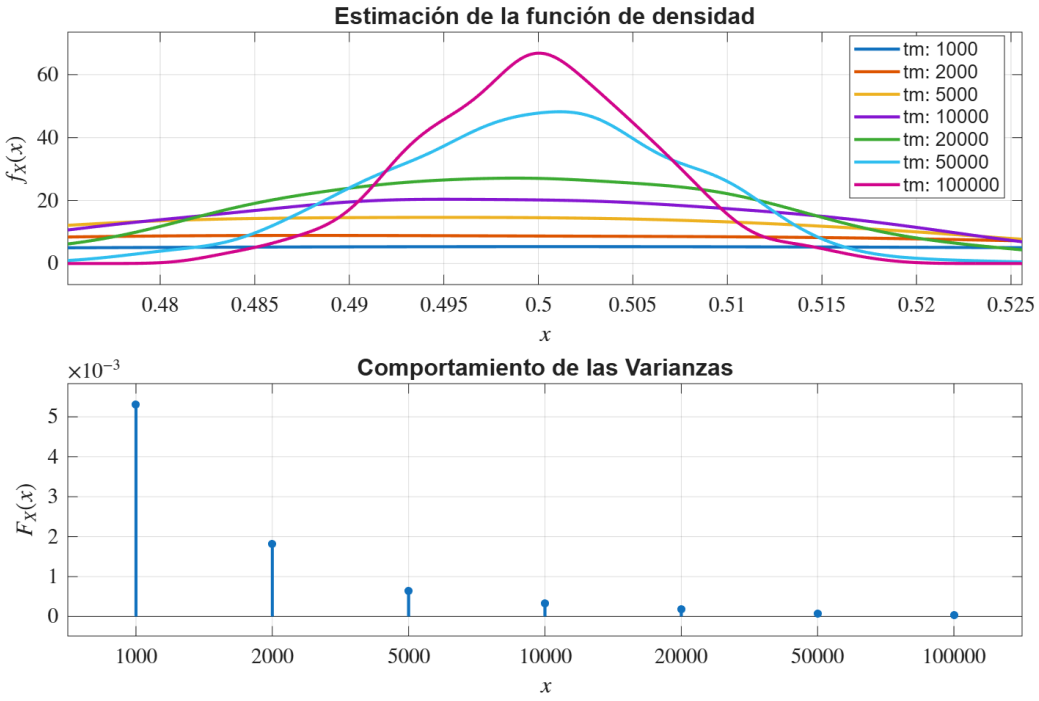
(b) Estimador VT: convergencia más lenta; la varianza cae de 2.65×10^{-4} ($N = 2^{14}$) a 2.7×10^{-4} ($N = 2^{20}$).

Figura 4: Consistencia de los estimadores VT y LD. Las PDFs se concentran en $H_0 = 0.5$ al crecer N, y las varianzas disminuyen monotónicamente (panel inferior de cada subfigura).

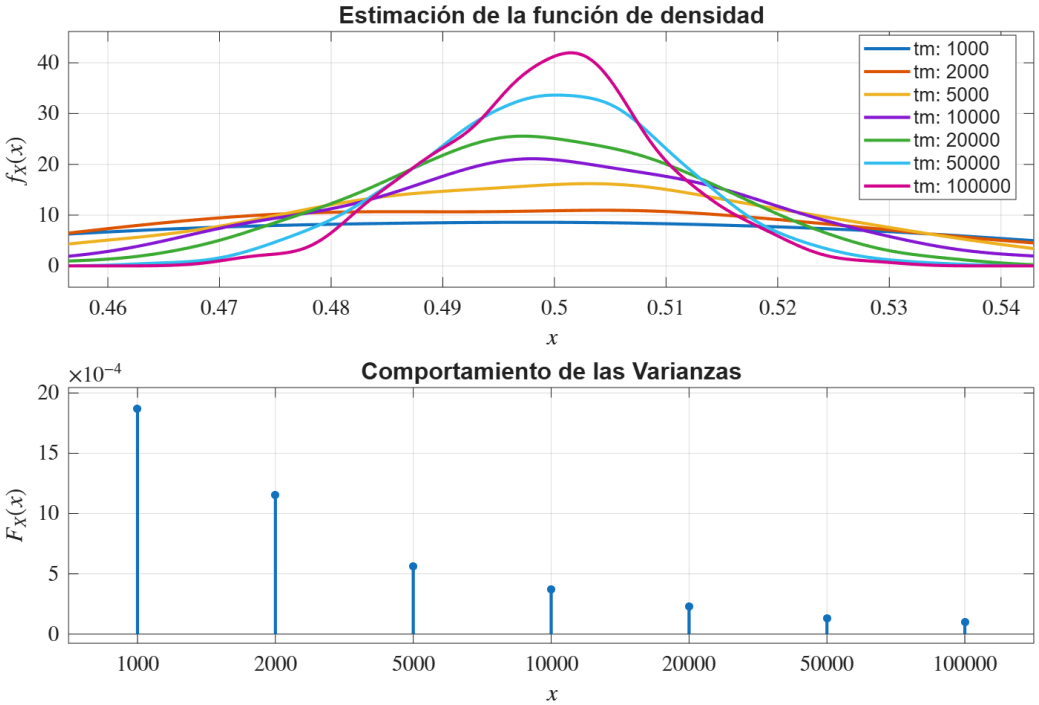
Ambos estimadores son consistentes: las densidades se estrechan y centran en $H_0 = 0.5$ al aumentar N, y las varianzas decrecen monótonamente. LD converge más rápido: para $N = 2^{20}$ su varianza es $\approx 6.7 \times 10^{-5}$, frente a $\approx 2.7 \times 10^{-4}$ de VT, una reducción cuatro veces mayor.

1.3. Prueba de Eficiencia

La eficiencia se mide comparando la varianza de cada estimador para un mismo tamaño de muestra n. Se usaron 1 000 repeticiones para cada $n \in \{1000, 2000, 5000, 10000, 20000, 50000, 100000\}$.



(a) Estimador LD.



(b) Estimador VT.

Figura 5: PDF empírica y comportamiento de las varianzas de VT y LD para distintos tamaños de muestra n.

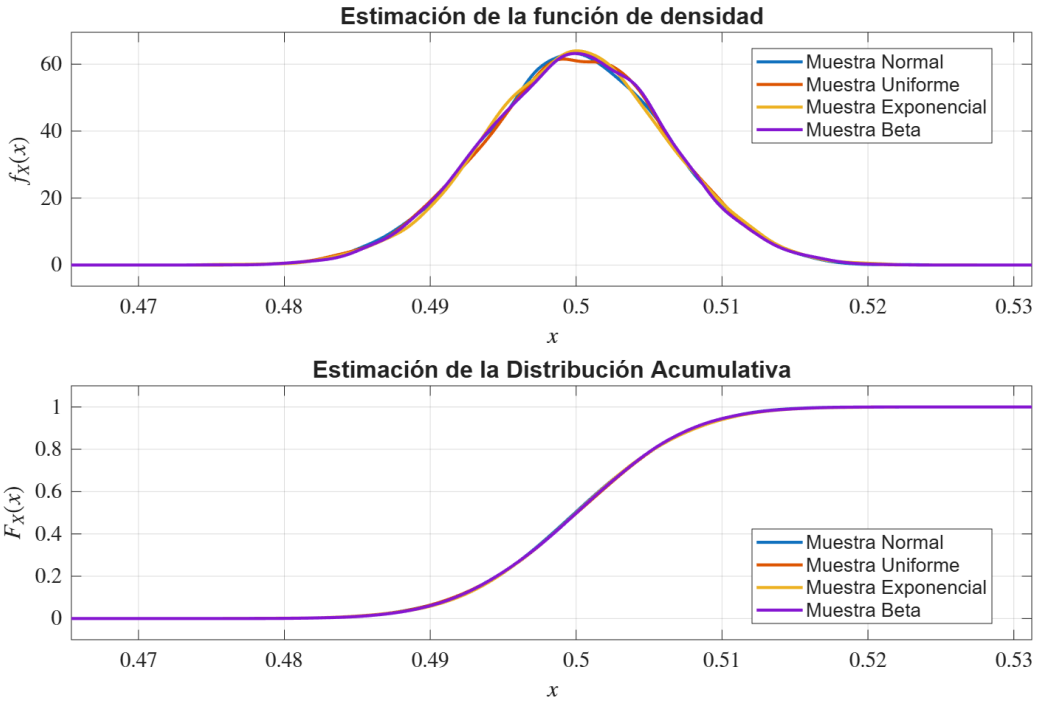
La Tabla 2 consolida las varianzas obtenidas. Para $n \leq 2\,000$, VT resulta más eficiente; a partir de $n = 5\,000$ LD supera a VT, y a $n = 100\,000$ su varianza es ≈ 2.65 veces menor.

Tabla 2: Varianza de $\hat{H}$ en función del tamaño de muestra n.

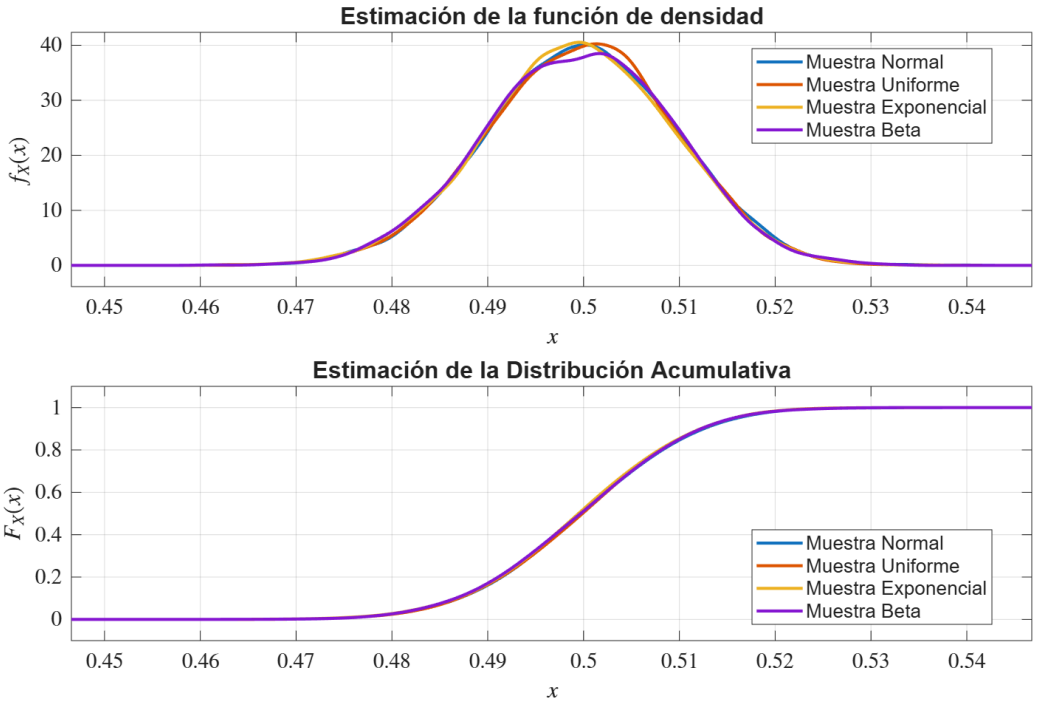
n	$\mathrm{Var}(\hat{H}_{\mathrm{VT}})$	$\mathrm{Var}(\hat{H}_{\mathrm{LD}})$
1 000	1.87×10^{-3}	5.31×10^{-3}
2 000	1.16×10^{-3}	1.82×10^{-3}
5 000	5.59×10^{-4}	6.43×10^{-4}
10 000	3.71×10^{-4}	3.27×10^{-4}
20 000	2.28×10^{-4}	1.83×10^{-4}
50 000	1.32×10^{-4}	6.76×10^{-5}
100 000	1.00×10^{-4}	3.77×10^{-5}

1.4. Prueba de Robustez

Se evaluó la sensibilidad de cada estimador ante cambios en la distribución de la secuencia de entrada, usando cuatro distribuciones: Normal $\mathcal{N}(0,1)$, Uniforme $\mathcal{U}(0,1)$, Exponencial Exp(1) y Beta$(2,5)$, con $n = 100\,000$ y 1 000 repeticiones.



(a) Estimador LD: las cuatro curvas son prácticamente indistinguibles, con pico ≈ 63.



(b) Estimador VT: las cuatro curvas también se superponen, con pico ≈ 40 y ligera separación entre distribuciones.

Figura 6: Robustez de los estimadores VT y LD ante distintas distribuciones de entrada ($n = 100\,000$, $1\,000$ repeticiones).

Ambos estimadores exhiben alta robustez: las PDF y CDF para las cuatro distribuciones se superponen casi perfectamente en ambos casos, centradas en $H_0 = 0.5$. LD presenta mayor concentración (pico ≈ 63 vs. ≈ 40 de VT), lo que refleja su menor varianza independientemente de la distribución de entrada. Ninguno de los dos estimadores muestra sensibilidad apreciable

ante cambios distribucionales para muestras grandes.

1.5. Resumen de la Actividad 1

Tabla 3: Comparación de estimadores VT y LD por propiedad evaluada.

Propiedad	**VT**	**LD**	**Ganador**
Sesgo ($n < 5\,000$)	$\hat{\sigma} = 0.0289$	$\hat{\sigma} = 0.0347$	**VT**
Sesgo ($n \geq 5\,000$)	$\hat{\sigma} = 0.0099$	$\hat{\sigma} = 0.0063$	**LD**
Consistencia	Converge, varianza mayor	Converge más rápido	**LD**
Eficiencia ($n < 5\,000$)	Var menor	Var mayor	**VT**
Eficiencia ($n \geq 5\,000$)	Var $\approx 1.00 \times 10^{-4}$	Var $\approx 3.77 \times 10^{-5}$	**LD**
Robustez	Alta	Alta	**Empate**

Para muestras grandes ($n \geq 5\,000$), LD supera a VT en sesgo, consistencia y eficiencia. Para muestras pequeñas ($n < 5\,000$), VT es más eficiente y presenta menor dispersión. Ambos estimadores son igualmente robustos ante cambios en la distribución de entrada.

2. Actividad 2: Evaluación con Secuencias LRD

Se evalúan los estimadores `vt2` y `LD2` sobre secuencias sintéticas con dependencia de rango largo (LRD), generadas con `betamwm` (multifractal) y `wfbm` (monofractal), para $H \in \{0.55, 0.60, \ldots, 0.95\}$ con 1 000 repeticiones por valor de H. Las propiedades evaluadas son sesgo, eficiencia y consistencia.

2.1. Prueba de Sesgo

Para construir la Figura 7 se realizó un sondeo sistemático del sesgo: por cada valor de $H \in \{0.55, 0.60, \ldots, 0.95\}$ (incrementos de 0.05, nueve puntos en total) se generaron 1 000 realizaciones independientes con cada generador y se aplicaron los estimadores `vt2` y `LD2`. El valor medio $\hat{\mu}$ de las 1 000 estimaciones se tomó como representante del estimador en ese punto y se graficó contra H real. La diagonal punteada representa el estimador ideal $\hat{H} = H$; la distancia vertical entre cada curva y la diagonal es el sesgo empírico $\hat{\mu} - H$ para ese valor de H.

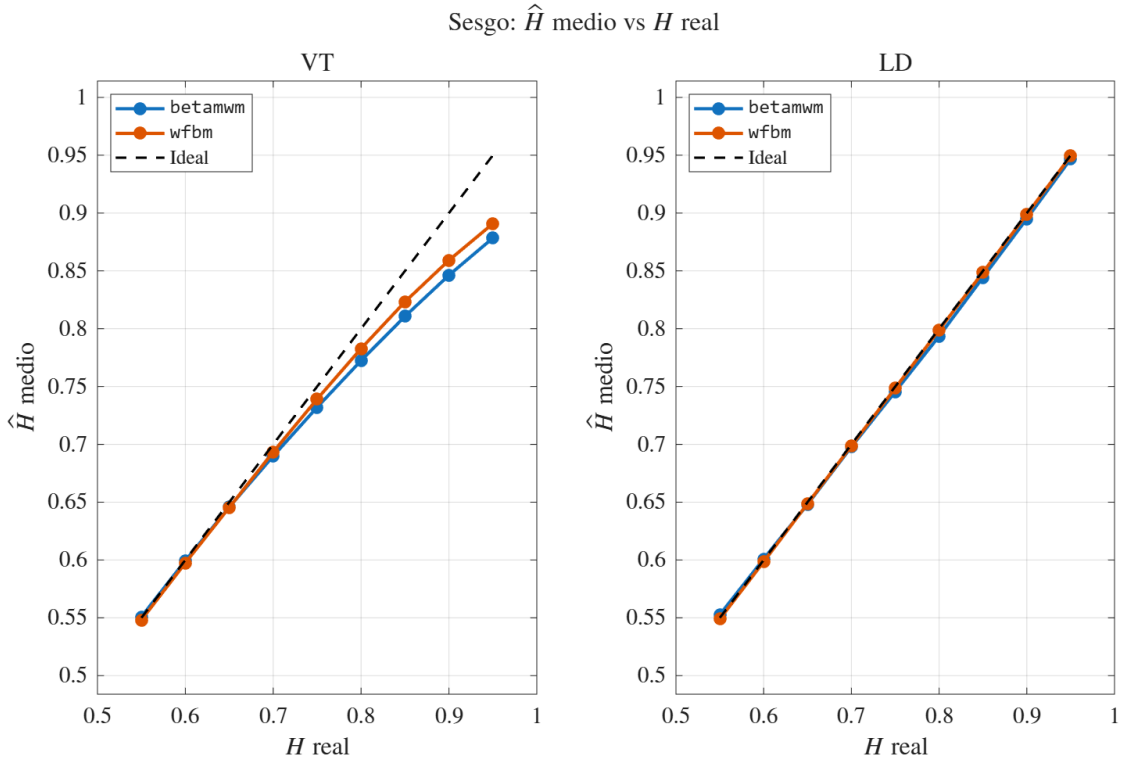


Figura 7: Sesgo de los estimadores VT y LD para `betamwm` y `wfbm` (1 000 repeticiones por valor de H).

Estimador VT. Ambos generadores producen subestimación creciente con H. Para `betamwm`, el sesgo pasa de -0.0023 en $H = 0.55$ hasta -0.0711 en $H = 0.95$; para `wfbm`, de -0.0016 a -0.0092. VT es considerablemente más sesgado con `betamwm` que con `wfbm` para valores altos de H, lo que evidencia su sensibilidad a la naturaleza multifractal del proceso.

Estimador LD. Las curvas se superponen casi perfectamente con la diagonal ideal en ambos generadores. El sesgo máximo es -0.0054 para `betamwm` ($H = 0.90$) y -0.0010 para `wfbm` ($H = 0.95$), valores despreciables en todo el rango. LD estima H con alta fidelidad independientemente del generador y del valor de H.

Tabla 4: Parámetros de ajuste normal y sesgo para el caso representativo $H = 0.9$ (1 000 repeticiones).

Generador	**Estimador**	$\hat{\mu}$	$\hat{\sigma}$	**Sesgo**
`betamwm`	VT	0.8463	0.0207	-0.0537
`wfbm`	VT	0.8592	0.0188	-0.0408
`betamwm`	LD	0.8951	0.0377	-0.0049
`wfbm`	LD	0.8989	0.0143	-0.0011

Para justificar el uso de `normfit` en la estimación de $\hat{\mu}$ y $\hat{\sigma}$, la Figura 8 presenta los QQ-plots de las 1 000 estimaciones para $H = 0.9$ en las cuatro combinaciones generador $\times$ estimador.

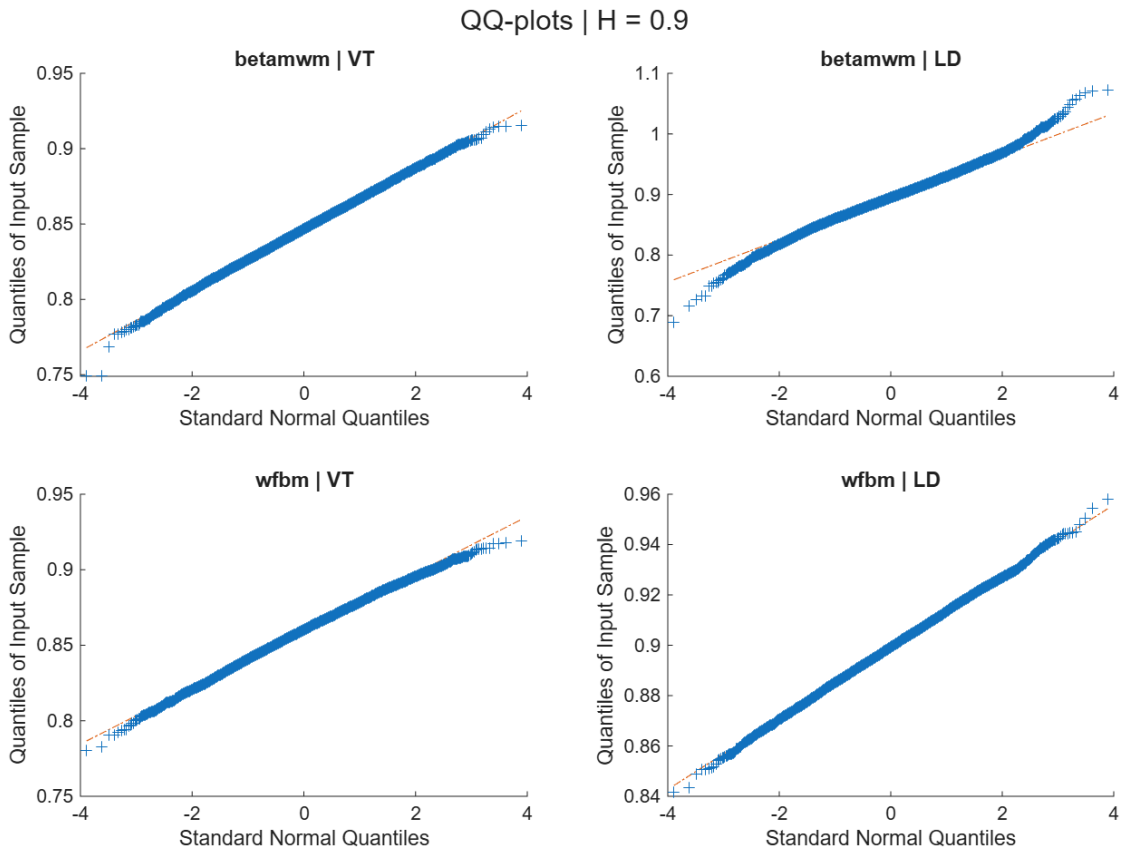


Figura 8: QQ-plots de $\hat{H}$ para $H = 0.9$ (1 000 repeticiones). La disposición es: `betamwm` (fila superior) y `wfbm` (fila inferior); VT (columna izquierda) y LD (columna derecha).

Los cuatro paneles confirman que las distribuciones empíricas de $\hat{H}$ siguen aproximadamente una normal, validando el uso de `normfit`. Se observan diferencias cualitativas coherentes con el análisis de sesgo:

- `betamwm` | **VT** (panel superior izquierdo): buen ajuste en el cuerpo central con leve desviación en la cola inferior. La distribución está centrada en $\hat{\mu} = 0.846$, alejada de $H = 0.9$, consistente con el sesgo de -0.054.
- `betamwm` | **LD** (panel superior derecho): mayor dispersión de los cuatro casos ($\hat{\sigma} = 0.038$) con desviación en ambas colas. A pesar de ello, la distribución está centrada cerca de $H = 0.9$ (sesgo de -0.005), confirmando que LD estima correctamente aunque con mayor varianza para procesos multifractales.
- `wfbm` | **VT** (panel inferior izquierdo): buen ajuste con leve desviación en la cola superior. Centrado en $\hat{\mu} = 0.859$, con sesgo de -0.041, menor que `betamwm` pero aún apreciable.
- `wfbm` | **LD** (panel inferior derecho): el ajuste más fiel a la recta de referencia, con la menor dispersión ($\hat{\sigma} = 0.014$) y el menor sesgo (-0.001). Confirma que LD sobre secuencias monofractales es el escenario más favorable.

Las Figuras 9 y 10 muestran las PDF y CDF empíricas para $H = 0.9$, donde el sesgo de VT y la diferente dispersión entre generadores son directamente visibles, en coherencia con los

QQ-plots.

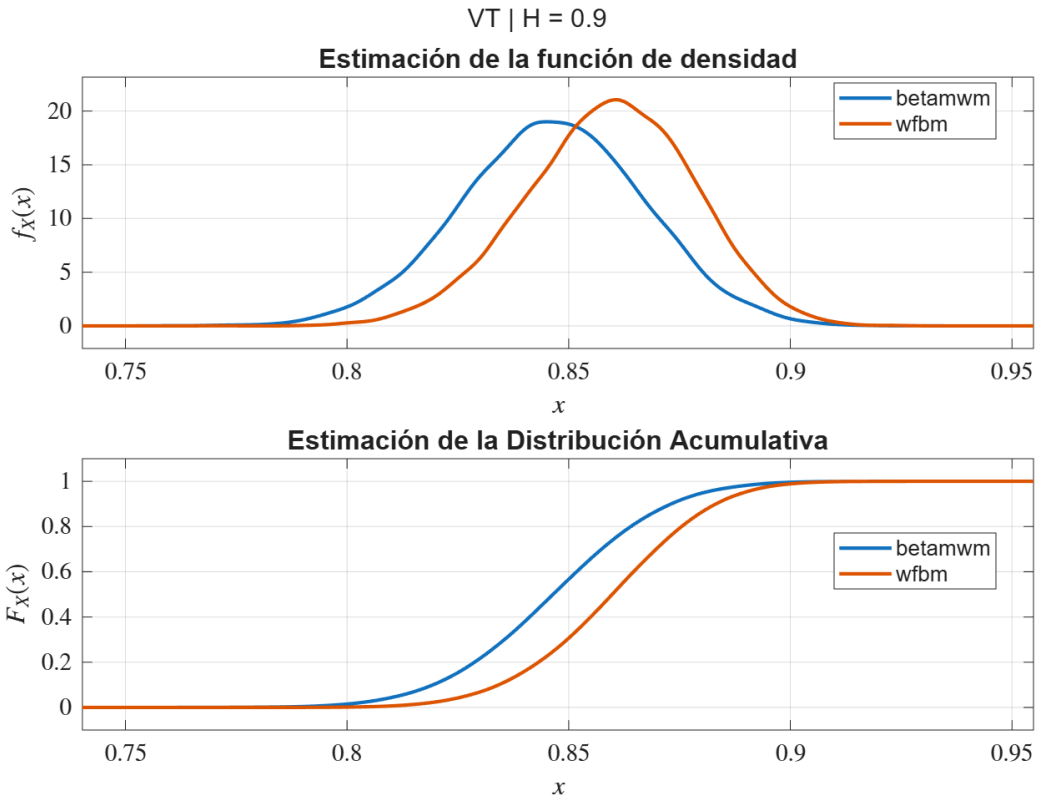


Figura 9: PDF y CDF de $\hat{H}$ con estimador VT para $H = 0.9$. La distribución de `betamwm` está desplazada hacia la izquierda respecto a `wfbm`, evidenciando mayor sesgo.

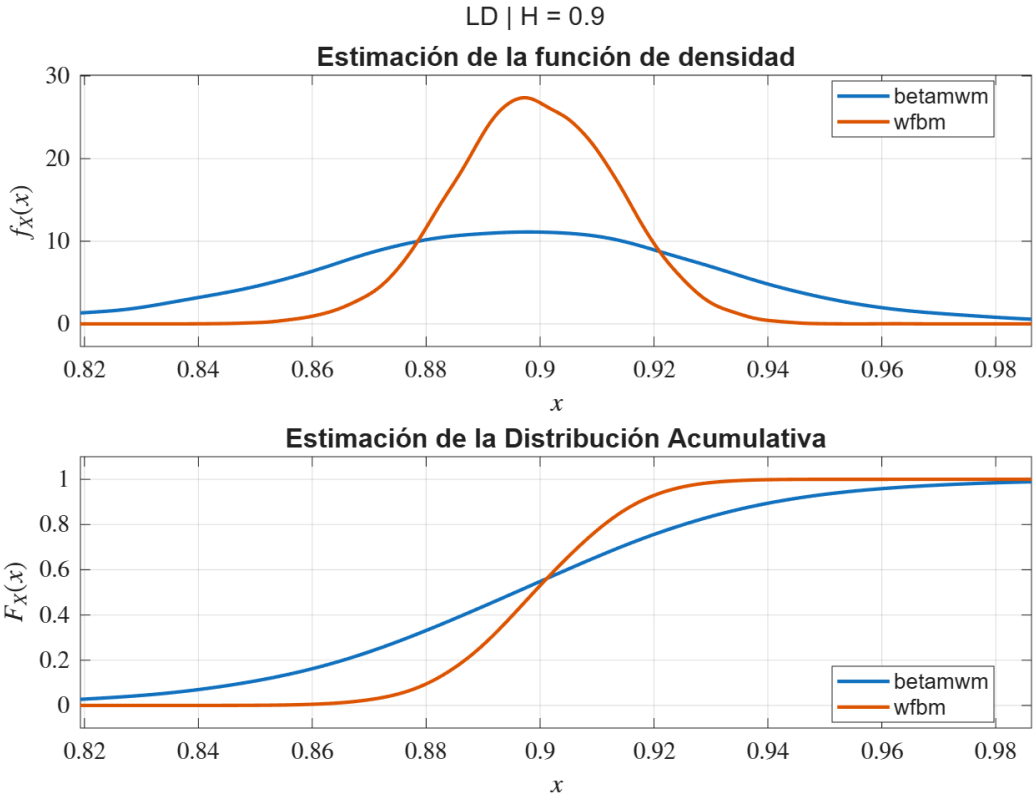


Figura 10: PDF y CDF de $\hat{H}$ con estimador LD para $H = 0.9$. `wfbm` presenta mayor concentración (menor $\hat{\sigma}$), pero ambas distribuciones están centradas cerca de $H = 0.9$.

2.2. Prueba de Eficiencia

La eficiencia se mide comparando la varianza de $\hat{H}$ entre estimadores para un mismo valor de H: el estimador con menor $\mathrm{Var}(\hat{H})$ es más eficiente. Las Figuras 11 y 12 muestran $\mathrm{Var}(\hat{H})$ en función de H real para cada combinación estimador $\times$ generador.

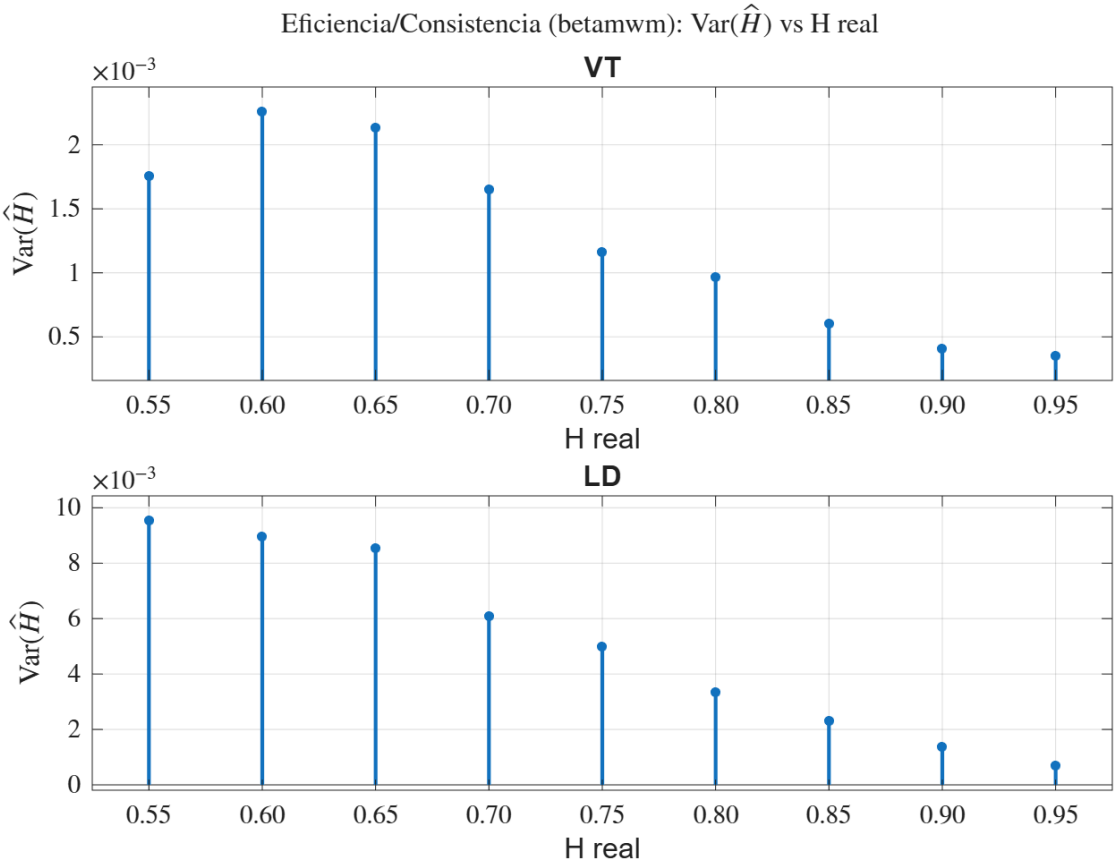


Figura 11: Varianza de $\hat{H}$ vs. H real para `betamwm`. VT (arriba) presenta varianzas del orden 10^{-3}; LD (abajo) del mismo orden pero con mayor magnitud en todo el rango de H.

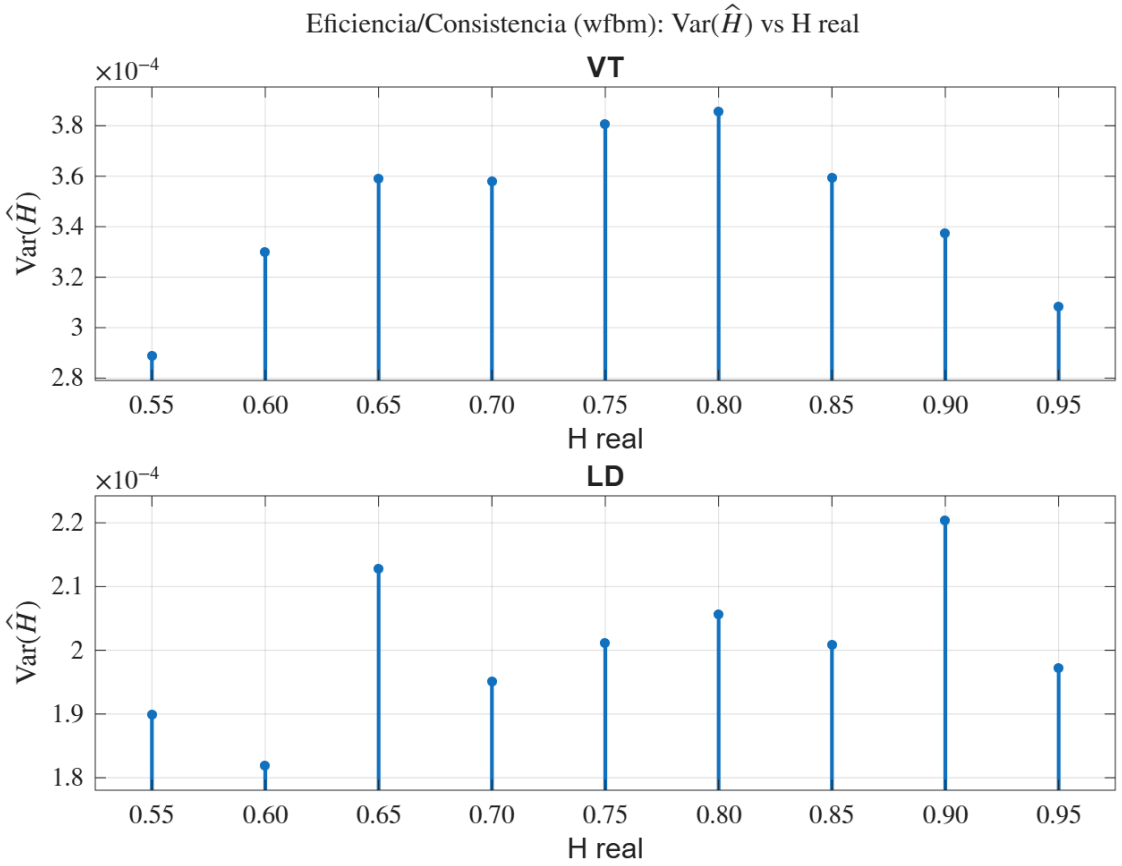


Figura 12: Varianza de $\hat{H}$ vs. H real para `wfbm`. VT (arriba) muestra varianzas del orden 10^{-4}; LD (abajo) mantiene varianza menor y más estable en todo el rango.

`betamwm` **(Figura 11).** VT es más eficiente que LD en todo el rango de H: su varianza se mantiene por debajo de 2.25×10^{-3}, mientras que la de LD supera los 9×10^{-3} para H bajo. La naturaleza multifractal de `betamwm` penaliza especialmente a LD, cuyo modelo wavelet asume monofractalidad.

`wfbm` **(Figura 12).** La situación se invierte: LD es más eficiente en todo el rango, con varianza estable alrededor de 2×10^{-4}, mientras que VT fluctúa entre 2.9×10^{-4} y 3.85×10^{-4}. Para secuencias monofractales, el modelo wavelet de LD se ajusta al proceso, produciendo estimaciones más concentradas.

Tabla 5: Comparación de varianzas para el caso representativo $H = 0.9$.

Generador	**Estimador**	$\hat{\sigma}$	$\hat{\sigma}^2$
`betamwm`	VT	0.0207	4.28×10^{-4}
`wfbm`	VT	0.0188	3.53×10^{-4}
`betamwm`	LD	0.0377	1.42×10^{-3}
`wfbm`	LD	0.0143	2.05×10^{-4}

En síntesis, la eficiencia de cada estimador depende del tipo de proceso: VT es más eficiente ante procesos multifractales (`betamwm`) y LD ante procesos monofractales (`wfbm`), lo que refleja la adecuación del modelo subyacente de cada estimador al tipo de LRD presente.

2.3. Prueba de Consistencia

La consistencia se evalúa fijando H y aumentando el tamaño de muestra $N \in \{2^{10}, 2^{12}, 2^{14}, 2^{16}\}$: un estimador consistente debe mostrar $\mathrm{Var}(\hat{H}) \to 0$ al crecer N, para todo valor de H en el intervalo evaluado.

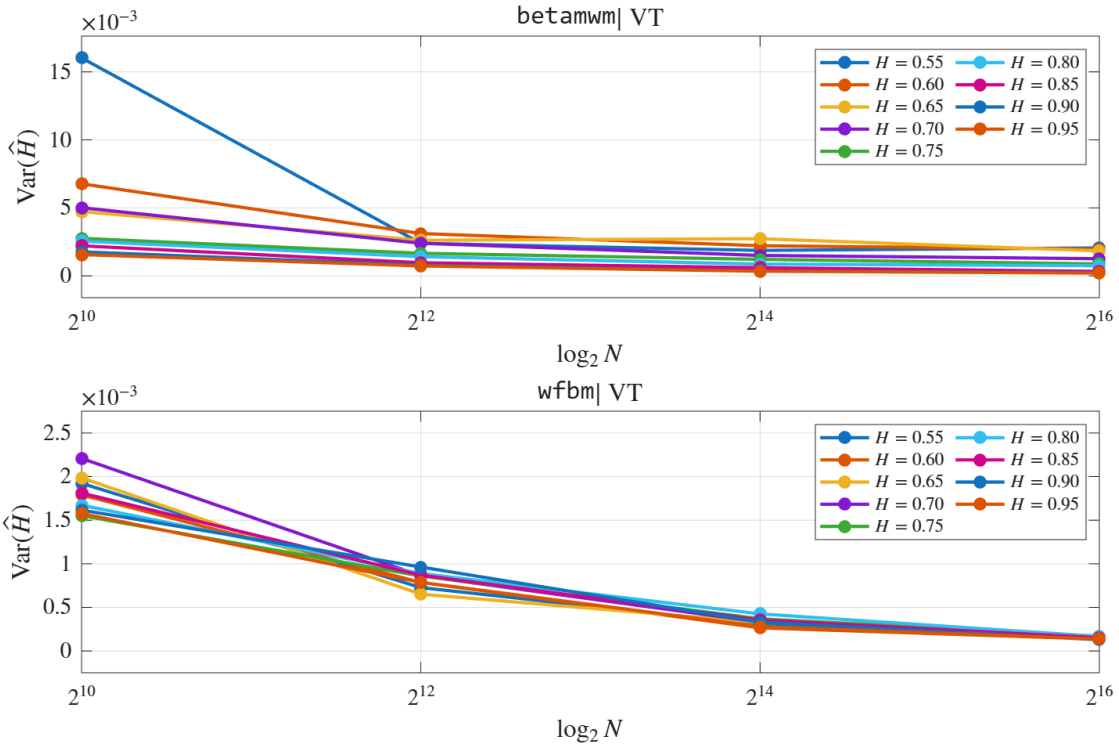


Figura 13: Consistencia del estimador VT: $\mathrm{Var}(\hat{H})$ vs. N para `betamwm` (arriba) y `wfbm` (abajo), con $H \in [0.55, 0.95]$ (300 repeticiones por punto).

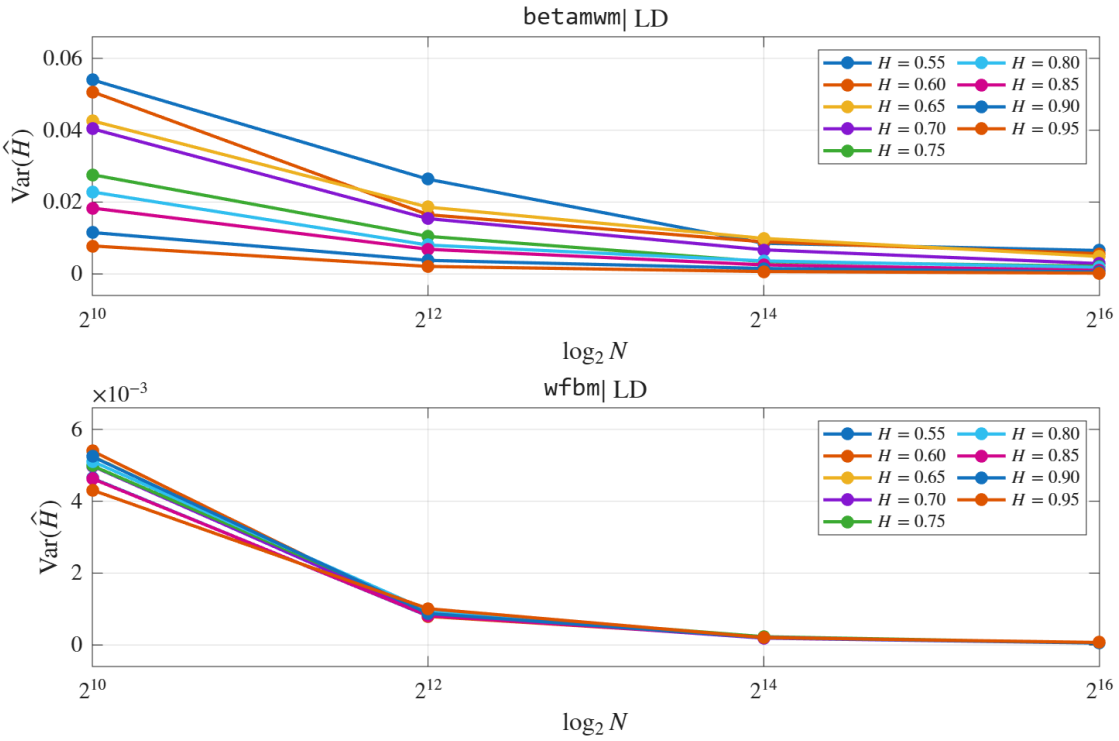


Figura 14: Consistencia del estimador LD: $\mathrm{Var}(\hat{H})$ vs. N para `betamwm` (arriba) y `wfbm` (abajo), con $H \in [0.55, 0.95]$ (300 repeticiones por punto).

Estimador VT – `betamwm` (Figura 13, arriba). Para $H = 0.55$ se observa el caso más problemático: la varianza parte en 1.60×10^{-2} para $N = 2^{10}$ y cae bruscamente a 2.39×10^{-3} en $N = 2^{12}$, pero luego se estabiliza alrededor de 2×10^{-3} para $N \in \{2^{14}, 2^{16}\}$, sin continuar decreciendo. Este comportamiento indica que VT **no es consistente** con `betamwm` para H bajo: la varianza converge a un piso no nulo. Para $H \geq 0.70$ la varianza sí decrece monótonamente, aunque de forma lenta.

Estimador VT – `wfbm` (Figura 13, abajo). Las nueve curvas descienden de manera ordenada y monótona desde $\approx 2 \times 10^{-3}$ en $N = 2^{10}$ hasta $\approx 1.5 \times 10^{-4}$ en $N = 2^{16}$, sin excepción. VT es **consistente** para `wfbm` en todo el rango de H evaluado.

Estimador LD – `betamwm` (Figura 14, arriba). La varianza decrece en todos los casos, pero con magnitudes mucho mayores que VT: para $H = 0.55$ parte en 5.40×10^{-2} y llega a 6.52×10^{-3} en $N = 2^{16}$, aún un orden de magnitud superior al piso de VT. La convergencia es clara pero lenta, especialmente para H bajo. LD es consistente con `betamwm`, pero requiere muestras muy grandes para alcanzar varianzas bajas.

Estimador LD – `wfbm` (Figura 14, abajo). Es el caso más favorable: las nueve curvas se superponen casi perfectamente y descienden de forma pronunciada desde $\approx 5 \times 10^{-3}$ hasta $\approx 5 \times 10^{-5}$, una reducción de dos órdenes de magnitud. LD es **altamente consistente** para `wfbm`, con convergencia rápida e independiente del valor de H.

La columna *Ratio* cuantifica cuántas veces se redujo la varianza al pasar de $N = 2^{10}$ a $N = 2^{16}$. El caso `wfbm` | LD destaca con reducciones superiores a 90×, confirmando su alta consistencia.

En contraste, `betamwm` | VT para H bajo muestra el ratio más pequeño (7.8×) y un piso de varianza residual, señal de inconsistencia asintótica en ese régimen.

2.4. Resumen de la Actividad 2

Tabla 6: Comparación de estimadores VT y LD por propiedad y generador.

Propiedad	**Generador**	**VT**	**LD**	**Ganador**
Sesgo	`betamwm`	Hasta -0.071	Hasta -0.005	**LD**
Sesgo	`wfbm`	Hasta -0.009	Hasta -0.001	**LD**
Eficiencia	`betamwm`	$\hat{\sigma}^2$ menor	$\hat{\sigma}^2$ mayor	**VT**
Eficiencia	`wfbm`	$\hat{\sigma}^2$ mayor	$\hat{\sigma}^2$ menor	**LD**
Consistencia	`betamwm`	Inconsistente (H bajo)	Consistente, lenta	**LD**
Consistencia	`wfbm`	Consistente	Altamente consistente	**LD**

LD supera a VT en sesgo para ambos generadores y en consistencia para ambos casos. En cuanto a eficiencia, el resultado depende del tipo de proceso: VT es más eficiente ante procesos multifractales (`betamwm`), mientras que LD lo es ante procesos monofractales (`wfbm`). La causa subyacente es el modelo asumido por cada estimador: VT está basado en la varianza del proceso agregado, lo que lo hace robusto ante multifractalidad pero sesgado para H alto; LD utiliza la estructura wavelet, óptima para procesos monofractales pero sensible a la complejidad multifractal de `betamwm`.

3. Actividad 3: Estimación de H en la *European ST-T Database*

Se estimó el parámetro de Hurst de la frecuencia cardíaca instantánea (convertida a BPM desde los intervalos RR) de los 90 registros de la *European ST-T Database*, aplicando los estimadores VT y LD.

3.1. Resultados por registro

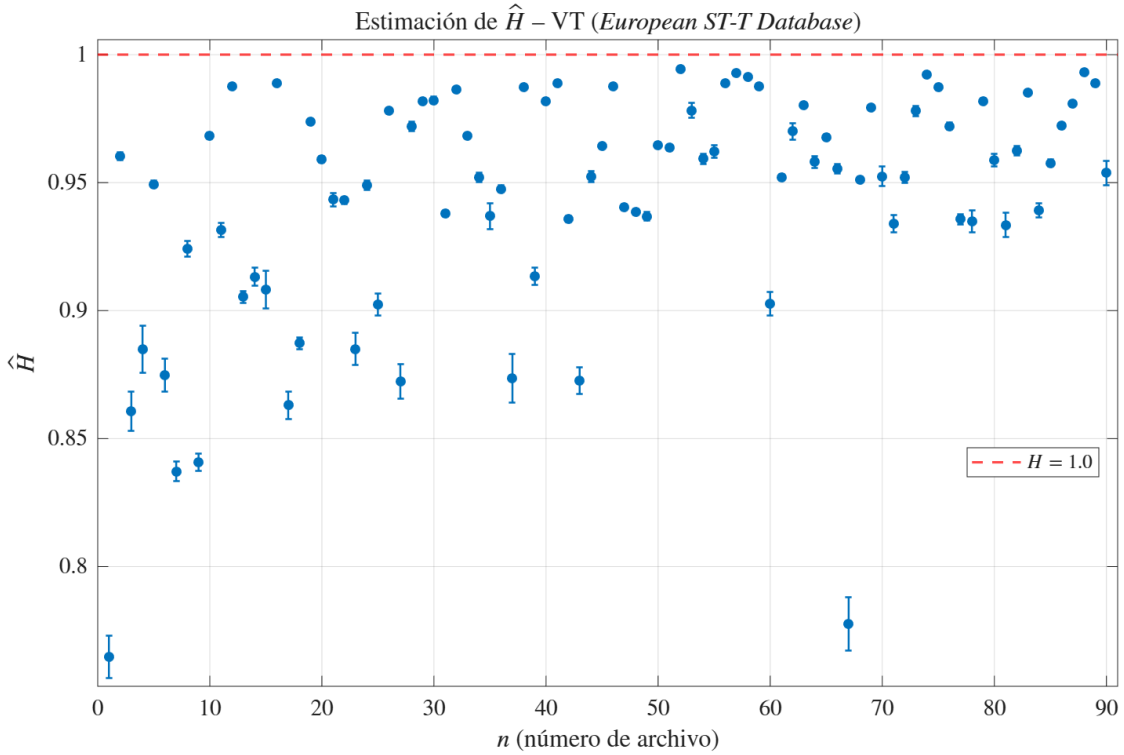


Figura 15: Estimación de $\hat{H}$ con VT para los 90 registros, con intervalos de confianza $[H_{\text{mín}}, H_{\text{máx}}]$.

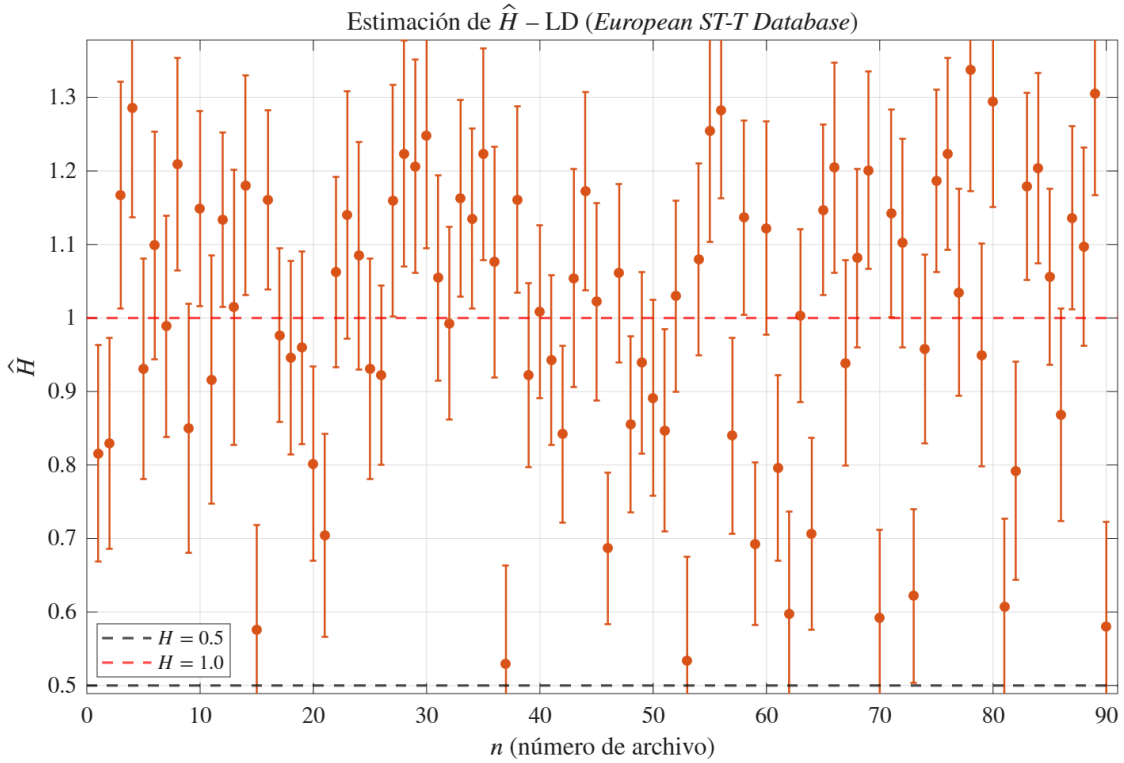


Figura 16: Estimación de $\hat{H}$ con LD para los 90 registros, con intervalos de confianza $[H_{\text{mín}}, H_{\text{máx}}]$.

Estimador VT (Figura 15). Las estimaciones se concentran en el rango [0.77, 0.99], con la mayoría de los registros entre 0.93 y 0.98. Los intervalos de confianza son estrechos y homogéneos entre registros, lo que se traduce en estimaciones estables y reproducibles. Dos registros ($n = 1$ y $n = 68$) presentan $\hat{H} \approx 0.77$, alejándose del comportamiento general. Ninguna estimación supera $H = 1.0$.

Estimador LD (Figura 16). Las estimaciones son notablemente más dispersas: el rango cubre desde ≈ 0.53 hasta ≈ 1.29. Una fracción considerable de registros presenta $\hat{H} > 1.0$, valor que no tiene interpretación física válida para un proceso estacionario. Los intervalos de confianza son amplios e inconsistentes entre registros, con algunos casos cubriendo casi 0.7 unidades de H.

3.2. Distribución global

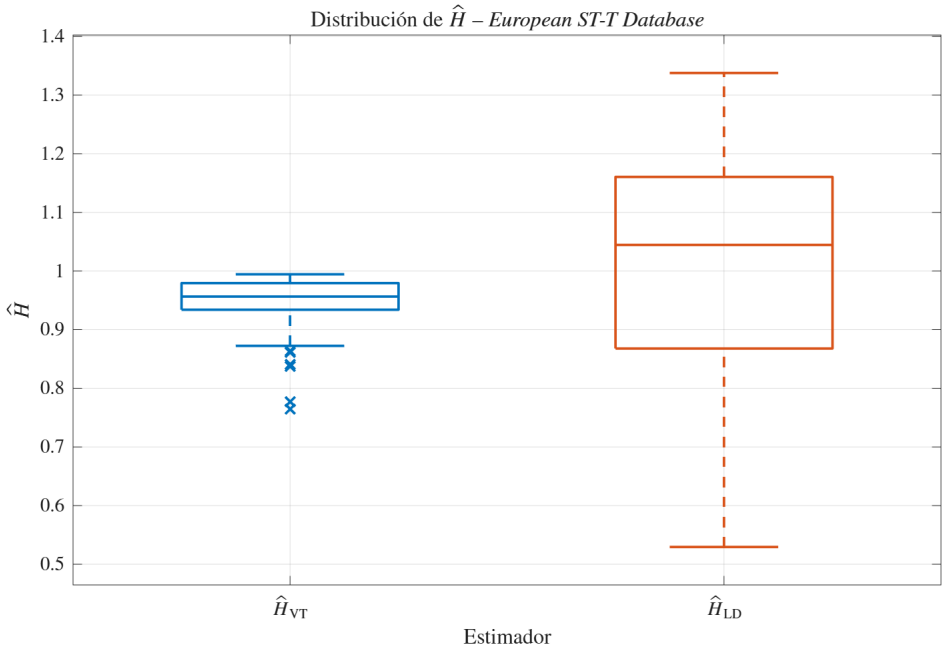


Figura 17: Distribución de $\hat{H}$ para los 90 registros, VT (azul) y LD (naranja).

La Figura 17 resume las diferencias entre estimadores. En el diagrama de caja y bigotes, el bigote superior representa el valor máximo no atípico, es decir, el dato más alto que no supera $Q_3 + 1.5 \cdot \text{IQR}$; el bigote inferior representa el valor mínimo no atípico, definido como el dato más bajo que no cae por debajo de $Q_1 - 1.5 \cdot \text{IQR}$. Los puntos fuera de estos límites se clasifican como valores atípicos y se marcan individualmente.

VT produce una distribución compacta: mediana ≈ 0.96, $Q_1 \approx 0.95$, $Q_3 \approx 0.97$, con un rango intercuartílico de apenas 0.02. El bigote superior llega a ≈ 1.00 y el inferior a ≈ 0.87, con tres valores atípicos por debajo (≈ 0.86, 0.84 y 0.77), que corresponden a registros con dinámica cardíaca particularmente distinta al resto de la base de datos.

LD presenta mediana ≈ 1.05, $Q_1 \approx 0.88$, $Q_3 \approx 1.16$, con un rango intercuartílico casi quince veces mayor que el de VT. El bigote superior alcanza ≈ 1.34 y el inferior ≈ 0.53, sin valores

atípicos detectados. Esto no es una señal favorable: significa que la dispersión es tan elevada que incluso los valores extremos quedan absorbidos dentro de los límites estadísticos del diagrama. En VT, los atípicos son registros genuinamente distintos al resto; en LD, la ausencia de atípicos refleja que la varianza intrínseca del estimador es tan alta que no permite distinguir comportamientos excepcionales.

3.3. Interpretación

Ambos estimadores coinciden en señalar LRD fuerte en todos los registros ($\hat{H} > 0.5$ en la totalidad de los casos). Sin embargo, sus resultados difieren sustancialmente en precisión, y la elección del estimador más adecuado depende de factores que se analizan a continuación.

Los registros de la base de datos contienen del orden de 1 000 a 5 000 intervalos RR por archivo. En ese régimen de tamaño muestral, la evaluación sobre secuencias i.i.d. demostró que VT presenta menor varianza que LD: la ventaja de LD en eficiencia solo se materializa para $n \geq 5\,000$. Este es el argumento más directo para preferir VT en esta base de datos, independientemente de la naturaleza del proceso.

VT presenta sesgo negativo creciente con H: para valores reales cercanos a 0.9–0.95, subestima el verdadero exponente. Esto sugiere que el valor real de H podría ser aún más próximo a 1.0 de lo que reporta. A pesar de ello, produce estimaciones estrechas y físicamente interpretables ($\hat{H} < 1.0$) en la totalidad de los registros.

LD genera en varios registros $\hat{H} > 1.0$, valor sin interpretación física válida para un proceso estacionario. Esto no refleja una propiedad real de la señal, sino la alta varianza de LD cuando opera en el régimen de alta LRD con muestras de tamaño moderado. La ausencia de valores atípicos en su boxplot no es favorable: evidencia que su dispersión intrínseca es tan elevada que incluso los valores extremos resultan estadísticamente normales dentro de su distribución.

Cabe señalar que la adecuación definitiva de cada estimador a esta señal depende también de su naturaleza mono o multifractal, cuestión que se aborda en la Actividad 4. Si la señal resultara monofractal y de tamaño muestral suficiente, LD podría ofrecer ventajas adicionales en eficiencia.

En conclusión, para esta base de datos y en las condiciones actuales de tamaño muestral, VT produce estimaciones más confiables: $\hat{H}_{\mathrm{VT}} \approx 0.96$ como valor central, con baja dispersión entre registros y coherencia física garantizada. Los resultados de LD deben interpretarse con cautela.

4. Actividad 4: Herramienta de clasificación mono/multifractal

Se desarrolla una herramienta en MATLAB que, dada una secuencia discreta, determina si es monofractal o multifractal. El algoritmo opera en dos etapas basadas en el R^2 del ajuste lineal:

1. **Verificación de LRD** ($R^2_{\mathrm{VT}} \geq 0{,}85$): se ajusta una recta al diagrama varianza–tiempo.

Si el ajuste es pobre, la muestra se descarta como *no clasificable*.

2. **Clasificación fractal** ($R^2_\tau \geq 0{,}90$): se obtienen los exponentes de escala $\tau(q)$ con `dwtleader`. Si $\tau(q)$ es lineal, la muestra es monofractal; si presenta curvatura, es multifractal.

4.1. Diagrama de flujo

La Figura 18 presenta el algoritmo implementado.

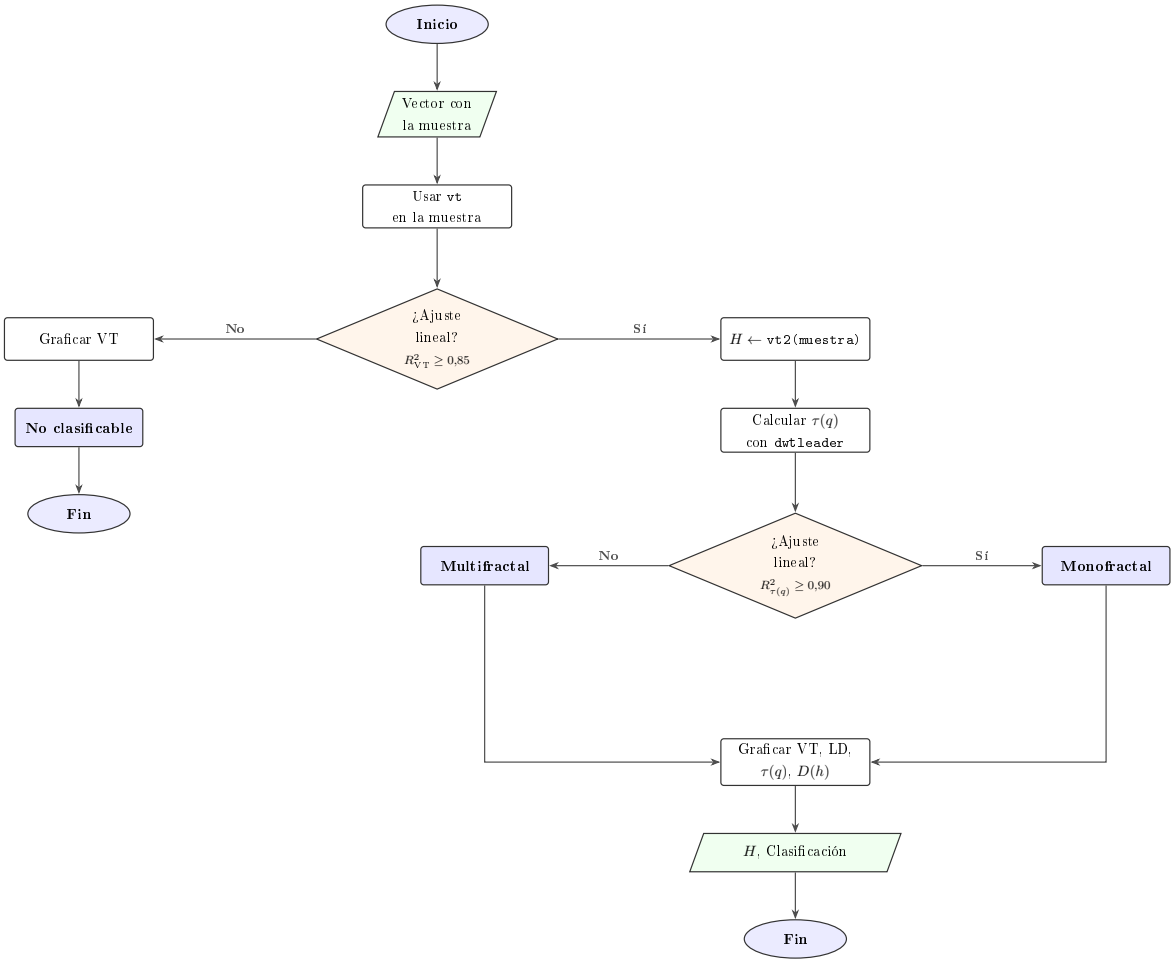


Figura 18: Diagrama de flujo del clasificador mono/multifractal.

4.2. Validación

Se generan muestras de 2^{17} datos con `wfbm` (monofractal) y `betamwm` (multifractal) para validar la herramienta. Las Figuras 19 y 20 muestran los resultados para $H = 0{,}8$.

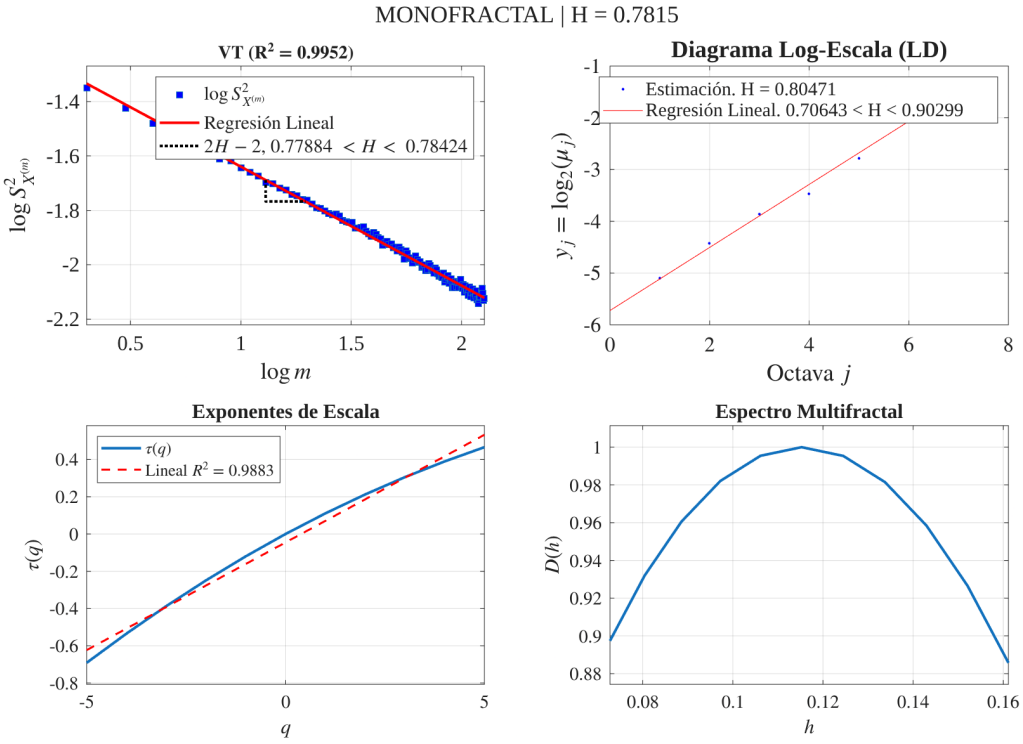


Figura 19: Muestra monofractal (`wfbm`, $H = 0{,}8$): $\tau(q)$ es lineal ($R^2_\tau = 0{,}9883$) y $D(h)$ se concentra en un rango estrecho.

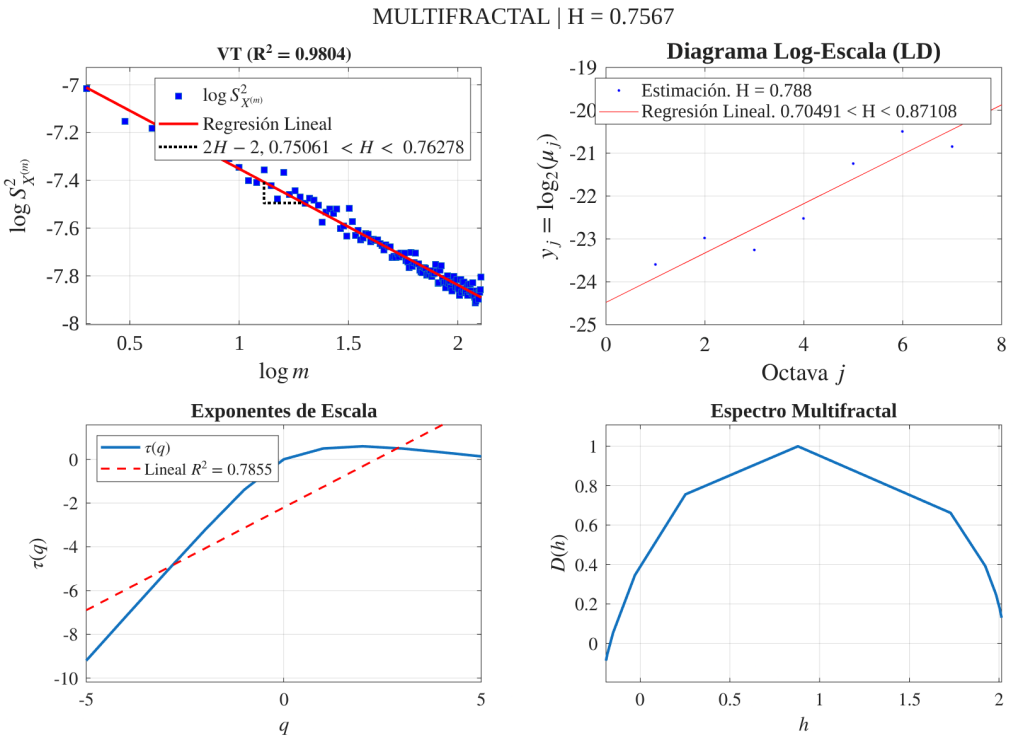


Figura 20: Muestra multifractal (`betamwm`, $H = 0{,}8$): $\tau(q)$ presenta curvatura ($R^2_\tau = 0{,}7855$) y $D(h)$ tiene forma de campana.

La Tabla 7 presenta el barrido completo. La columna $R^2_{\tau(q)}$ permite ver directamente por qué el clasificador toma cada decisión: valores cercanos a 1 indican linealidad (monofractal), mientras que valores por debajo de 0,90 revelan curvatura (multifractal).

Tabla 7: Validación del clasificador con distintos valores de H.

Generador	**Tipo real**	H	$\hat{H}$	$R^2_{\tau(q)}$	**Clasificación**
`wfbm`	monofractal	0,6	0,6095	0,9911	monofractal
`wfbm`	monofractal	0,7	0,7013	0,9940	monofractal
`wfbm`	monofractal	0,8	0,7827	0,9958	monofractal
`wfbm`	monofractal	0,9	0,8431	0,9920	monofractal
`betamwm`	multifractal	0,6	0,6088	0,8967	multifractal
`betamwm`	multifractal	0,7	0,7038	0,9055	monofractal*
`betamwm`	multifractal	0,8	0,7735	0,8702	multifractal
`betamwm`	multifractal	0,9	0,8748	0,8521	multifractal

*Caso borderline: $R^2_\tau = 0{,}9055$, apenas por encima del umbral 0,90.

4.3. Análisis

La herramienta clasifica correctamente 7 de las 8 muestras evaluadas. Las muestras generadas con `wfbm` presentan R^2_τ consistentemente superior a 0,99, lo que confirma la linealidad de $\tau(q)$ propia de un proceso monofractal. En contraste, las muestras de `betamwm` exhiben R^2_τ entre 0,85 y 0,90, reflejando la curvatura esperada en un proceso multifractal.

El caso de `betamwm` con $H = 0{,}7$ ($R^2_\tau = 0{,}9055$) se ubica justo en el límite del umbral. Esto se debe a la naturaleza estocástica del generador: para ciertos valores de H, la curvatura de $\tau(q)$ es menos pronunciada y una realización particular puede producir exponentes casi lineales. Este comportamiento es inherente a cualquier clasificador basado en umbrales fijos y no invalida la herramienta, sino que señala una zona de transición donde la distinción entre mono y multifractal es menos marcada.

5. Actividad 5: Clasificación fractal de la European ST-T Database

6. Actividad 6: Escenario real con LRD

Conclusiones

asdasdasd

Referencias